中图分类号：TM912　　论文编号：
学科分类号：470.40　　密　　级：公　开

安徽理工大學

专业学位硕士学位论文

（全日制）

基于 AFFRLS-MIASRCKF 算法的锂电池 SOC 估计

作者姓名：王保德
专业名称：电气工程
研究方向：电池管理
导师姓名：郭来功 副教授
导师单位：安徽理工大学
答辩委员会主席：余安徽　高级工程师
论文答辩日期：2025 年 5 月 24 日

安徽理工大学研究生院

2025 年 6 月 6 日

中国知网 https://www.cnki.net

A Dissertation in Electrical Engineering

SOC Estimation of Lithium Battery Based on AFFRLS-MIASRCKF Algorithm

Candidate: Wang Baode

Supervisor: Guo Laigong

School of Electrical and Information Engineering

Anhui University of Science and Technology

No. 168, Taifeng Street, Huainan, 232001, Anhui, P. R. China

中国知网 https://www.cnki.net

摘 要

锂离子电池因其高能量密度、长循环寿命及低自放电率等优势，已广泛应用于便携式电子设备、电动汽车以及储能系统等领域。荷电状态（State of Charge, SOC）是电池管理系统的关键参数之一，对提升电动汽车安全性、稳定性以及延长电池寿命具有重要意义。本文以三元锂电池为研究对象，对 SOC 估计方法进行研究，具体的研究内容如下：

（1）基于搭建的锂电池测试平台，对 NCR-18650GA 型单体锂电池进行特性试验，具体包括温度特性试验、开路电压特性试验和动态工况试验。通过实验数据，分析了不同温度对其放电容量与 OCV 的影响规律。结果表明：随着温度的升高，锂离子电池的放电容量逐渐增加，OCV-SOC 关系曲线的斜率逐渐增大。

（2）基于二阶 RC 等效电路模型，对比分析了离线和在线参数辨识方法。采用灰狼优化算法（Grey Wolf Optimizer, GWO）进行离线参数辨识，采用带遗忘因子的递推最小二乘法（Forgetting factor recursive least squares, FFRLS）与自适应遗忘因子递推最小二乘法（Adaptive Forgetting Factor Recursive Least Square, AFFRLS）进行在线参数辨识。结果表明：GWO 算法在静态脉冲工况下参数辨识的均方根误差均控制在 11.3mV 以内，但在动态工况中误差显著增大；而 FFRLS 算法与 AFFRLS 算法均能有效跟踪动态参数变化，在动态工况中，辨识的均方根误差均低于 28.3mV。其中，AFFRLS 算法通过引入自适应遗忘因子，在 BJDST 工况下将辨识的均方根误差降至 4.9mV，较 FFRLS 算法误差减少了 47.3%，展现出更优的准确性。

（3）在 ASRCKF 的基础上，引入多新息理论，提出一种融合多新息自适应平方根容积卡尔曼滤波算法（Multi-innovation Adaptive Square Root Cubature Kalman Filter, MIASRCKF），并通过结合 AFFRLS 算法，实现锂离子电池 SOC 估计。为验证方法的有效性，在不同环境温度下，基于 BJDST 与 FUDS 动态工况进行验证。结果表明：在 BJDST 工况下，AFFRLS-MIASRCKF 算法的 SOC 估计均方根误差均低于 1%；在 FUDS 工况下，RMSE 仍稳定在 3%以内。最后分析了不同 SOC 初始值和高斯噪声对 AFFRLS-MIASRCKF 算法估计的影响，结果表明：AFFRLS-MIASRCKF 算法估计精度均控制在 3%以内，具有较好的准确性与鲁棒性。

图 [50] 表 [13] 参 [87]

关键词：锂电池；等效电路模型；参数辨识；容积卡尔曼滤波；SOC 估计

分类号：TM912

中国知网 https://www.cnki.net

Abstract

Lithium-ion batteries have been widely used in portable electronic devices, electric vehicles, and energy storage systems due to their high energy density, long cycle life, and low self-discharge rate. State of charge (SOC) is one of the key parameters of battery management systems, which is of great significance for improving the safety, stability and battery life of electric vehicles. In this paper, the SOC estimation method is studied with ternary lithium battery as the research object, and the specific research contents are as follows:

(1) Based on the built lithium battery test platform, the characteristics test of NCR-18650GA single lithium battery was carried out, including temperature characteristic test, open-circuit voltage characteristic test and dynamic working condition test. Through the experimental data, the influence of different temperatures on its discharge capacity and OCV was analyzed. The results show that with the increase of temperature, the discharge capacity of lithium-ion batteries gradually increases, and the slope of the OCV-SOC relationship curve gradually increases.

(2) Based on the second-order RC equivalent circuit model, the offline and online parameter identification methods are compared and analyzed. The Grey Wolf Optimizer (GWO) algorithm was used for offline parameter identification, and the Forgetting factor recursive least squares (FFRLS) and Adaptive Forgetting Factor Recursive Least Square, AFFRLS) for online parameter identification. The results show that the root mean square error of the GWO algorithm is controlled within 11.3 mV under the static pulse condition, but the error increases significantly under the dynamic condition, while the FFRLS algorithm and the AFFRLS algorithm can effectively track the dynamic parameter changes, and the root mean square error of the identification is less than 28.3 mV under the dynamic condition. Among them, the AFFRLS algorithm reduces the root mean square error of identification to 4.9mV under the BJDST condition by introducing the adaptive forgetting factor, which is 47.3% lower than that of the FFRLS algorithm, showing better accuracy.

(3) On the basis of ASRCKF, the multi-innovation adaptive square root Cubature Kalman filter (MIASRCKF) algorithm is proposed, and the SOC estimation of lithium-ion batteries is realized by combining the AFFRLS algorithm. In order to verify the

中国知网 https://www.cnki.net

effectiveness of the method, the method was verified under different ambient temperatures based on BJDST and FUDS dynamic working conditions. The results show that the root mean square error of SOC estimation of the AFFRLS-MIASRCKF algorithm is less than 1% under the BJDST condition. Under the FUDS scenario, the RMSE remains stable within 3%. Finally, the influence of different initial SOC values and Gaussian noise on the estimation of the AFFRLS-MIASRCKF algorithm is analyzed, and the results show that the estimation accuracy of the AFFRLS-MIASRCKF algorithm is controlled within 3%, which has good accuracy and robustness.

Figure [50] Table [13] Reference [87]

Key Words: lithium battery; equivalent circuit model; parameter identification; volumetric Kalman filter; SOC estimates

Chinese Books Catalog:TM912

中国知网 https://www.cnki.net

目　录

1 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....2
1.2.1 锂电池模型研究现状.....2
1.2.2 锂电池参数辨识研究现状.....3
1.2.3 SOC 估计研究现状.....5
1.3 研究内容和研究目标.....8
1.3.1 研究内容.....8
1.3.2 研究目标.....9
2 锂离子电池概述及实验设计.....11
2.1 锂离子电池概述.....11
2.1.1 结构及原理.....11
2.1.2 性能参数.....13
2.2 锂离子电池测试平台及实验.....15
2.2.1 温度特性实验.....16
2.2.2 开路电压特性实验.....17
2.2.3 动态工况实验.....18
2.3 本章小结.....21
3 锂离子电池建模及参数辨识.....23
3.1 等效电路模型选择.....23
3.2 等效电路模型建立.....25
3.3 电池模型离线参数辨识.....26
3.3.1 OCV-SOC 曲线获取.....26
3.3.2 基于灰狼算法的离线参数辨识.....27
3.4 电池模型在线参数辨识.....32
3.4.1 含遗忘因子的递推最小二乘法.....32
3.4.2 自适应遗忘因子的递推最小二乘法.....36
3.4.3 不同工况下对比分析.....37
3.5 本章小结.....42
4 锂离子电池 SOC 估计.....43
4.1 卡尔曼滤波算法及变体.....43
4.1.1 EKF 算法的原理.....43
4.1.2 CKF 算法的原理.....44
4.1.3 SRCKF 算法的原理.....47

中国知网　https://www.cnki.net

4.1.4 MIASRCKF 算法的原理 49
4.2 AFFRLS-MIASRCKF 估计 SOC 分析 52
4.2.1 收敛性分析 52
4.2.2 估计精度分析 53
4.2.3 电流和电压传感器噪声的影响 57
4.3 不同工况下各算法 SOC 估计对比分析 62
4.3.1 BJDST 工况结果分析 62
4.3.2 FUDS 工况结果分析 64
4.4 本章小结 66
5 结论与展望 67
5.1 结论 67
5.2 展望 67
参考文献 69

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景及意义

随着全球能源危机和气候变化问题的日益严峻，开发清洁能源和减少碳排放成为了国际社会的共同目标[1]。在资源枯竭和环境污染的双重挑战下，各国政府纷纷采取措施来推动能源结构的转型，其中运输领域作为碳排放的主要来源，能源替代与低碳化转型显得尤为迫切。新能源汽车因其零排放、高效率等特点，正逐渐成为全球绿色交通发展的重要技术路线。在此背景下，我国也在大力推动新能源汽车产业的发展。政府相继发布了《新能源汽车产业发展规划（2021-2035 年）》和《中国制造 2025》等政策性文件，明确提出要加快发展战略性新兴产业推动汽车产业的转型升级[2]。根据中国汽车工业协会的分析数据图 1 所示，2025 年 1 月我国新能源汽车月度销量延续了快速增长的势头，其产销达到了 94.4 万辆，同比增长 29.4%。这一增长不仅反映出新能源汽车在国内市场的快速普及，也为全球能源结构转型和减排目标的实现提供了重要的推动力。

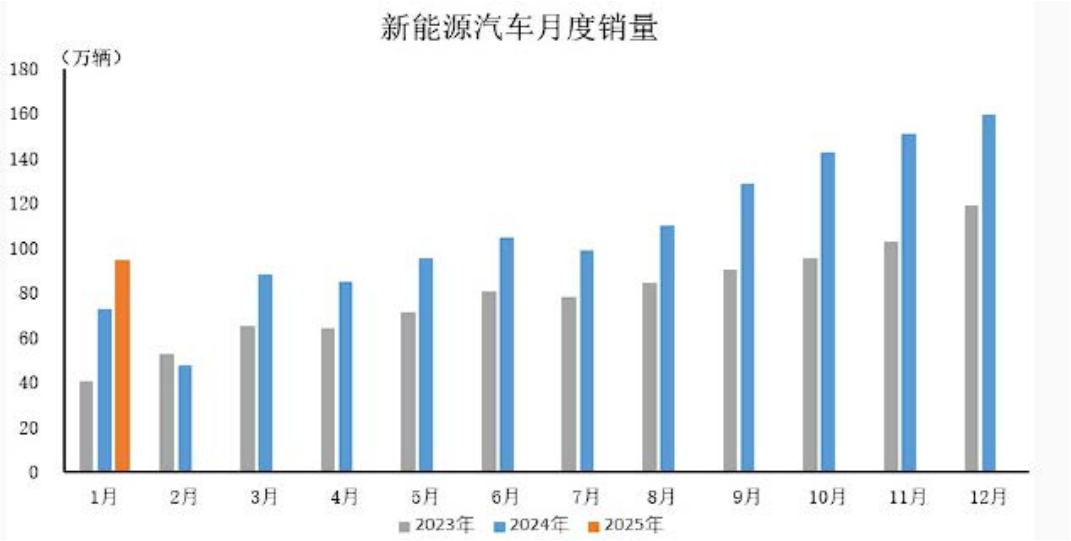


图 1 新能源汽车月度销量

Fig.1 Monthly sales of new energy vehicles

作为新能源汽车的核心技术之一，蓄电池的研究与发展始终是各界关注的焦点。在众多蓄电池技术中，锂离子电池因其高能量密度、长循环寿命等特点，已经成为当前新能源汽车的主流动力电池技术[3-4]。然而，尽管锂离子电池在理论和实验条件下具备优异的性能，但其电化学特性却极为复杂，且容易受到外部环境的影响。例如温度、充放电速率、使用环境等因素均会对电池的各项性能产生不同程度

中国知网 https://www.cnki.net

的影响。此外锂电池还表现出强烈的动态非线性特性，这意味着电池的电压、容量、内阻等性能参数在实际使用过程中并非恒定，而是会随着时间、负载及使用条件的变化而变化。这种变化不仅使电池性能的预测变得极为复杂，还对电池管理系统（Battery Management System, BMS）的设计与应用提出了更高的要求。

荷电状态（State of Charge, SOC）在 BMS 中扮演着至关重要的角色，它是反映锂电池剩余电量和运行状态的核心参数[5]。准确估算 SOC 不仅关乎电池的安全性和可靠性，对于延长电池使用寿命、优化新能源汽车的整体性能也至关重要。但 SOC 是一个无法直接通过传感器测量的隐含变量，通常需要借助电池的电压、电流和温度等可测量参数并结合相应的模型和算法进行间接估算。传统的 SOC 估算方法，例如基于电压、电流的简单积分法，虽然在某些特定工况下能够达到较为理想的效果，但在实际应用中仍然存在精度和鲁棒性不足的问题，特别是在电池受到温度变化、充放电速率剧烈波动等外部因素影响时，传统方法往往难以准确预测电池的剩余电量和运行状态。这一缺陷直接制约了 BMS 的性能，使其成为锂电池高效、安全运行的瓶颈。

因此，针对锂离子电池 SOC 估计精度与鲁棒性不足的问题，开展深入研究具有重要意义。一方面，提升 SOC 估计的准确性能够为锂电池的安全性、可靠性提供坚实保障，从而优化新能源汽车的性能表现。另一方面，SOC 估计精度的提升对于推动新能源汽车产业的快速发展、促进能源结构的低碳化转型、实现“双碳”目标也具有重要的现实意义。

1.2 国内外研究现状

近年来随着锂离子电池应用数量的增加，国内外越来越多的高校和实验室着手于锂电池 SOC 估计的研究，如国外的新加坡南洋理工大学、美国密歇根大学、瑞典哥德堡查尔默斯理工大学、三菱电气研究实验室，以及国内的清华大学、哈尔滨工业大学、西安交通大学、浙江大学等[6]。通常来说，锂离子电池的 SOC 估计主要分为以下三个步骤：建立电池模型、辨识模型参数以及估计 SOC。建立锂离子电池的模型是估计荷电状态的基础，电池模型、参数辨识与 SOC 估计算法的优越性共同决定了 SOC 估计的最终效果。

1.2.1 锂电池模型研究现状

锂离子电池作为一种复杂的非线性系统，其电气特性受多种因素的影响，如环境温度、电池老化程度、构成材料以及制造工艺等均会对其产生影响。因此，为了

中国知网 https://www.cnki.net

深入分析和研究锂离子电池的性能，需要构建一个合适的模型来描述各影响因素与电池动态特性之间的关系。目前，锂离子电池的模型主要可分为以下几类：

（1）电化学模型

电化学模型[7]考虑了电池内部的电荷转移、离子传导及固液相扩散等过程，通过引入动力学方程，详细描述了电池的内部反应机制。这使得电化学模型能够精确预测电流、电压、电解液过电势、电极电流密度以及固液相锂离子浓度等物理量，因此被认为是描述电池动态特性最为精准的模型。但由于电化学模型通常涉及偏微分方程和耦合方程的求解，导致其求解难度较高。

（2）耦合模型

耦合模型[8]综合考虑了多个领域的相互作用，通常融合电化学、热学、力学和电学等多个方面，能够更加全面地反映电池的综合行为。尽管它能提供对电池性能的高度仿真，但由于考虑因素众多，导致其计算复杂度较大，因此这类模型通常用于电池的仿真研究。

（3）数据驱动模型

数据驱动模型[9-11]是一种线性或非线性函数，通常用来描述输出响应对于输入变量的映射关系，而不考虑系统内部的运作机理，因此能够提供更好的灵活性。然而，这种模型虽然在结构选择上具有较大的自由度，但由于其参数往往缺乏明确的物理意义，无法直接作为电池性能的定量参考，并且数据驱动模型的构建依赖于大量且高质量的训练数据，这种数据的获取往往具有较高的成本和难度，导致其在实际应用中面临着一定的局限性。

（4）等效电路模型

等效电路模型（Equivalent Circuit Model，ECM）通过将电池内部的反应过程（如极化反应和扩散作用）与外部电气特性（如电荷转移阻抗和电极内阻）等效为电路元件的组合，从而整体描述电池的特性。由于等效电路模型中的电路元件大多为线性元件，因此其计算相对简便，且具有较高的精度，这使得 ECM 成为 BMS 领域中应用最广泛的模型之一。目前，Rint 模型[12]、PNGV 模型[13]、Thevenin 模型[14]以及 n 阶 RC 等效电路模型等被广泛应用于 SOC 估计等研究领域，尤其是二阶 RC 等效电路模型在 SOC 估计中的应用最为普遍[15-18]。

1.2.2 锂电池参数辨识研究现状

由于锂离子电池的状态变量与电压、电流、温度等因素存在非线性关系，且电动汽车复杂多变的动态工况进一步加剧了这种非线性特性，因此准确辨识锂离子

中国知网 https://www.cnki.net

电池模型参数变得尤为重要。目前，锂电池模型参数的辨识方法可以分为三类：直接测量法、离线辨识法和在线辨识法[19]。

直接测量法通常通过设计周期性实验来获取未知参数。常见的方法包括通过混合脉冲功率特性测量电池内阻，或通过拟合电化学阻抗谱数据来测定电池的阻抗值[20-21]。这些方法一般可行性较高，且具备较高的精度。然而，该方法所需的时间较长，且具备复杂的分析过程，因此在实际应用中存在一定的局限性。

为克服直接测量法的不足，离线辨识方法被广泛采用。离线辨识通常将电池的电压测量与模型预测之间的均方根误差作为优化目标，通过遗传算法[22]（GA）和粒子群算法[23]（PSO）等全局优化算法来估计未知参数。PSO 特别适用于二阶 RC 模型的参数识别，且与 GA 相结合时能够进一步提升识别精度。部分研究者还采用郊狼算法[24]和布谷鸟搜索算法[25]等新型优化算法，在电池二阶 RC 模型的参数辨识中取得了较好的效果。然而，这些方法虽然能够在静态实验条件下提供较高的辨识精度，但其参数结果通常仅适用于特定的实验环境，难以反映电池在动态运行过程中因工况、环境和使用条件变化而带来的特性变化。因此，在实际复杂多变的工况下，离线辨识的局限性逐渐显现，其难以满足实时监测与动态控制的需求。

为提升电池模型的适应性和实时性，在线参数辨识方法应运而生。目前，在线参数辨识方法主要可分为两类：智能寻优算法和基于递推最小二乘法[26]的方法。智能寻优算法虽然能有效进行参数辨识，但在实际应用中存在优化时间长、容易陷入局部最优等问题，导致其难以满足实时性的要求。因此，基于递推最小二乘法（Recursive Least Square, RLS）的方法成为在线辨识中的另一重要选择。RLS 算法假设电池模型的参数具有缓慢变化的特性，并能够自动追踪这些变化，从而提高电池模型的适应性和预测精度。然而，RLS 在实际应用中可能会遇到数据饱和问题，导致新数据的影响力减弱，进而影响算法性能。对此，研究者提出引入含遗忘因子的递推最小二乘法[27-29]（FFRLS），通过遗忘旧数据避免数据饱和，实现了对时变参数的实时辨识。然而，FFRLS 虽然能够通过引入遗忘因子来应对时变参数，但由于固定遗忘因子的策略，使它在处理电池模型参数的动态变化时，无法充分适应复杂工况下的时变性，进而影响参数辨识的精度。针对这一问题，研究者提出了自适应遗忘因子递推最小二乘法[30-31]（AFFRLS）。通过自适应调整遗忘因子，AFFRLS 能够根据电池运行过程中的时变特性对每个参数进行优化，从而显著提升了系统的鲁棒性与辨识精度。

根据以上分析可知，在线参数辨识方法已在递推最小二乘法和智能寻优算法的基础上得到广泛应用。在这两类方法中，基于递推最小二乘法的算法通过引入遗

中国知网 https://www.cnki.net

忘因子以及改进遗忘因子等策略，能够更好地应对时变参数的挑战，在复杂的电池动态变化环境下，具备更好的稳定性和适应能力。

1.2.3 SOC 估计研究现状

电池的 SOC（State of Charge），即表示为电池的荷电状态，通常用于反应电池的剩余电量[32]。目前，我国尚未对 SOC 的定义建立统一的标准。大多情况下，SOC 被定义为电池当前放电至截止电压时所释放的容量与满电状态下可释放容量的比值。其定义公式为：

$$SOC(t)=\frac{C_r}{C_N}\times 100\% \tag{1-1}$$

其中，C_r 代表锂电池的剩余电量，C_N 为电池的额定容量。SOC 的取值范围通常在 0%-100%之间，用以直观地反映电池的剩余电量。例如，当 SOC 为 100%时，表明电池处于满电状态；而当 SOC 接近 0%时，说明电池即将耗尽需要充电。目前常见的动力电池 SOC 估计方法有：查表法[33]、安时积分法[34]、基于电化学阻抗谱的方法[35]、基于模型的方法[36]以及基于数据驱动的方法[37]。

（1）查表法

查表法是一种通过电池的外部特征参数来反应其内部状态，从而实现对电池 SOC 估计的方法。目前方法包括有开路电压法[38]和交流阻抗法[39]。

开路电压法（Open Circuit Voltage, OCV）是通过测量无输出电流下电池两端电压来推算电池的 SOC。当输出电流为零时，电池两端电压与 SOC 之间存在一定的非线性关系，因此可以通过测量 OCV 估计 SOC 值。OCV 法的优点在于其实施简单且成本低廉。然而，该方法的精度易受温度等环境条件影响。因此，为了提高 SOC 估计的精度和鲁棒性，一般将其与其他方法结合使用。

交流阻抗法是另一种形式的查表法，其通过测量电池的交流阻抗来估计 SOC。该方法的基本原理是基于电池在不同频率下的阻抗特性和电化学行为，在实际应用中使用电化学阻抗分析仪进行测量，并将获取的阻抗数据转化为 SOC 信息。为了确保测量结果的准确性，电池需要在稳定状态下进行交流阻抗测试，同时需要考虑 SOC 和温度对电池阻抗的影响。研究表明，电池 SOC 越低，交流阻抗也会相应增大，因此该方法在低 SOC 时特别有效。交流阻抗法的优点在于能够提供实时的 SOC 估计值[40]。然而，它的准确性一般受温度和频率的影响较大，且需要专业的设备和复杂的算法来处理测量数据。

中国知网 https://www.cnki.net

（2）安时积分法

安时积分法又称库仑计数法，是一种简单且直观的 SOC 估计方法。该方法根据电池充放电时的电流积分来计算电池的剩余容量，在电流传感器精度足够高且已知电池初始状态的前提下，可以实现高精度的电池 SOC 估计。然而安时积分法过度依赖于电流传感器来测量充放电电流，当传感器受到噪声、温度变化或硬件不精确的影响时，会导致电流测量的不准确，进而影响 SOC 的估计。同时，安时积分法本身没有内建的误差校正机制，随着时间的推移，误差不断累积，SOC 估计误差会越来越大。

（3）基于电化学阻抗谱的方法

电化学阻抗谱（Electrochemical Impedance Spectroscopy, EIS）是一种用于分析和模拟电化学系统的技术手段。在宽频率范围内，对电池施加小的干扰信号时，通过测量频率范围内的阻抗谱判断电池的状态。EIS 的数据通常使用 ECM 来解释，ECM 通常由多种元件组成，包括电感、电阻和电容等元件，这些元件可以通过不同的组合形式来构造不同的 ECM。文献[41]提出了一种由多元件组成的 ECM 建立 EIS，用于拟合不同 SOC 下的 EIS 数据，并深入研究了多项式函数顺序的影响。结果表明，该模型能够精确地拟合 EIS，远优于常见的插值法。然而，尽管 EIS 方法在电池状态评估中具有重要应用，但它也存在一些局限性。首先，EIS 测试通常耗时较长，尤其在低频范围影响实时监测电池性能。其次，EIS 数据的解释过度依赖复杂的模型，不同模型可能得出不同结论，结果受模型选择和拟合过程影响较大。此外，EIS 测试受电池老化、温度变化等外部因素影响较大，导致数据的可靠性降低。

（4）基于模型的方法

该方法是通过建立锂离子电池的数学模型推算电池的 SOC，具有实时和闭环反馈的优点，因此得到了很大发展。其估计方法多样，例如卡尔曼滤波器(Kalman Filter, KF)及变体[42-44]、粒子滤波器[45](Particle Filter, PF)、H∞滤波器[46](H Infinity Filter, HIF)以及其他状态观测器。

KF 通过预测系统状态并将预测值与实际测量值进行比较，从而不断修正系统状态的估计值。然而，由于 KF 假设系统为线性模型，处理非线性问题时会表现不佳。针对这一问题，研究人员提出了一些基于 KF 的扩展方法，如扩展卡尔曼滤波器[47]（Extended Kalman Filter, EKF）、无迹卡尔曼滤波器[48]（Unscented Kalman Filter, UKF）和容积卡尔曼滤波器[49]（Cubature Kalman Filter, CKF）等。与 KF 相比，EKF 在预测和更新步骤中引入了非线性函数，从而能够处理非线性系统状态的估计问

中国知网 https://www.cnki.net

题。文献[50]基于一阶 Thevenin 电池模型，使用 EKF 对电池的荷电状态（SOC）进行估计，并与安时积分法进行了对比。结果表明，EKF 能够提供比安时积分法更高的准确性和精度，且在电流变化较大的情况下，具有较强的鲁棒性。然而，EKF 的一个主要缺点是对初始参数值的敏感性，如果初始参数不准确，可能导致算法发散，从而影响估计结果。文献[51]利用递推最小二乘法进行电池模型的在线参数识别，并结合无迹卡尔曼滤波（UKF）进行 SOC 估计。相比 EKF，UKF 通过对非线性系统状态进行无迹变换，可以更好地处理系统的非线性特性，因此能够在 SOC 估计中提供更精确的结果。文献[52]提出了一种结合双卡尔曼滤波和充电电压曲线的 SOC 估计方法，结果表明该方法的估计误差低于 3%。此外，文献[53]结合多新息理论和自适应噪声策略，提出了一种基于 MIAUKF 的锂离子电池 SOC 和健康状态（SOH）协同估计方法。文献[54]则通过引入 BP 神经网络对 DUKF 算法的估计结果进行动态修正，从而进一步提高了 SOC 和 SOH 的估计精度。尽管 UKF 相比 EKF 具有更好的性能，但它的计算复杂度和存储需求较高，在高维系统中可能存在计算效率瓶颈。针对这一问题，CKF 作为一种新的扩展卡尔曼滤波方法，具有较低的计算复杂度和更好的适应性。CKF 能够更好地处理电池系统中的非线性特性，尤其在复杂、变化多端的环境条件下，能够提供更准确的 SOC 估计结果[55]。文献[56]将 EKF、UKF 和 CKF 算法在计算时间，计算复杂程序上进行了比较，发现 CKF 算法更具有优势。然而，CKF 也存在一定的局限性。例如，在计算过程中，CKF 可能会丧失矩阵的正定性和对称性，这会影响算法的稳定性。针对这一问题，文献[57]提出了一种改进的 CKF 算法，即 ASRCKF 算法。该算法通过使用平方根滤波代替传统的矩阵求逆操作，从而提高了算法的稳定性。同时，ASRCKF 算法引入了自适应噪声策略，能够动态调整过程噪声和测量噪声，从而增强了算法的适应能力和估计精度。文献[58]采用简化的 S-G 滤波器对 CKF 算法中的噪声进行更新，结果表明其估计误差不超过 1%。文献[59]在 ASRCKF 的基础上，提出一种可变协方差窗口的改进 ASRCKF 算法，进一步提升了 SOC 估计的精度与适应性。文献[60]通过结合 AFFRLS 算法构建了 AFFRLS-ASRCKF 联合算法，并在宽温度下进行验证，结果表明 AFFRLS-ASRCKF 算法收敛性好，算法精度高，鲁棒性更好。

粒子滤波（PF）是一种基于蒙特卡洛方法的状态估计算法，通过在状态空间中传播一组随机样本来近似估计概率密度函数。PF 的优势在于它不依赖于系统的线性化假设，因此能够有效地处理高维非线性系统及非高斯噪声。然而，粒子滤波的计算复杂度较高，且在低信噪比的情况下容易出现粒子贫化问题，因此其在实时 SOC 估算中的应用受到一定限制。针对这一问题，文献[61]提出了一种双粒子滤波

中国知网 https://www.cnki.net

算法（DPF），相较于单一的 PF 算法，有效的提高了锂离子电池 SOC 的估计精度。当然，除了基于滤波算法的估计中，其它类型的观测器也被广泛应用于 SOC 估算中。例如，文献[62]等人采用多级比例积分状态观测器（PI）对电池 SOC 进行估算，并通过实验验证了该方法的准确性。

（5）数据驱动的方法

数据驱动的 SOC 估计方法通常依赖于机器学习或深度学习算法，这些方法利用历史数据、传感器数据以及其他电池运行状态的数据进行训练和估计。常见的数据驱动方法包括：支持向量机[63]、极限学习机[64]、人工神经网络[65]和高斯过程回归[66]等。文献[67]针对 LiFeO4 电池的 OCV-SOC 曲线，提出了一种基于深度神经网络的 SOC 估计方法，估计的 SOC 误差低于 2.03%。文献[68]提出一种基于改进麻雀搜索算法优化 BP 神经网络的锂离子电池 SOC 估计方法，用于解决 BP 神经网络容易陷入局部最优的问题。文献[69]提出了一种基于改进麻雀搜索算法优化极限学习机的 SOC 估计方法，针对人为给定的极限学习机隐含层神经元数量不当导致估计精度不理想的问题，选用麻雀搜索算法对极限学习机隐含层神经元数量进行寻优，同时引入 Tent 混沌映射和模拟退火算法中的 Metropolis 准则对麻雀搜索算法改进以提高麻雀搜索算法的全局搜索能力，在不同温度下 SOC 估计误差均保持在 1.3%以内。文献[70]将 LSTM 与 ACKF 相结合，首先利用 LSTM 完成 SOC 的初步预测，再使用 ACKF 对 LSTM 的预测值进行平滑处理，从而实现准确稳定的 SOC 估计。基于数据驱动的 SOC 估计方法虽然能够克服传统基于物理模型的估计方法的局限，但通常需要较大的计算资源和时间来进行训练和推理，这可能不适合嵌入式系统中实时运行，尤其是在资源受限的场景下。

根据以上分析可知，随着研究的深入，基于模型的 SOC 估计方法，逐渐成为 SOC 估计的主流方法。基于模型的 SOC 估计方法具有较高的精度、良好的实时性、适应性强等优点，能够更好地满足复杂应用环境中的需求。

1.3 研究内容和研究目标

1.3.1 研究内容

本文以 NCR-18650GA 三元锂电池为研究对象，首先开展电池性能特性实验。基于实验获取的数据，在 Matlab 中基于电池二阶 RC 等效电路模型，研究分析了离线参数辨识和在线参数辨识的辨识精度。最后，搭建在线 SOC 估计算法框架，并在不同温度下基于多动态工况数据进行验证。具体的研究内容如下：

中国知网 https://www.cnki.net

（1）锂电池测试实验及特性分析

基于搭建的锂电池测试平台和实验设计方案在不同工作温度下对锂电池进行放电容量、开路电压测试和动态工况测试，研究电池在不同工作温度下的容量和OCV特性，实验获取的电池实验数据为后续参数辨识及状态估计提供支持。

（2）离线和在线参数辨识精度对比研究

基于二阶RC等效电路模型，通过电池实验数据分别进行离线和在线参数辨识并进行辨识结果验证。通过端电压误差评价指标，对离线和在线参数辨识的精度进行比较。

（3）基于AFFRLS-MIASRCKF方法的在线SOC估计框架建立和验证

在电动汽车的实际运行条件下，锂离子电池工作过程中的内部参数会不断变化，如果将内部参数视为定值，则会影响SOC估计的准确性。因此，基于选择的参数辨识算法搭建SOC在线估计框架，并与多种SOC估计算法进行比较分析，验证SOC在线估计框架在不同温度的动态工况下的可行性。

1.3.2 研究目标

（1）探究锂离子电池在不同温度下的特性变化，获取相应的试验数据，为锂离子电池SOC估计提供数据基础。

（2）建立二阶RC电路模型，设计相应的离线和在线参数辨识方法，通过实验数据验证离线和在线参数辨识模型的精度。

（3）构建基于AFFRLS-MIASRCKF算法的SOC估计框架，实现准确的在线估计，在不同温度的动态工况下验证估计方法。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

2　锂离子电池概述及实验设计

锂离子电池因其能量密度高、功率密度大及使用寿命长等优点，被广泛应用于电动汽车、储能系统等多个领域。然而，锂离子电池虽然具有诸多优点，但其内部的化学反应过程复杂且难以直接观测。为了更好地理解锂离子电池的工作原理与性能特性，本章探讨了锂离子电池的基本概念，包括其结构、工作原理以及性能参数。以 NCR-18650GA 型三元锂离子电池为实验对象，搭建电池测试平台，开展了温度特性实验、开路电压特性实验和动态工况实验，实验数据可为后续的锂离子电池参数辨识和 SOC 估计提供基础。

2.1　锂离子电池概述

2.1.1　结构及原理

（1）锂离子电池结构

随着技术的不断进步，锂离子电池已成为储能系统和智能电网领域的核心技术支撑，在能源的开发与利用中发挥着重要作用。锂离子电池主要由正极、负极、隔膜、电解液及电池壳体等部件协同作用组成[71]，其结构如图 2 所示。

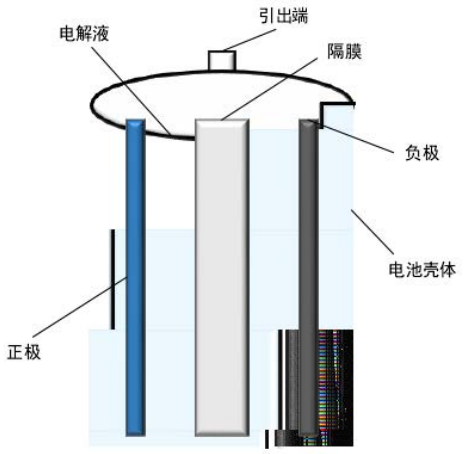


图 2 锂电池组成结构图

Fig.2 Composition structure diagram of lithium battery

1）正极材料：正极材料不仅是锂离子的储存介质，同时也是电池中参与电化学反应的关键组件。常用的正极材料通常为锂化合物，比如钴酸锂（$LiCoO_2$）、锰酸锂（$LiMn_2O_4$）、磷酸铁锂（$LiFePO_4$）及镍钴锰酸锂（$LiNiCoMnO_2$）。这些材料的选择不仅关系到电池的能量密度，还直接影响其循环寿命和安全性。

中国知网　https://www.cnki.net

2）负极材料：在锂离子电池中，负极材料是用于储存锂离子的主体部分。目前主要以石墨或其他碳材料为主，具有优异的嵌锂与脱锂能力。

3）隔膜：隔膜是一种多孔膜材料，位于正极和负极之间，用于防止电极间直接接触导致短路，同时允许锂离子自由穿过。常用的隔膜材料包括聚丙烯（PP）和聚乙烯（PE）等，其厚度和孔隙率设计对电池的性能稳定性和安全性具有重要意义。

4）电解液：电解液是锂离子在正负极之间迁移的介质，起到离子传导和电子隔离的作用，通常由锂盐（如六氟磷酸锂 $LiPF_6$）在有机溶剂中溶解制备而成。电解液的性能对电池的安全性、导电性和化学稳定性起关键作用，同时影响电池的循环寿命和操作温度范围。

5）电池壳体：电池壳体通常可分为钢壳、铝壳、镀镍铁壳及铝塑膜等多个类型，通常在其顶部设有一个电池盖，主要用来实现电池正负极的电性引出。

锂离子电池的工作机制主要是基于锂离子在正极和负极之间的可逆迁移以及相应的氧化还原反应，图 3 为锂离子电池的充放电工作原理。

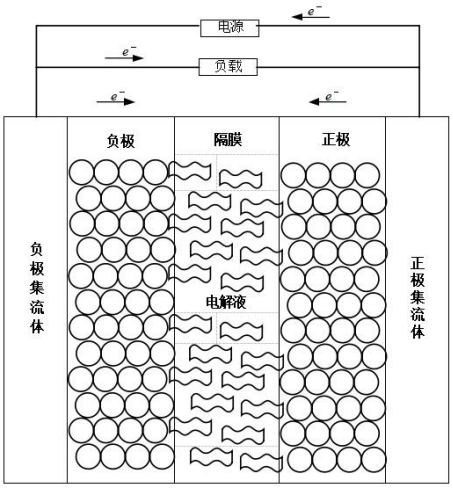


图 3 锂离子电池的工作原理

Fig.3 How lithium-ion batteries work

在充电过程中，正极材料中的锂离子穿过电解液和隔膜迁移到负极，同时电子通过外电路流向负极，参与负极的还原反应并储存能量。相反，在放电过程中，负极材料中的锂离子穿过电解液迁移至正极，而电子则通过外电路回流到正极，与正极材料发生氧化反应释放能量[72]。整个充放电过程依靠锂离子的电解液迁移和电子的外电路传递协同完成，实现能量的高效存储和释放。

由上述分析可知，尽管锂离子电池内部的电化学反应较为复杂，但其工作机制相对直观，主要体现在锂离子在正极和负极之间的嵌入与脱嵌过程中。充放电过程

中国知网 https://www.cnki.net

本质上是正负极之间的氧化还原反应及相关电化学变化，可以采用式(2-1)-(2-3)表示：

$$Li_xA_yB_z \underset{\text{放电}}{\overset{\text{充电}}{\rightleftarrows}} A_yB_z + xLi + xe \tag{2-1}$$

$$xLi + xe + 6C \underset{\text{放电}}{\overset{\text{充电}}{\rightleftarrows}} Li_xC_6 \tag{2-2}$$

$$Li_xC_6 + A_yB_z \underset{\text{放电}}{\overset{\text{充电}}{\rightleftarrows}} Li_xA_yB_z + 6C \tag{2-3}$$

其中，正极的化学反应式如上式（2-1）所示，负极的化学方程式如（2-2）所示，总反应为式（2-3）。

2.1.2　性能参数

在评估和应用锂电池时，理解其性能参数是至关重要的。这些参数能够反映电池的实际表现，并对其应用领域和使用寿命产生直接影响。因此，以下将介绍几个关键的锂电池性能参数。

（1）电池容量

电池容量是衡量电池性能的重要参数之一，通常用来描述电池在特定条件下能够释放的电量大小，是评估电池能量输出能力的重要参考值[73]，其单位通常为毫安时（mAh）。根据测量方式和使用条件，电池容量可以分为额定容量、理论容量和实际容量三类。以 NCR-18650GA 系列锂电池为例，其额定容量由厂家标定，理论容量基于电池活性材料的理想反应计算，而实际容量则是在室温下以 0.5C 电流倍率放电时测得的值。三种容量的对比如图 4 所示。

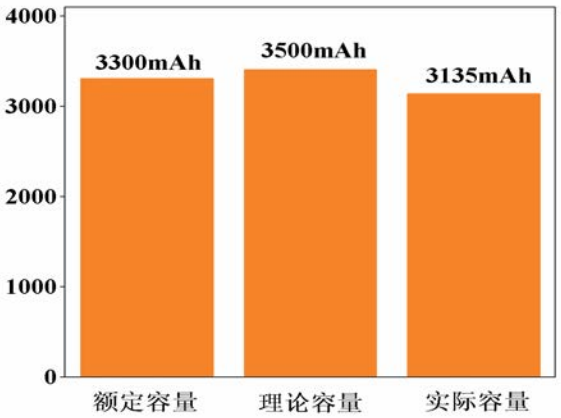


图 4 容量对比图

Fig.4 Capacity comparison chart

通过三种容量类型的对比，可以了解到电池容量受到实际使用条件的影响。因此，在实际应用中应根据实际容量来评估电池的性能，并结合使用场景合理选择电

中国知网　https://www.cnki.net

池类型。

（2）电压

电压也是电池性能的重要表征指标之一，与电池的使用效率和能量输出能力密切相关[74]。在电池的实际应用中，主要涉及以下几种电压参数：开路电压、工作电压和截止电压。

1）开路电压：开路电压具体是指当电池在无输出电流通过时，两极之间的电势差。在这一状态下，电池内部没有电流流动，处于静置且稳定的平衡电势状态。在充电过程中，当电池完成充电后并静置一段时间，开路电压会低于充电截止时的末端电压。在放电过程中，当电池完成放电并静置一段时间，开路电压会高于放电截止时的末端电压。

2）工作电压：工作电压指的是在电池运行过程中表现出的实际电压值，其值通常低于开路电压。这主要是由于电池的内阻效应，当通过较大的放电电流时会导致工作电压下降。

3）截止电压：截止电压分为充电截止电压和放电截止电压。充电截止电压是电池完成充电时的最高电压值，超过此电压可能导致电池过充，出现发热、老化甚至安全问题。放电截止电压是电池在放电过程中的最低允许电压值，低于放电截止电压可能导致电池过放，损害电池内部结构，从而影响电池寿命和性能。

三种电压的关系图如下所示。由于内阻的存在，使得工作电压<开路电压<截止电压，各电压关系所图 5 所示。

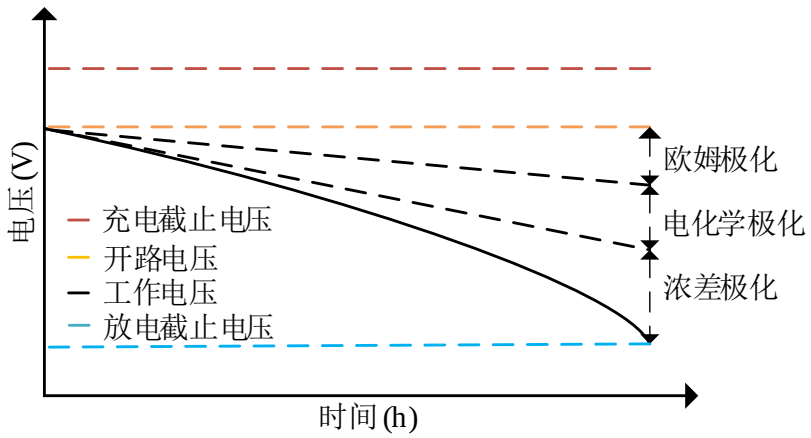


图 5 电压关系图

Fig.5 Voltage diagram

（3）内阻

电池的内阻是指电流通过电池内部时所受到的阻力，是影响电池性能和寿命

中国知网 https://www.cnki.net

的重要参数之一，主要由欧姆内阻和极化内阻组成[75]。欧姆内阻来源于电池材料本身的固有电阻，与电池结构和材料特性密切相关。而极化内阻则是在充放电动态过程中，由于电极反应动力学受限导致的阻力，一般表现为锂离子迁移中的主要阻碍。在锂离子从正极迁移到负极的过程中，内阻对电池的性能产生了显著影响，迁移阻力通常随着化学反应的强度、环境条件以及锂离子运动状态而变化。较高的内阻会直接导致电池工作电压降低、放电时间缩短以及发热量增加，从而影响电池能量利用率并缩短其使用寿命。因此在电池设计和制造过程中，降低内阻显得尤为重要，通过优化材料性能、改进电极结构和提高工艺精度可以有效减少内阻，提升电池的综合性能和使用效率。

2.2　锂离子电池测试平台及实验

本文采用电池测试系统、恒温试验箱、上位机组成的实验平台对三元锂电池进行性能测试，从而获得电池测试过程中的时间、电流、电压、充放电容量等信息，获取的数据可用于估计锂离子电池 SOC 估计。整体的测试平台如图 6 所示，测试对象为 NCR-18650GA 型三元锂电池，主要参数如表 1 所示。

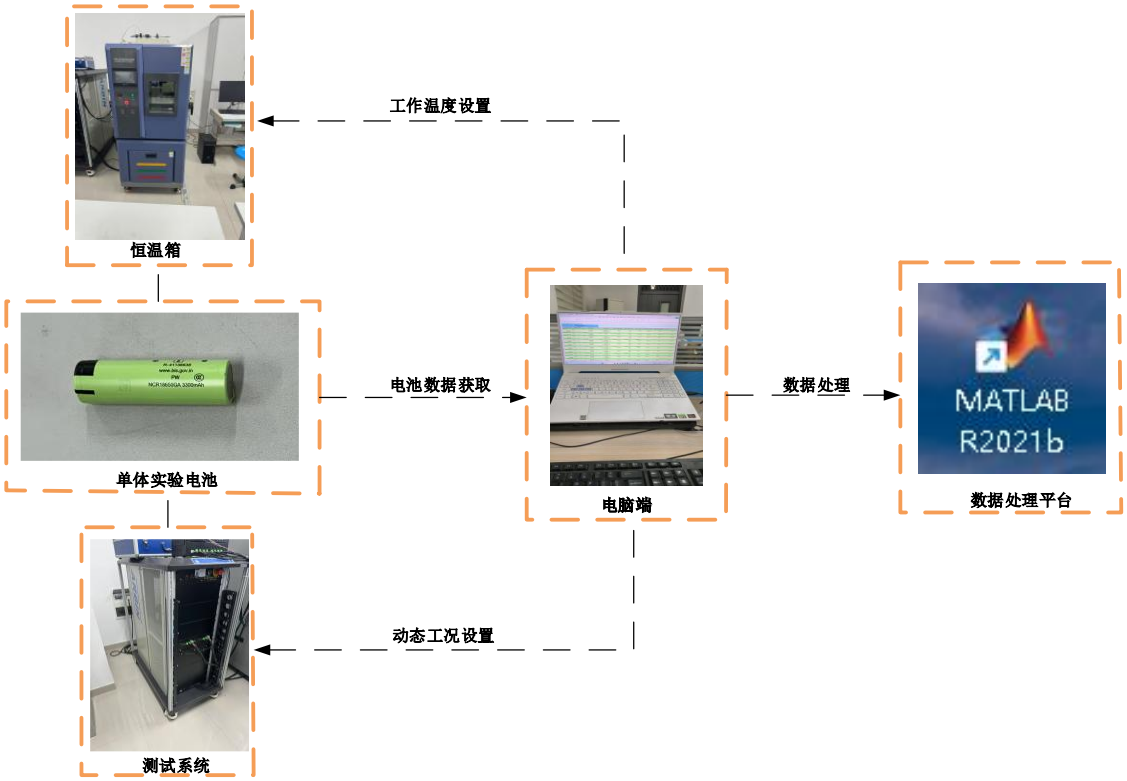


图 6　锂离子电池测试平台

Fig.6 Lithium-ion battery test platform

中国知网　https://www.cnki.net

表 1 NCR-18650GA 型三元锂电池的具体参数

Table 1 Specific parameters of NCR-18650GA type lithium ternary battery

规格	参数
标称容量	3300mAh
额定电压	3.7V
最大充电电压	4.2V
放电截止电压	2.75V
最大充电电流	10A
最大放电电流	10A
内阻	≤25mΩ
工作温度范围	-20°C 至 60°C

2.2.1 温度特性实验

温度是影响锂离子电池性能的影响因素之一，在不同的环境温度下放电，锂电池内部的化学反应会受到影响，导致电池的内阻和极化特性发生变化，进而影响电池容量[76]。为了探究温度对电池的容量影响，分别在-10℃、25℃和 40℃的温度下对样本电池进行恒流充放电实验，实验步骤如下：

（1）设定恒温箱的温度为-10℃。

（2）以 0.24C（0.8A）的电流对电池进行恒流充电至截止电压 4.2V，接着以 4.2V 的恒压使其充电电流稳定至 0.02A，此时认为电池电量已充满。

（3）在-10℃下以 0.3C 的电流对电池进行恒流放电，当电压至放电截止电压 2.75V，此时认为电池电量已放完。

（4）在-10℃放电结束后静置 1 小时。

（5）在 25℃、40℃下设定恒温箱温度重复步骤(2)-(4)，根据得到的放电数据绘制容量曲线。

图 7 展示了在-10℃、25℃和 40℃下进行恒流充放电实验得到容量曲线。从图中可以观察到，在不同温度下锂电池的放电容量是不一致的，随着电池工作温度的降低，电池所释放出的能量有所下降，端电压也有相应程度的降低。在低温环境下，电池的容量明显减少，放电曲线更加陡峭，表现出电池内部化学反应的不稳定性。相对而言，在 25℃和 40℃环境温度下，电池的性能较为稳定，放电容量较高。因此，在实际应用中，应充分考虑锂电池在不同环境温度下的性能差异，以确保电池在多种工作条件下的可靠性和稳定性。

中国知网 https://www.cnki.net

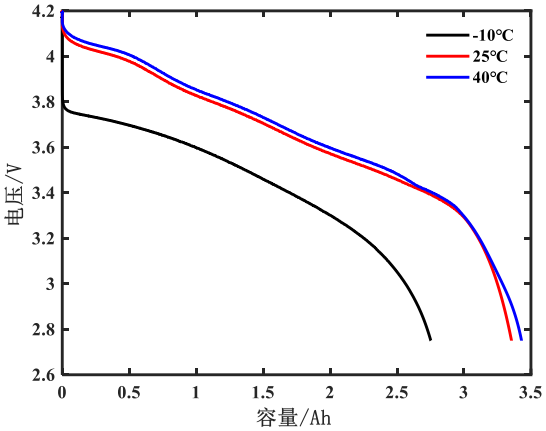


图 7 不同温度下电压-容量图

Fig.7 Voltage-capacity diagram at different temperatures

2.2.2　开路电压特性实验

开路电压(Open circuit voltage, OCV)与电池的荷电状态 SOC 之间存在密切关系，所以研究开路电压对锂离子电池特性分析具有重要意义[77]。在 SOC 估计中，OCV 通常用于提供 SOC 的参考值。为精确标定 OCV 与 SOC 之间的关系，采用长时间静置法，分别在温度为-10℃、25℃和 40℃进行 HPPC 测试，并通过实验数据建立出锂电池的 OCV-SOC 曲线。

实验测试步骤如下：

（1）设定恒温箱的温度为-10℃。

（2）以 0.24C（0.8A）的电流对电池进行恒流充电至截止电压 4.2V，接着以 4.2V 的恒压使其充电电流稳定至 0.02A，静置 1 小时后，测量电池两端电压值，此时电压即为 SOC=100%时对应的开路电压。

（3）在-10℃下以 0.3C 的电流对电池进行恒流放电，放电容量为额定容量的 10%时结束，静置 1 小时后，测量电池两端电压值。

（4）重复步骤（3），当电压至放电截止电压 2.75V 时，本次实验结束。

（5）在 25℃、40℃下设定恒温箱温度重复步骤(2)-(4)。

图 8 展示了在-10℃、25℃和 40℃下进行 HPPC 测试所得到的 OCV 与状态荷电关系曲线。从图中可以看到，不同温度对 OCV-SOC 关系有着影响显著。具体来说，随着温度的升高，曲线的斜率逐渐增大，表现出较大的电压变化范围。尤其是在 40℃的测试条件下，OCV-SOC 曲线的变化最为明显，表明温度的升高使得电池的电化学反应更加活跃，导致开路电压的变化更为敏感。相反，在-10℃的低温环境下，OCV-SOC 曲线的斜率较小，且电压变化幅度较低，说明低温环境下电池的

中国知网　https://www.cnki.net

电化学反应减缓，OCV 与 SOC 之间的关系较为平缓。因此，在实际 SOC 估计中，应考虑电池在不同环境下的性能变化，以确保估计算法在多条件下的适用性，从而为电池管理系统的优化提供理论支持和实践依据。

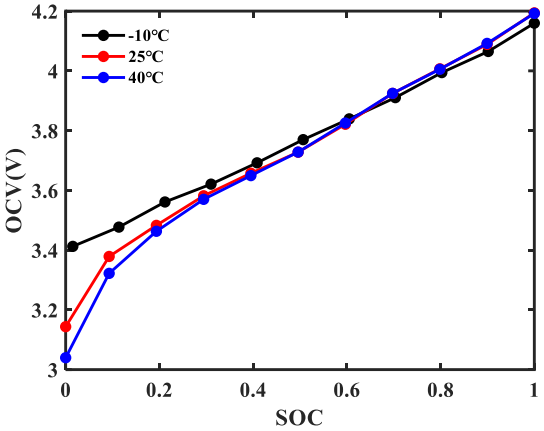


图 8 不同温度下的 OCV-SOC 关系曲线

Fig.8 OCV-SOC relationship curves at different temperatures

2.2.3 动态工况实验

锂电池动态工况测试的本质是通过模拟车辆加速、制动、怠速等非线性负载特性，构建能够反映实际驾驶场景的电池响应数据库。为构建面向复杂环境的数据基准，本文选取 BJDST（Beijing dynamic stress test，BJDST）和 FUDS（Federal Urban Driving Schedule，FUDS）两种典型动态工况，分别在-10℃、25℃和 40℃下进行实验测试。

(1) BJDST 工况实验

BJDST 工况是一种针对电动汽车电池性能测试的标准工况，设计时考虑了多样化的驾驶模式，包括城市道路、高速公路等不同环境下的驾驶行为。该工况通过模拟多种实际驾驶情况，旨在评估电池在不同驾驶条件下的综合表现，特别是电池的能量消耗和温度变化等关键指标。

BJDST 动态工况实验步骤具体如下：

（1）设定恒温箱的温度为-10℃。

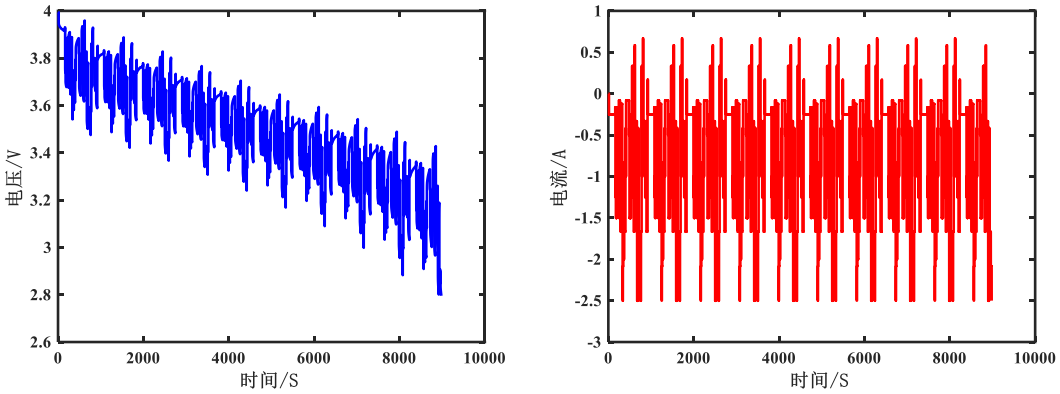
（2）以 0.24C（0.8A）的电流对电池进行恒流充电至截止电压 4.2V，接着以 4.2V 的恒压使其充电电流稳定至 0.02A 后结束充电，并静置 1 小时。

（3）设置 BJDST 动态工况，采样间隔 1s，对电池进行循环测试，当达到放电截止电压 2.75V 时结束测试，并静置 1 小时。

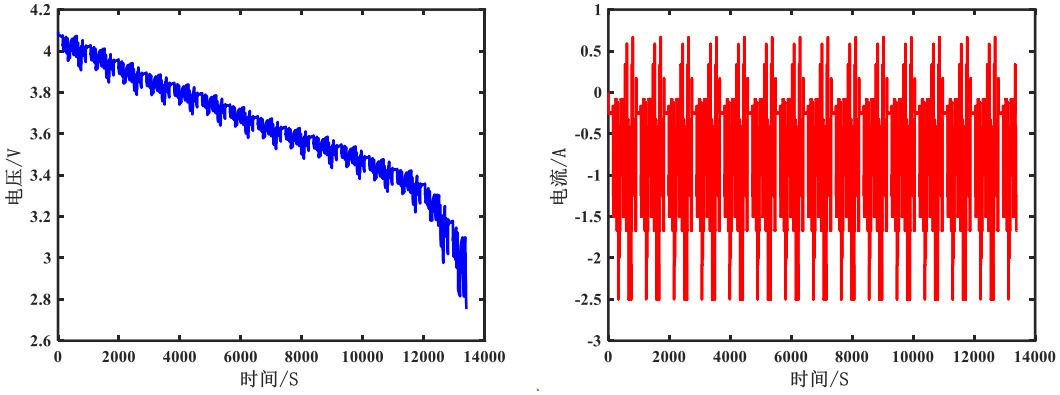
（4）在 25℃、40℃下设定恒温箱温度重复步骤(2)-(3)。

中国知网 https://www.cnki.net

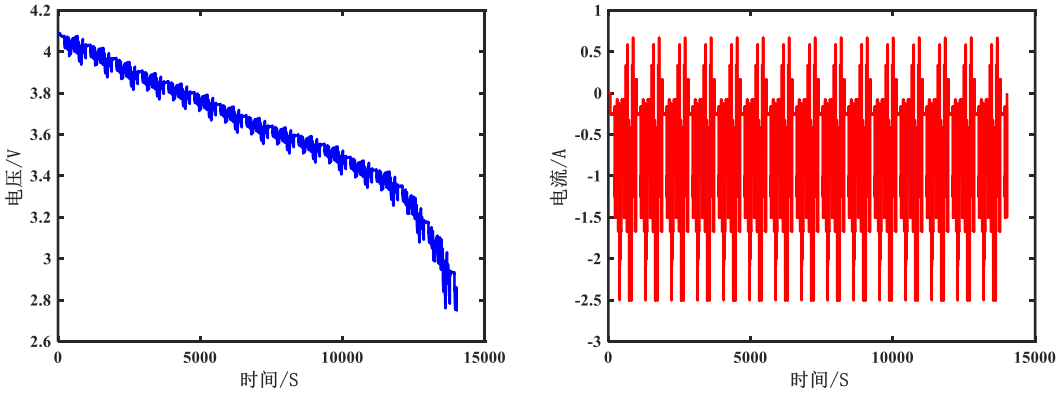
根据上述步骤，该工况在-10℃、25℃和 40℃下的电压电流测试数据如图 9 所示。



(a) -10℃



(b) 25℃



(c) 40℃

图 9 BJDST 工况在不同温度下的电流电压曲线

Fig.9 Current and voltage curves of BJDST at different temperatures

中国知网　https://www.cnki.net

(2) FUDS 工况试验

FUDS 工况是一种经典的城市驾驶循环工况，广泛应用于电动汽车和插电式混合动力汽车的性能测试中。设计时考虑了城市交通的特点，如频繁的起停和低速行驶，测试中通常包含较短的行驶时间和较长的停车时间，充分模拟实际交通状况对电池性能的影响。

FUDS 动态工况实验步骤具体如下：

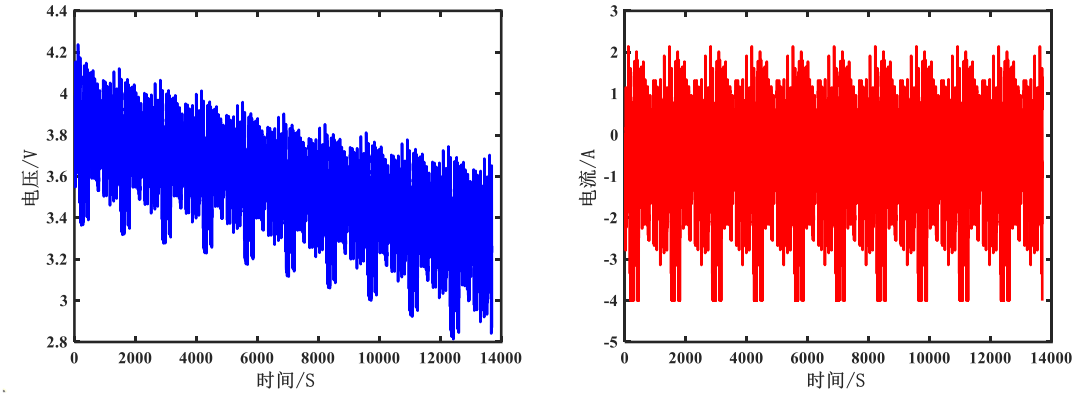
（1）设定恒温箱的温度为-10℃。

（2）以 0.24C（0.8A）的电流对电池进行恒流充电至截止电压 4.2V，接着以 4.2V 的恒压使其充电电流稳定至 0.02A 后结束充电，并静置 1 小时。

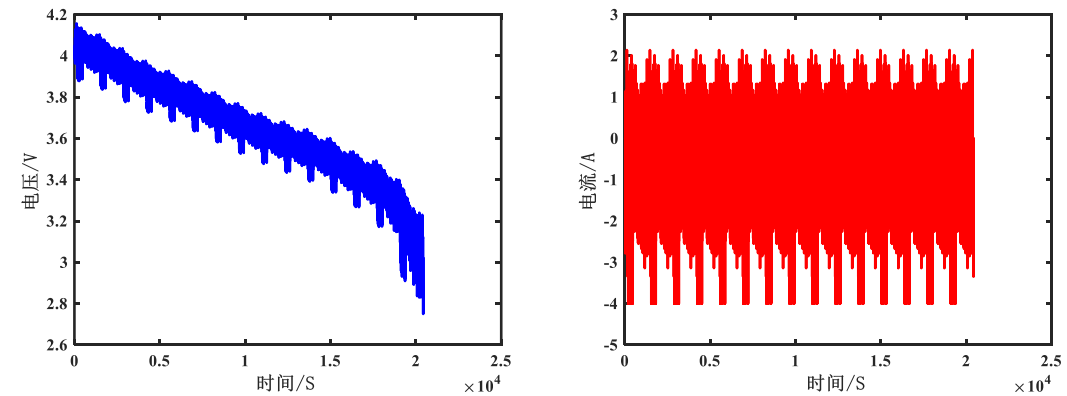
（3）设置 FUDS 动态工况，采样间隔 1s，对电池进行循环测试，当达到放电截止电压 2.75V 时结束测试，并静置 1 小时。

（4）在 25℃、40℃下设定恒温箱温度重复步骤(2)-(3)。

根据上述步骤，该工况在-10℃、25℃和 40℃下的电压电流测试数据如图 10 所示。

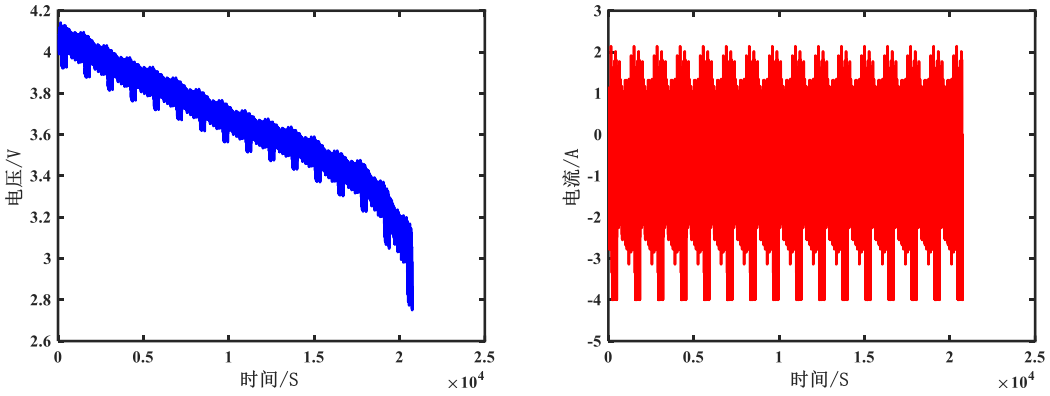


(a) -10℃



(b) 25℃

中国知网 https://www.cnki.net



(c) 40℃

图 10 FUDS 工况在不同温度下的电流电压曲线

Fig.10 Current and voltage curves of FUDS at different temperatures

2.3　本章小结

本章主要介绍了锂离子电池的构成、工作原理及其性能参数，利用锂离子电池测试平台对 NCR-18650GA 型三元锂电池进行充放电测试，分析了不同温度对锂离子电池放电容量和开路电压的影响，测试数据也将为后续的锂离子电池参数辨识以及 SOC 估计提供基础。

中国知网　https://www.cnki.net

中国知网 https://www.cnki.net

3　锂离子电池建模及参数辨识

选择合适的电池模型和准确的参数辨识方法是实现高效 SOC 估计的基础。常见的电池模型包括内阻模型、Thevenin 模型、PNGV 模型和二阶 RC 模型等，其中，二阶 RC 模型因其物理意义明确，模型复杂度和计算量适中，被广泛应用。常见的电池模型参数辨识方法分为离线参数辨识和在线参数辨识，采用离线辨识方法获得的参数估计值是不变的。考虑到锂离子电池在工作中的电流和电压是时刻变化的，研究人员提出了在线辨识方法，以此提高电池参数辨识的精度。本章基于二阶 RC 电路模型，研究离线辨识和在线辨识对模型精度的影响，采用灰狼优化算法离线参数辨识，采用 FFRLS 和 AFFRLS 在线参数辨识，在不同的工况下验证不同方法参数辨识的精度。

3.1　等效电路模型选择

锂离子电池的动态行为具有显著的非线性与时变特性，其内部多物理场耦合效应导致系统动力学行为高度复杂。为分析电池动态响应机制并实现高精度状态估计，构建适配的数学模型是理论研究和工程应用的基础。合适的数学模型不仅能够降低参数辨识的计算复杂度，还可显著提升 SOC 估计的精确性、鲁棒性及实时性。目前广泛应用的等效电路模型主要包括以下几类：

（1）内阻模型

内阻模型也被称为 Rint 模型，该模型通过将电池的行为简化为一个电压源与内阻的组合，在假设电池内阻与工作条件保持不变的情况下，能够简要描述电池在理想条件下的性能，这种模型适用于电池状态较为稳定时的分析。然而在电池充放电过程中，由于电池内部化学反应的复杂性，这种简化模型未能考虑到电池行为的动态特性。内阻模型的原理图如图 11 所示，图中 U_{oc} 表示开路电压，R 是电池内阻，U_L 为电池两端的输出电压，I 为充放电电流。

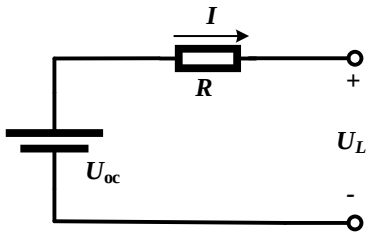


图 11 内阻模型

Fig.11 Internal resistance model

中国知网　https://www.cnki.net

（2）Thevenin 模型

在内阻模型的基础上，Thevenin 模型通过增加电容元件，进一步改进了电池的等效电路模型。该模型能够更好地描述电池内部的动态特性，从而提高了模型的准确性。虽然 Thevenin 模型比内阻模型更精细，但它也增加了计算的复杂度。其原理图如图 12 所示，U_{oc} 为电池的开路电压，R_0 为电池的欧姆内阻，R_1、C_1 分别表示电池的电阻和电容，U_L 为电池的输出电压，I 为充放电电流。

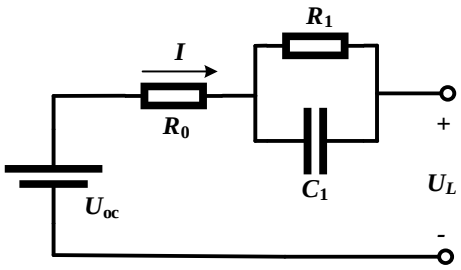


图 12 Thevenin 模型

Fig.12 Thevenin model

（3）PNGV 电路模型

PNGV 模型在 Thevenin 模型的基础上进一步发展，添加了额外的电容元件，用以更细致地模拟电池的动态特性。该模型能够在电池开路和充放电状态下，更准确地考虑电流对电池性能的影响，并能够捕捉电池在不同工作条件下的表现。虽然 PNGV 模型在精度上优于 Thevenin 模型，但它的复杂度也有所增加。原理图如图 13 所示，其中 U_{oc} 为电池的开路电压，R_0 为电池的欧姆内阻，R_1、C_1 分别为电池的电阻和电容，U_L 为电池的输出电压，I 为充放电电流。

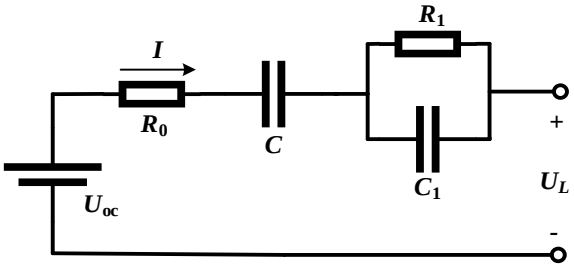


图 13 PNGV 模型

Fig.13 PNGV model

（4）二阶 RC 电路模型

二阶 RC 电路模型是一种更加复杂的电池等效电路模型，能够更精确地反映电池的动态响应。这一模型通过组合两个电阻和两个电容，形成一个二阶 RC 系统，

中国知网 https://www.cnki.net

从而能够更好地描述电池的电化学过程以及充放电时电池内部的动态行为。二阶 RC 模型适用于需要高精度电池建模的情况，尤其在电池 SOC 估算等应用中，能够显著提高准确性。原理图如图 14 所示，其中 U_{oc} 为电池的开路电压，R_0、R_1、R_2、C_1 和 C_2 为电池的电阻和电容，U_L 为电池的输出电压，I 为充放电电流。

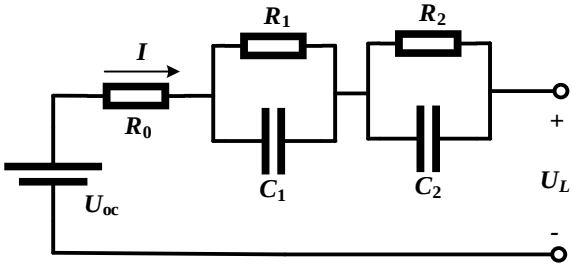


图 14 二阶 RC 电路模型

Fig.14 Second-order RC circuit model

锂电池 SOC 估算的精度与鲁棒性高度依赖于模型对动态特性的表征能力。研究表明，二阶 RC 电路模型通过引入双极化时间常数的设计，相较于内阻模型与 Thevenin 模型，能够更全面地描述电池在充放电过程中的非线性动态行为，尤其在高倍率充放电与多温工况下表现出显著的精度优势[78]。因此，本文选择二阶 RC 电路模型作为后续参数辨识与 SOC 估算的理论框架。

3.2　等效电路模型建立

基于图 14 所示的二阶 RC 等效电路模型，根据基尔霍夫电压定律（KVL）与电流定律（KCL），可推导出如下状态方程与输出方程。

状态方程：

$$\begin{aligned} I &= \frac{U_1}{R_1} + C_1 \frac{\mathrm{d}U_1}{dt} \\ I &= \frac{U_2}{R_2} + C_2 \frac{\mathrm{d}U_2}{dt} \end{aligned} \tag{3-1}$$

输出方程：

$$U_L = U_{OC}\left(SOC\right) - U_1 - U_2 - IR_0 \tag{3-2}$$

其中，U_1 与 U_2 分别为两个 RC 并联支路的极化电压，R_0 为欧姆内阻，$U_{oc}(SOC)$ 对应 SOC 开路电压 U_{oc} 的函数。

对式（3-1）进行微分求解，得到极化电压的解析表达式：

中国知网　https://www.cnki.net

$$\begin{cases} U_1(t) = U_1(0)e^{-T/\tau_1} + IR_1\left(1-e^{-T/\tau_1}\right) \\ U_2(t) = U_2(0)e^{-T/\tau_2} + IR_2\left(1-e^{-T/\tau_2}\right) \end{cases} \tag{3-3}$$

其中，T 为采样周期，τ_1与τ_2分别为 RC 并联支路的时间常数。对基于安时积分法表示的 SOC 进行离散化：

$$SOC_{(k)} = SOC_{(k-1)} - \frac{\eta T}{C_N} i_{(k-1)} \tag{3-4}$$

以电流 I 为输入、端电压 U_L 为输出，定义状态向量$x = [SOC_{(k)} \quad U_{1(k)} \quad U_{2(k)}]^T$，联立式（3-3）与（3-4），可构建基于二阶 RC 电路模型的离散化状态方程和输出方程：

$$\begin{bmatrix} SOC_{(k)} \\ U_{1(k)} \\ U_{2(k)} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & e^{-\frac{T}{\tau_1}} & 0 \\ 0 & 0 & e^{-\frac{T}{\tau_2}} \end{bmatrix} \begin{bmatrix} SOC_{k-1} \\ U_{1(k-1)} \\ U_{2(k-1)} \end{bmatrix} + \begin{bmatrix} -\frac{\eta T}{C_N} \\ R_1\left(1-e^{-\frac{T}{\tau_1}}\right) \\ R_2\left(1-e^{-\frac{T}{\tau_2}}\right) \end{bmatrix} I_{k-1} + w_k \tag{3-5}$$

$$U_{L(k)} = U_{oc}\left(SOC_{(k)}\right) - I_{(k)}R_0 - U_{1(k)} - U_{2(k)} + v_k \tag{3-6}$$

其中，w_k 为过程噪声向量，v_k 为测量噪声，表示模型不确定性与传感器误差。

3.3 电池模型离线参数辨识

3.3.1 OCV-SOC 曲线获取

在锂离子电池参数辨识之前，通常需要先获得准确的 OCV-SOC 拟合曲线。这里以 25℃环境温度下条件为例，对当前温度下锂离子电池的 OCV 曲线进行拟合。为了减小 OCV-SOC 拟合曲线和 OCV 测量值之间的误差，对不同阶数的 OCV-SOC 曲线拟合误差进行比较，并采用 R^2 为评价指标来评估不同阶数的拟合结果。图 15 为不同多项式拟合结果，表 2 为不同阶数多项式的确定系数 R^2。

中国知网 https://www.cnki.net

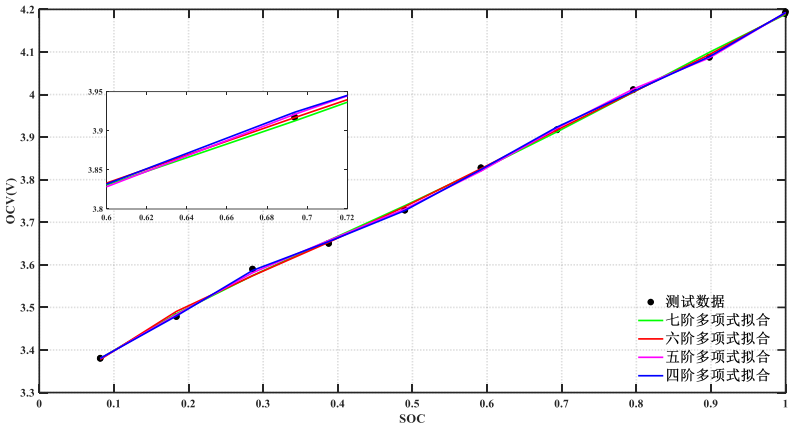


图 15 不同多项式拟合结果

Fig.15 Fitting results of different polynomials

表 2 不同阶数的 R^2 比较

Table 2 R^2 comparison of different orders

拟合阶数	R^2
4 阶	0.9990
5 阶	0.9992
6 阶	0.9996
7 阶	0.9998

从表中可以看出七阶多项式的 R^2 最大，拟合效果最好。因此，本章采用七阶多项式来拟合 OCV-SOC 曲线，拟合公式如下：

$$\begin{aligned} U_{ocv} = &-93.81SOC^7 + 383.46SOC^6 - 630.75SOC^5 + 532.79SOC^4 \\ &-243.96SOC^3 + 58.53SOC^2 - 5.61SOC + 3.56 \end{aligned} \tag{3-7}$$

3.3.2　基于灰狼算法的离线参数辨识

灰狼算法[79]是一种智能优化算法，相较于粒子群算法、遗传算法具有寻优能力强、需要调整的参数少，收敛快等特点。采用灰狼优化算法进行锂离子电池离线参数辨识主要有以下两个步骤。

步骤一：辨识 R_0。采用 HPPC 实验数据进行锂离子电池离线参数辨识，离线参数辨识方法通过拟合端电压曲线来获得模型参数。图 16 为锂离子电池在 25℃下的一段脉冲放电曲线，可由电池放电开始到结束时的端电压变化特征计算 R_0。

$$R_0 = \frac{|U(t_b) - U(t_a)| + |U(t_d) - U(t_c)|}{2|I|} \tag{3-8}$$

式中，U 为各点的端电压，I 为放电电流。取 SOC 大于 20%脉冲放电阶段的

中国知网　https://www.cnki.net

平均值作为 R_0 的计算结果。

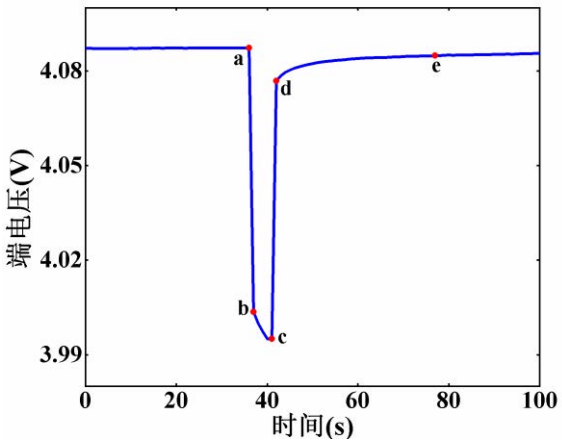


图 16 HPPC 脉冲电压曲线

Fig.16 HPPC impulse voltage curve

步骤二：辨识 R_1、R_2、C_1、C_2

本节采用灰狼优化算法辨识锂离子电池的 R_1、R_2、C_1、C_2。设计灰狼算法时，把狼群中每一头灰狼当作种群的一个潜在解，为了刻画灰狼的社会等级结构，将 α 狼的位置视为最优解，β 狼和 γ 狼的位置分别作为优解和次优解，而 δ 狼的位置作为其余的候选解。在灰狼算法中，由 a，β 和 γ 引导搜索，δ 狼跟随前面三种狼。灰狼优化算法的实现原理如下：

捕猎过程中，灰狼群体首先包围猎物，数学模型可表示为：

$$\begin{aligned}\vec{D} &= \left|\vec{C}\times\vec{X_P}(t)-\vec{X}(t)\right| \\ \vec{X}(t+1) &= \vec{X_P}(t)-\vec{A}\times\vec{D}\end{aligned} \tag{3-9}$$

式中，t 代表当前迭代的次数，$Xp(t)$为第t次迭代中猎物的位置向量，$X(t)$为第t次迭代中灰狼的位置向量。A和C为协同向量，计算方式为：

$$\begin{aligned}\vec{A} &= 2\vec{a}\times\vec{r_1}-\vec{a} \\ \vec{C} &= 2\vec{r_2}\end{aligned} \tag{3-10}$$

式中，a中的分量在迭代过程中从 2 到 0 线性递减，r_1 和 r_2 为[0,1]中的随机向量。随后，灰狼开始狩猎，按照式(3-11)~(3-12)更新位置：

$$\begin{cases} D_a = \left|C_1\cdot X_a - X(t)\right| \\ D_\beta = \left|C_2\cdot X_\beta - X(t)\right| \\ D_\gamma = \left|C_3\cdot X_\gamma - X(t)\right| \\ X_1 = X_a - A_1\cdot D_a \\ X_2 = X_\beta - A_2\cdot D_\beta \\ X_3 = X_\gamma - A_3\cdot D_\gamma \end{cases} \tag{3-11}$$

中国知网 https://www.cnki.net

$$X(t+1)=\frac{X_1+X_2+X_3}{3} \tag{3-12}$$

式中，C_1、C_2、C_3 为随机向量，D_α、D_β、D_γ 代表其他狼与α、β、γ 狼之间的距离，X_α、X_β、X_γ 代表当前迭代中α、β、γ 狼的位置，X_1、X_2、X_3 代表α、β、γ 狼当前迭代更新后的最新位置。在灰狼算法中，通过 a 值逐渐线性减少，使得 A 的波动范围也随之线性减少，从而模拟狼群逼近猎物的行为，流程图如图 17 所示。适应度函数为实测电压与模型输出电压之间的均方根误差，其计算方式如下：

$$RMSE=\sqrt{\frac{1}{m}\sum_{k=1}^{m}(U_{1,k}-U_{2,k})^2} \tag{3-13}$$

式中，m 为数据长度，$U_{1,k}$ 为实测电压值，$U_{2,k}$ 为模型仿真电压值，k 为当前的时刻。

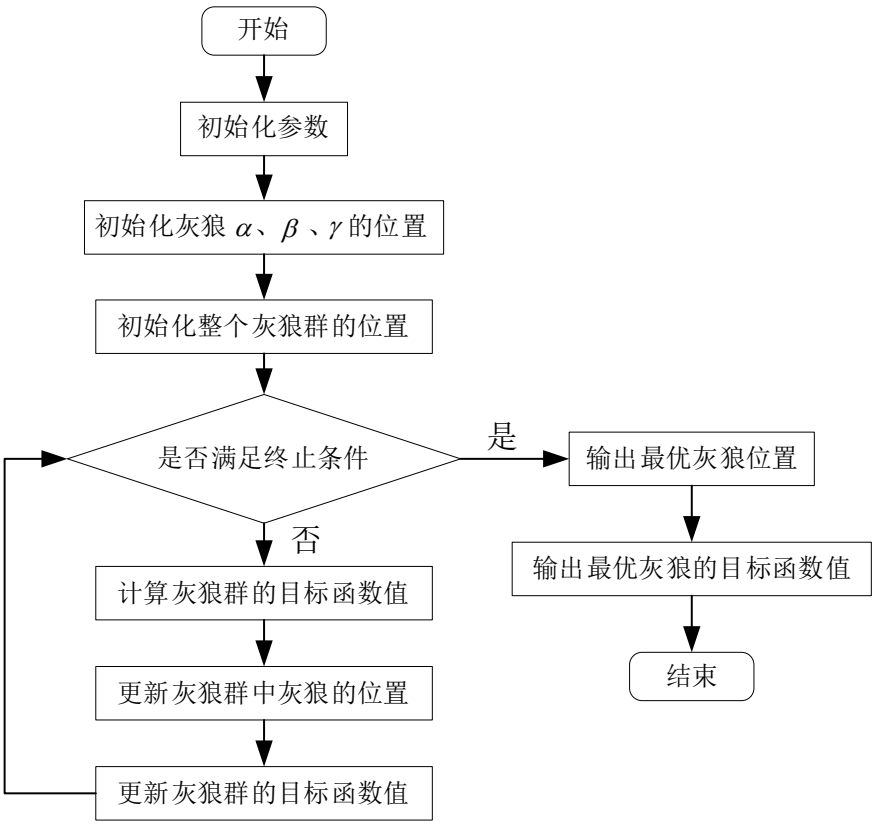


图 17 灰狼算法流程图

Fig.17 Flow chart of the gray wolf optimization algorithm

采用灰狼算法在不同温度下的 HPPC 工况的辨识结果如图 18-20 所示，从图中可以看到，离线辨识方法下的端电压值基本符合真实值的变化趋势，仅仅只在放电初期和末期误差最大。表 3 给出了灰狼算法离线参数辨识具体的误差，可以看出灰狼算法在-10℃的低温下参数辨识误差最大，要高于 25℃和 40℃。在不同温度的

中国知网　https://www.cnki.net

HPPC 工况下，灰狼算法参数辨识的 RMSE 控制在 11.3mv 以内，符合参数辨识的精度要求。然而，离线参数辨识通常是在电池不处于工作状态下进行的。而在实际应用中，电池的行为会受到充放电过程、环境温度、负载波动等因素的影响，离线辨识无法准确捕捉这些动态过程中的电池特性。因此，在一些复杂的工况中，可能会出现较大的偏差，例如图 21-22 所示，灰狼算法在 25℃条件下的 BJDST 工况和 FUDS 工况参数辨识误差明显高于 HPPC 工况参数辨识误差。以 BJDST 工况为例，灰狼算法参数辨识的 MAE 和 RMSE 分别为 37.8mV 和 69.9mV，表明动态工况下的辨识精度相对静态工况下较差。因此，离线参数辨识虽然在一定条件下是有用的，但是在面对一些对实时性要求高的工况时，由于无法及时响应动态变化，使其应用受到显著限制。

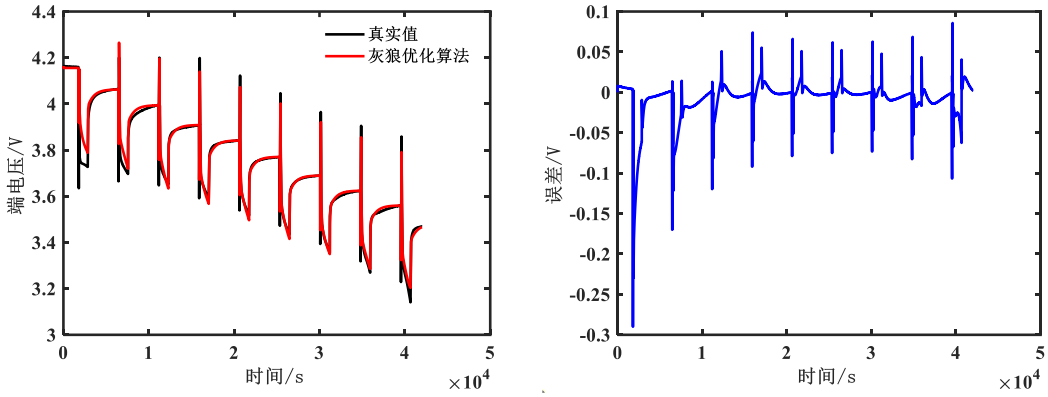


图 18 -10℃ HPPC 工况参数辨识结果

Fig.18 Identification results of -10°C HPPC operating conditions

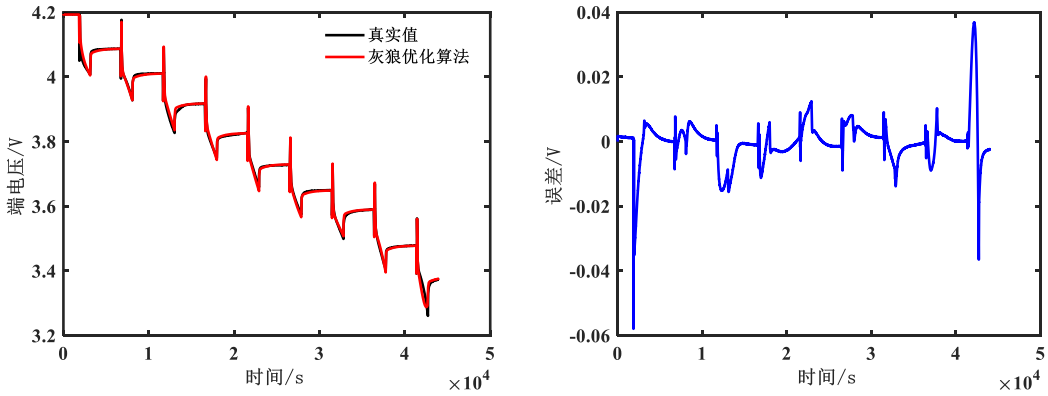


图 19 25℃ HPPC 工况参数辨识结果

Fig.19 Identification results of parameters under 25°C HPPC condition

中国知网 https://www.cnki.net

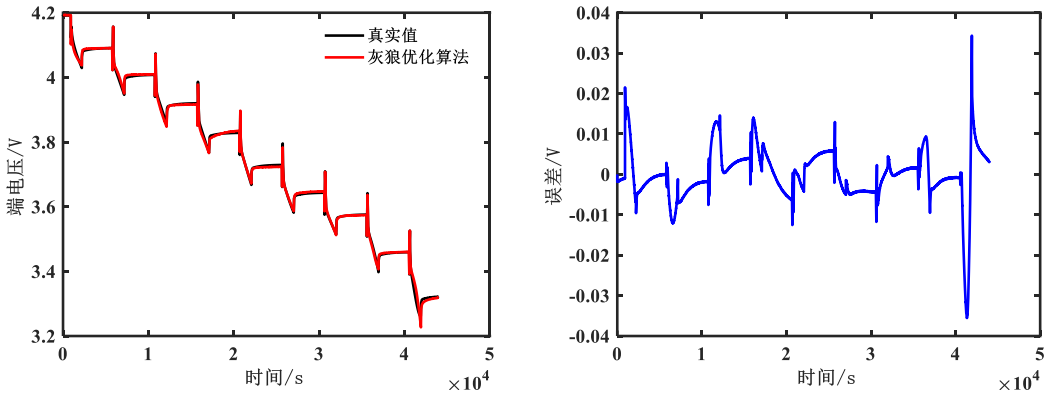


图 20 40℃ HPPC 工况参数辨识结果

Fig.20 Identification results of parameters under 40°C HPPC operating conditions

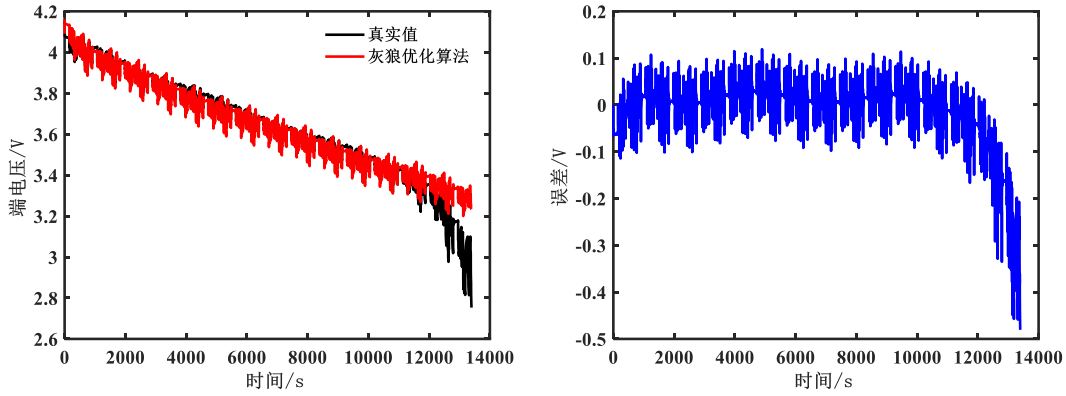


图 21 25℃ BJDST 工况参数辨识结果

Fig.21 Identification results of parameters under 25°C BJDST operating conditions

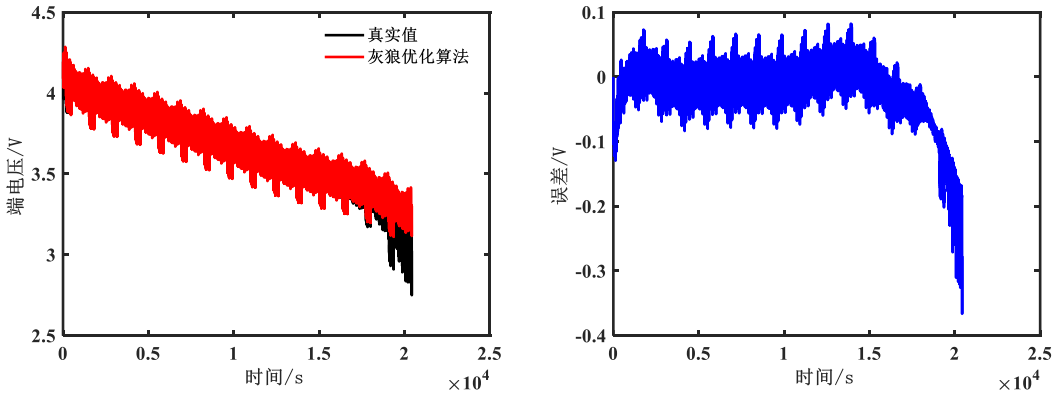


图 22 25℃ FUDS 工况参数辨识结果

Fig.22 Identification results of parameters under 25°C FUDS operating conditions

中国知网　https://www.cnki.net

表 3 不同温度下三个工况辨识误差

Table 3 Identification errors of three working conditions at different temperatures

工况	温度	MAE(mV)	RMSE(mV)
HPPC	-10℃	6.6	11.3
HPPC	25℃	3.9	6.7
HPPC	40℃	4.3	6.4
BJDST	25℃	37.8	69.9
FUDS	25℃	33.0	53.0

3.4 电池模型在线参数辨识

与离线参数辨识不同，在线辨识无需要提前获取电池的输入、输出数据，能够实时跟踪电池在动态过程中的参数变化，进而使得模型能够更准确地描述电池的实际行为。

3.4.1 含遗忘因子的递推最小二乘法

递推最小二乘法（RLS）是一种常用的在线参数辨识方法，它通过最小化误差的平方和来更新系统参数。RLS 算法的核心思想是利用输入输出数据对系统参数进行递推估计，并在每次迭代中修正模型，以提高参数辨识的准确性[80]。具体而言，RLS 算法在每次迭代时通过以下公式对参数进行更新。

参数更新：

$$\theta_k = \theta_{k-1} + K_k\left[y_k - \phi_k^T\theta_{k-1}\right] \tag{3-14}$$

增益矩阵更新：

$$K_k = \frac{P_{k-1}\phi_k}{1+\phi_k^T P_{k-1}\phi_k} \tag{3-15}$$

协方差矩阵更新：

$$P_k = P_{k-1} - \frac{P_{k-1}\phi_k\phi_k^T P_{k-1}}{1+\phi_k^T P_{k-1}\phi_k} \tag{3-16}$$

其中，θ_k 表示参数矩阵，K_k 为增益矩阵，ϕ_k 测量数据矩阵。

通过递推最小二乘法的推导可知，该算法能够动态修正参数估计值，逐步逼近真实参数。然而，随着协方差矩阵的逐步积累，可能会面临“数据饱和”问题，即历史数据过多会影响新数据对参数更新的贡献，导致模型对历史数据的依赖逐渐增强。当系统特性发生快速变化时，这种不均衡的权重分配可能会导致算法无法及时

中国知网 https://www.cnki.net

响应动态变化，进而影响参数估计的精度，甚至导致更新效果减弱。

针对这一问题，含遗忘因子的递推最小二乘法（Forgetting Factor Recursive Least Squares, FFRLS）应运而生。该算法通过引入遗忘因子对历史数据的权重进行动态调整，使得最新数据占据更高比重，从而提升算法对动态变化系统的适应能力[81]。在 FFRLS 算法中，遗忘因子 λ 通常取值在 0.9-1 之间。当 λ 取值为 1 时，FFRLS 算法退化为经典的 RLS 算法。结合二阶 RC 等效电路模型，将电池视为一个动态系统，其中输入变量电压 $U_L(s)$，电流 $I(s)$。根据电路特性，该模型在频域下的传递函数 $G(s)$可以表示为：

$$G(s)=\frac{U_L(s)-U_{oc}(s)}{I(s)}=-\left(R_0+\frac{R_1}{1+R_1C_1s}+\frac{R_2}{1+R_2C_2s}\right) \tag{3-17}$$

令$E=U_L-U_{oc}$，通过双线性变换法代入$s=2(1-z^{-1})/T(1+z^{-1})$到传递函数 $G(s)$进行离散化可得：

$$G(z^{-1})=\frac{E(k)}{I(k)}=\frac{\theta_3+\theta_4z^{-1}+\theta_5z^{-2}}{1-\theta_1z^{-1}-\theta_2z^{-2}} \tag{3-18}$$

对式（3-18）化简，得到基于二阶 RC 电路模型的递推方程式：

$$E(k)=\theta_1E(k-1)+\theta_2E(k-2)+\theta_3I(k)+\theta_4I(k-1)+\theta_5I(k-2) \tag{3-19}$$

在式（3-19）中，令：

$$\begin{cases} y(k)=E(k) \\ \theta(k)=\begin{bmatrix}\theta_1 & \theta_2 & \theta_3 & \theta_4 & \theta_5\end{bmatrix}^T \\ \phi(k)=\begin{bmatrix}E(k-1) & E(k-2) & I(k) & I(k-1) & I(k-2)\end{bmatrix}^T \end{cases} \tag{3-20}$$

通过式（3-20）可得二阶 RC 电路模型输出向量的矩阵形式：

$$y(k)=\phi(k)^T\theta(k) \tag{3-21}$$

其中，参数矩阵中的θ_1、θ_2、θ_3、θ_4、θ_5由式（3-22）表示：

中国知网　https://www.cnki.net

$$\begin{cases}\theta_1=\dfrac{8b-2T^2}{4b+2cT+T^2}\\ \theta_2=\dfrac{4cT}{4b+2cT+T^2}-1\\ \theta_3=\dfrac{4ab+2eT+dT^2}{4b+2cT+T^2}\\ \theta_4=\dfrac{8ab-2dT^2}{4b+2cT+T^2}\\ \theta_5=\dfrac{4ab-2eT+dT^2}{4b+2cT+T^2}\end{cases}\tag{3-22}$$

其中，$a=R_0$，$b=\tau_1\cdot\tau_2$，$c=\tau_1+\tau_2$，$d=R_0+R_1+R_2$和$e=R_0(\tau_1+\tau_2)+R_1\tau_2+R_2\tau_1$均为中间变量。令$\tau_1=\left(c+\sqrt{c^2-4b}\right)/2$，$\tau_2=\left(c-\sqrt{c^2-4b}\right)/2$，通过中间变量求解即可得到二阶 RC 电路模型参数：

$$\begin{cases}R_0=a\\ R_1=\left[\tau_1\left(d-a\right)+ac-e\right]/\left(\tau_1-\tau_2\right)\\ R_2=d-a-R_1\\ C_1=\tau_1/R_1\\ C_2=\tau_2/R_2\end{cases}\tag{3-23}$$

对上式反解，即可求出中间变量a、b、c、d、e：

$$\begin{cases}a=\dfrac{\theta_4-\theta_3-\theta_5}{1+\theta_1-\theta_2}\\ b=\dfrac{T^2\left(1+\theta_1-\theta_2\right)}{4\left(1-\theta_1-\theta_2\right)}\\ c=\dfrac{T\left(1+\theta_2\right)}{1-\theta_1-\theta_2}\\ d=\dfrac{-\theta_3-\theta_4-\theta_5}{1-\theta_1-\theta_2}\\ e=\dfrac{T\left(\theta_5-\theta_3\right)}{1-\theta_1-\theta_2}\end{cases}\tag{3-24}$$

联立式（3-22）、（3-23）和（3-24）即可实现二阶 RC 电路模型R_0、R_1、R_2、C_1、C_2参数的求解。FFRLS 算法步骤如下：

Step1：初始化ϕ_0、P_0、θ_0。

Step2：计算当前时刻引入固定遗忘因子λ的增益矩阵K_k。

中国知网 https://www.cnki.net

$$K_k = \frac{P_{k-1}\phi_k}{\lambda + \phi_k^T P_{k-1}\phi_k} \tag{3-25}$$

Step3：更新待估参数θ_k。

$$\theta_k = \theta_{k-1} + K_k\left[y_k - \phi_k^T\theta_{k-1}\right] \tag{3-26}$$

Step4：更新协方差矩阵P_k。

$$P_k = \frac{1}{\lambda}\left[I - K_k\phi_k^T\right]P_{k-1} \tag{3-27}$$

Step5：下一时刻的辨识过程返回到步骤（2）进行循环，直至 FFRLS 算法所有时刻辨识结束，参数辨识流程图如图 23 所示。

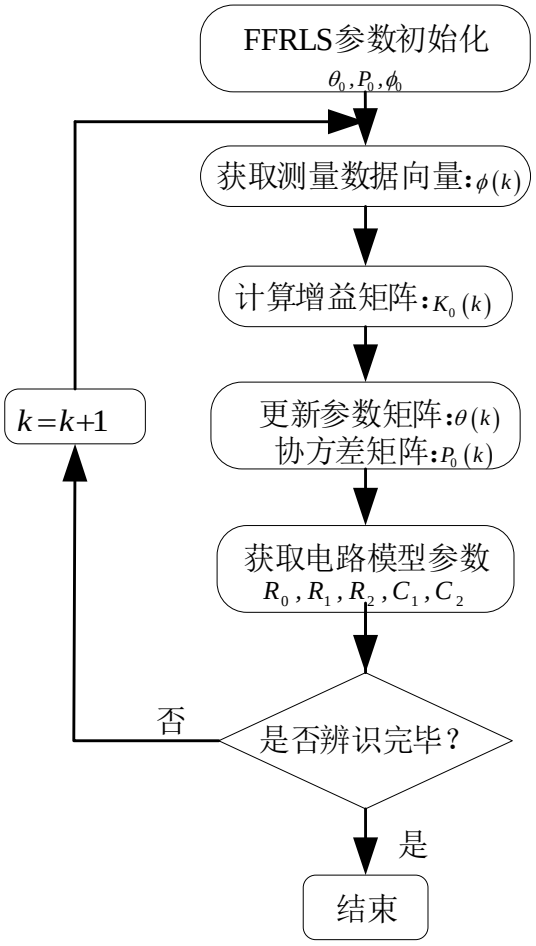


图 23 FFRLS 算法流程图

Fig.23 Flow chart of the FFRLS algorithm

中国知网　https://www.cnki.net

3.4.2 自适应遗忘因子的递推最小二乘法

在 FFRLS 算法中，遗忘因子λ的选择对算法的性能至关重要。当遗忘因子较大时，算法对系统动态变化的响应较慢，而当遗忘因子较小时，系统容易受到噪声干扰，降低了辨识的鲁棒性。由于遗忘因子的固定性，这就使得在实际运行中，遗忘因子 λ 的选取难以同时兼顾算法的快速性与稳定性。

为此，在 FFRLS 算法的基础上，引入了基于自适应遗忘因子的递推最小二乘（AFFRLS）算法，它通过引入自适应遗忘因子公式，使得遗忘因子λ能够根据端电压预测误差自适应地变化，从而提升了算法的稳定性和精度[82]。其公式如下：

$$\lambda_k = \lambda_{\min} + (1-\lambda_{\min}) \cdot L^{\varepsilon_k} \tag{3-28}$$

其中：

$$\varepsilon_k = round\left(\frac{e_k}{e_{base}}\right)^2 \tag{3-29}$$

在上述公式中，λ_{min}是遗忘因子取值范围内的最小值，用于确保辨识的稳定性；参数 L 是灵敏系数，其作用是能够改变遗忘因子λ值对预测误差的敏感程度，取值通常在 0 到 1 之间。$round(\cdot)$表示取整函数，e_k是模型预测误差，e_{base}是允许误差。当预测误差大于允许误差时，λ值趋于λ_{min}；相应的当小于允许误差时，遗忘因子λ的值接近于 1，以维持参数辨识的稳定性。

基于上述自适应遗忘因子设计，AFFRLS 算法的参数辨识步骤如下：

Step1：初始化ϕ_0、P_0、θ_0、λ_{min}。

Step2：计算当前时刻引入自适应遗忘因子λ_k的增益矩阵K_k。

$$K_k = \frac{P_{k-1}\phi_k}{\lambda_{k-1} + \phi_{k-1}{}^T P_{k-1}\phi_{k-1}} \tag{3-30}$$

Step3：更新待估参数θ_k。

$$\theta_k = \theta_{k-1} + K_k\left[y_k - \phi_k^T\theta_{k-1}\right] \tag{3-31}$$

Step4：更新协方差矩阵P_k。

$$P_k = \frac{1}{\lambda_{k-1}}\left[I - K_k\phi_k^T\right]P_{k-1} \tag{3-32}$$

Step5：更新自适应遗忘因子λ_k。

$$\lambda_k = \lambda_{\min} + (1-\lambda_{\min}) \cdot L^{\varepsilon_{k-1}} \tag{3-33}$$

Step6：下一时刻的辨识过程返回到步骤（2）进行循环，直至 AFFRLS 算法所有时刻辨识结束，参数辨识流程图如图 24 所示。

中国知网 https://www.cnki.net

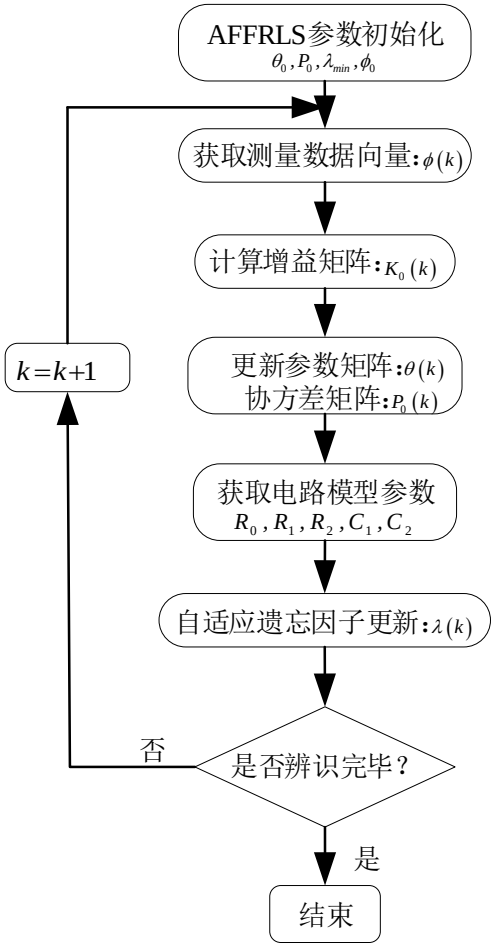


图 24 AFFRLS 算法流程图

Fig.24 Flow chart of the AFFRLS algorithm

3.4.3　不同工况下对比分析

在上一小节中分别对两种在线辨识算法的原理及实现过程进行了阐述。为了分析比较 FFRLS 算法和 AFFRLS 算法参数辨识结果的表现差异，本节将对比这两种算法在相同工况不同温度下的端电压估计效果，为实际应用中算法的选择提供科学依据。

图 25 为 AFFRLS 算法在 25℃下的 BJDST 工况参数辨识结果，从图中可以看出欧姆内阻、极化内阻和极化电容实时跟随整个放电过程，R_0、R_1、R_2 的值在放电末期变化剧烈，这主要是由于电池在放电末期电压波动较大所导致的，R_0 值的变化末端接近于 0.08Ω。

中国知网　https://www.cnki.net

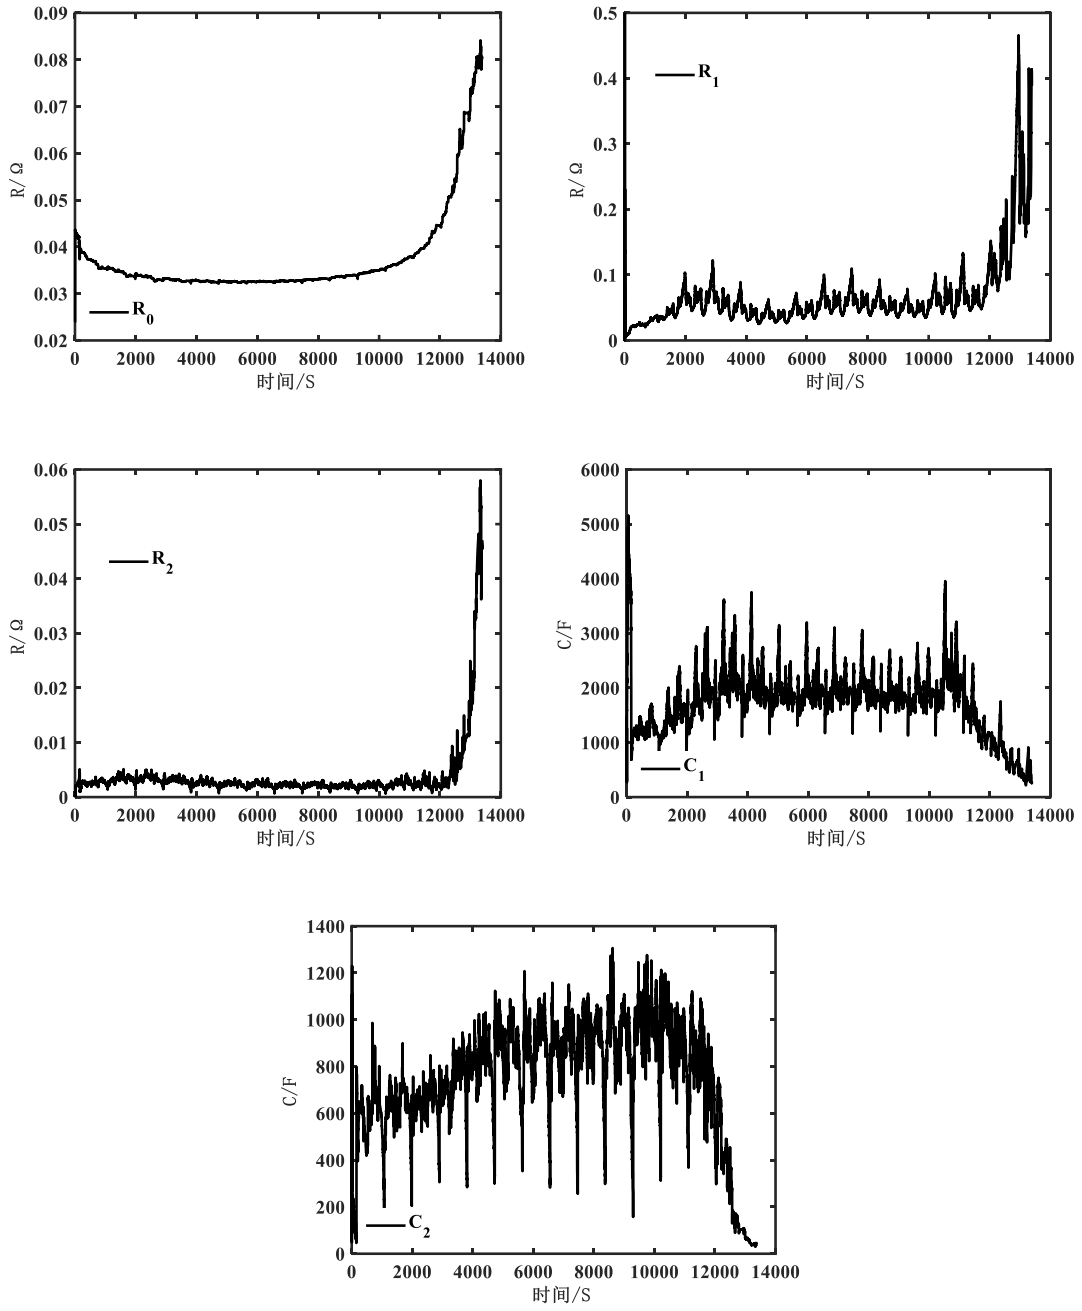


图 25 AFFRLS 的在线辨识结果

Fig.25 Online identification results of AFFRLS

图 26-28 分别展示了两种算法在 BJDST 工况不同温度下的辨识电压结果图和误差对比图，从图中可以明显观察到以下几点：

（1）随着温度的升高，两种算法的辨识精度均在常温条件下达到最高，而在低温环境下，辨识误差呈现较大的波动，表现出的稳定性最差。

（2）在相同温度条件下，AFFRLS 算法的辨识准确性普遍优于 FFRLS 算法，即在两种算法中，AFFRLS 算法的辨识误差较小，更接近真实端电压。

中国知网 https://www.cnki.net

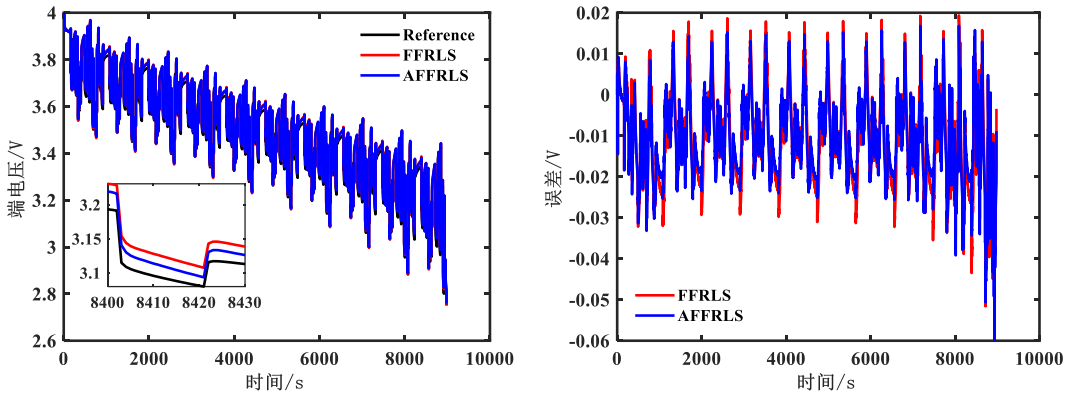


图 26 -10℃下 BJDST 工况参数辨识结果

Fig.26 Identification results of parameters under -10°C BJDST operating conditions

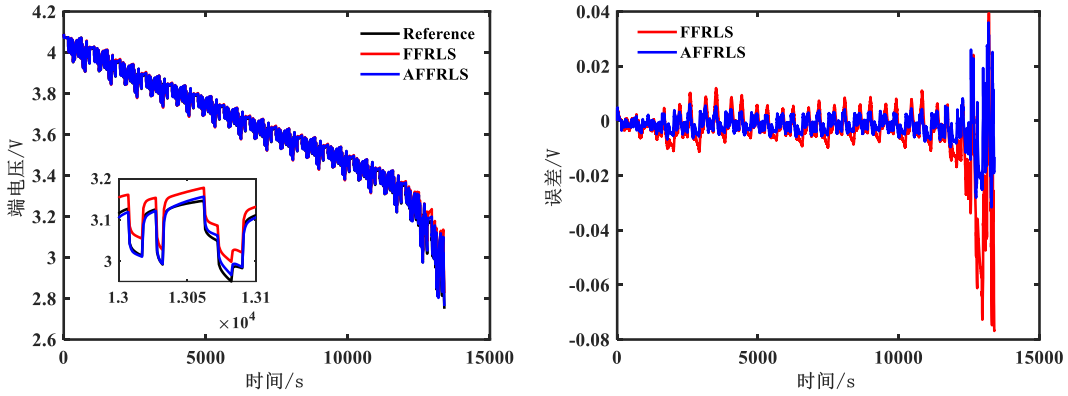


图 27 25℃下 BJDST 工况参数辨识结果

Fig.27 Identification results of parameters under 25°C BJDST operating conditions

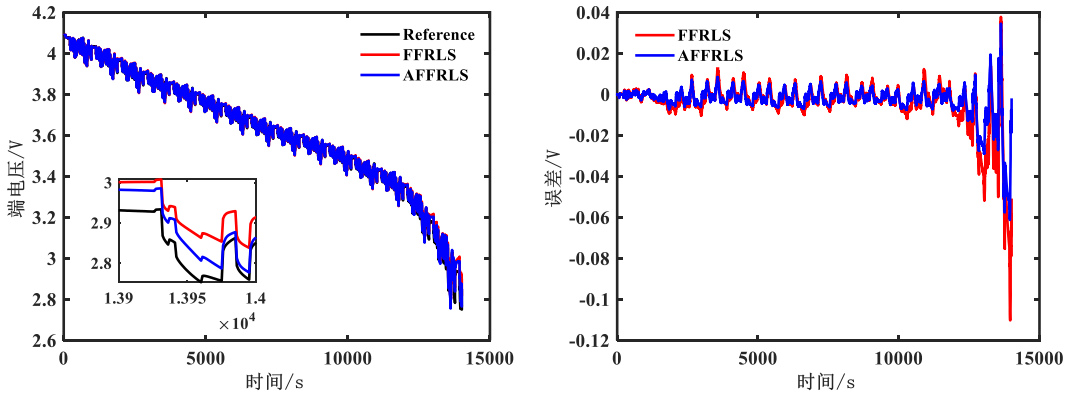


图 28 40℃下 BJDST 工况参数辨识结果

Fig.28 Identification results of parameters under 40°C BJDST operating conditions

为了量化两种算法的表现差异，表 4 列出了在 BJDST 工况下，两种算法在-10°C、25°C 和 40°C 温度下的最大误差、MAE 和 RMSE。

中国知网　https://www.cnki.net

表 4 BJDST 工况下两种算法在-10°C、25°C 和 40°C 误差结果

Table 4 Error results of the two algorithms at -10°C, 25°C and 40°C under BJDST conditions

算法	温度	Max(mV)	MAE(mV)	RMSE(mV)
FFRLS	-10	54.5	13	15.4
	25	78.5	5.6	9.3
	40	109.2	5.4	10.3
AFFRLS	-10	59.8	12.1	14.4
	25	38.5	3.2	4.9
	40	61.3	4.6	8.7

从表中数据可以看出，FFRLS 算法在-10°C 时的误差最大，MAE 为 13mV，RMSE 为 15.4mV，这表明固定的遗忘因子难以适应低温下参数快速变化的非线性特性，导致误差积累。相比之下，通过自适应遗忘因子的引入，AFFRLS 的 MAE 和 RMSE 较 FFRLS 算法分别降低 6.9%和 6.5%。在 25°C 时，两种算法的误差均有显著降低，但 AFFRLS 算法仍保持了更低的误差，最大电压误差为 38.5mV，MAE 为 3.2mV，RMSE 为 4.9mV，相较于 FFRLS 算法表现更优。在 40°C 时，两个算法的误差出现回升，但 AFFRLS 算法的表现依然要优于 FFRLS，其最大电压误差控制在 61.3mV，较 FFRLS 降低 43.8%。

图 29-31 分别展示了两种算法在 FUDS 工况不同温度下的辨识电压结果图和误差对比图，从图中同样可以明显观察到以下几点：

（1）随着温度的升高，两种算法的辨识精度均在高温条件下达到最高，而在低温环境下，辨识误差呈现较大的波动，表现出的稳定性最差。

（2）在相同温度条件下，AFFRLS 算法的辨识准确性同样也普遍优于 FFRLS 算法。

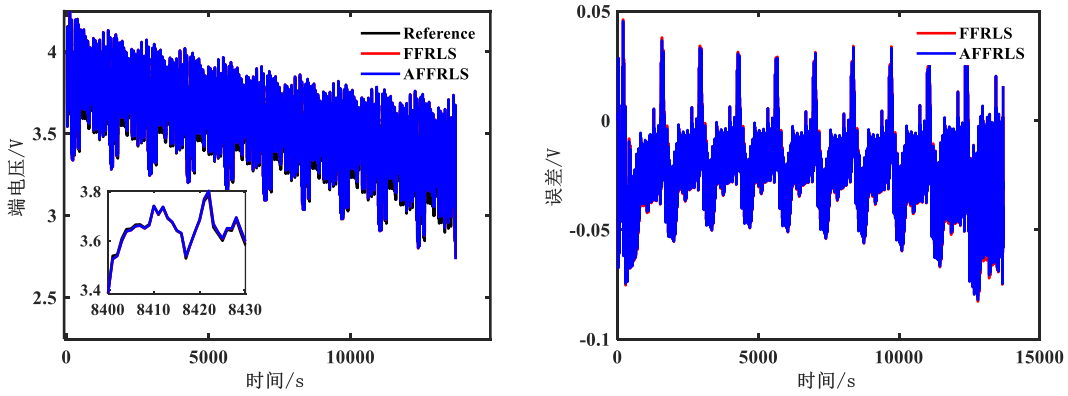


图 29 -10°C下 FUDS 工况参数辨识结果

Fig.29 Identification results of parameters under -10°C FUDS operating conditions

中国知网 https://www.cnki.net

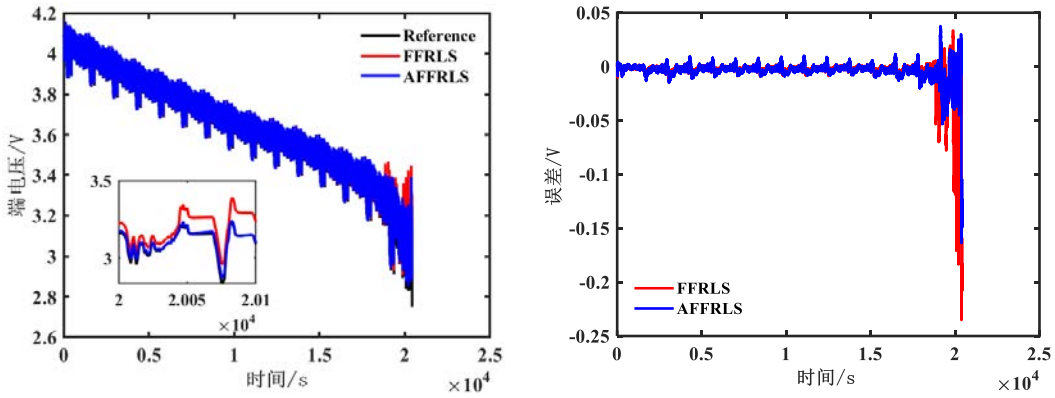


图 30 25°C下 FUDS 工况参数辨识结果

Fig.30 Identification results of parameters under 25°C FUDS operating conditions

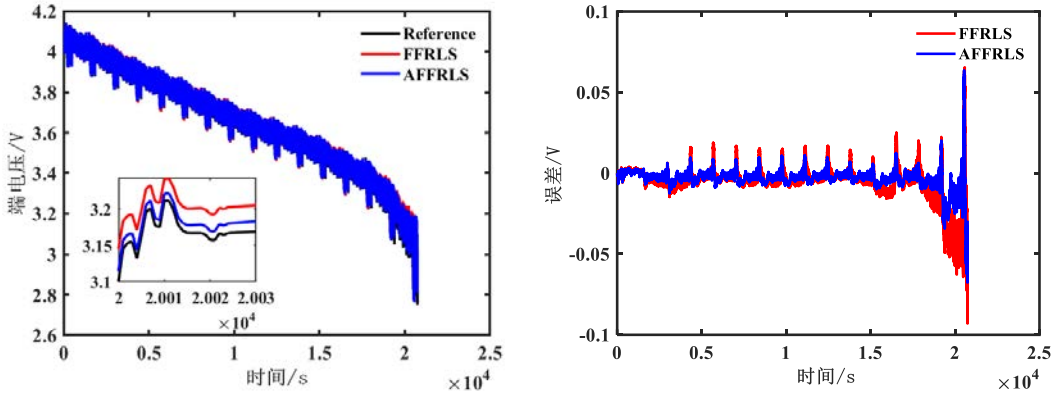


图 31 40°C下 FUDS 工况参数辨识结果

Fig.31 Identification results of parameters under 40°C FUDS operating conditions

为了量化两种算法的表现差异，表 5 列出了 FUDS 工况下，两种算法在-10°C、25°C 和 40°C 温度下的最大误差、MAE 和 RMSE。

表 5 FUDS 工况下两种算法在-10°C、25°C 和 40°C 误差结果

Table 5 Error results of the two algorithms at -10°C, 25°C and 40°C under FUDS conditions

算法	温度	Max(mV)	MAE(mV)	RMSE(mV)
FFRLS	-10	82.8	24.8	28.3
	25	235.2	6.4	19.3
	40	72.9	4.6	7.4
AFFRLS	-10	82	24.6	28.2
	25	163.7	4.5	9.2
	40	67.7	4.2	6.8

从表中的数据可以看出，在-10°C 时 FFRLS 算法和 AFFRLS 算法的 RMSE 分别为 82.8mV 和 82mV，表现非常接近，但 FFRLS 算法的均值误差和均方根误差略

中国知网　https://www.cnki.net

大，表明其表现稍逊色。在 25°C 时，AFFRLS 算法的均值误差和均方根误差显著降低，表明其在常温条件下的表现更为稳定。到了 40°C 时，FFRLS 算法的误差下降，最大误差为 72.9 mV，但 AFFRLS 算法仍然表现出更低的误差，并且均值误差和均方根误差值更低，显示出更好的适用性。

根据以上分析，在 BJDST 工况和 FUDS 工况下，AFFRLS 算法在不同温度下的误差表现始终显著优于 FFRLS 算法。因此，在实际复杂环境中，更适用于采用 AFFRLS 算法完成锂电池模型参数的辨识工作。

3.5 本章小结

本章首先介绍了几种常见的电池模型，分析了它们的优缺点，最终选择了模型结构复杂程度、精度都比较适中的二阶 RC 等效电路模型。分析比较了电池模型的离线参数辨识与在线参数辨识，并得出了相关结论。发现在比较简单的工况中，灰狼算法离线参数辨识表现出了较高的精度，但是在其他复杂的动态工况中，辨识精度显著降低；对比分析了 FFRLS 和 AFFRLS 两种在线参数辨识方法，并在多温度多工况下对两种方法辨识结果的最大误差、平均误差和均方根误差进行了分析，结果显示 AFFRLS 算法辨识的精度要高于 FFRLS 算法。因此，本文选择精度更高的 AFFRLS 在线参数辨识算法为后续 SOC 估计提供准确的电池模型参数。

中国知网 https://www.cnki.net

4　锂离子电池 SOC 估计

准确估算锂离子电池 SOC 是电池管理系统的核心任务之一。由于锂离子电池固有的动态非线性特性，加之实际运行中面临的复杂工况以及时变噪声干扰等因素的影响，导致传统 SOC 估计算法的应用面临着严峻挑战。针对上述问题，本章在自适应平方根容积卡尔曼算法的基础上，通过与多新息机制的结合，提出多新息自适应平方根容积卡尔曼滤波（MIASRCKF）算法，并在不同环境温度下，基于 BJDST 与 FUDS 动态工况分析验证 MIASRCKF 在复杂环境中的适用性，为锂离子电池 SOC 估计提供理论方法和技术支撑。

4.1　卡尔曼滤波算法及变体

卡尔曼滤波（Kalman Filter，KF）由 R.E. Kalman 于 1960 年提出的，是一种基于最小均方误差准则的线性递归状态估计算法。它利用上一时刻的状态估计和当前时刻的观测值，来获得当前状态的最优估计。KF 的状态方程和观测方程分别为：

$$\begin{cases} x_{k+1} = Ax_k + Bu_k + w_k \\ y_k = Cx_k + Du_k + v_k \end{cases} \tag{4-1}$$

其中，x_k 是系统的状态变量，y_k 是系统的观测量，u_k 是系统的输入量，w_k 和 v_k 分别是系统的过程噪声和测量噪声，且假设两者相互独立并服从高斯分布。

KF 算法主要步骤包括以下两部分：

预测阶段：利用上一时刻的状态，预测当前时刻的状态及其协方差。

修正阶段：结合当前观测值对预测结果进行修正，提高估计精度。

然而，由于 KF 假设系统为线性且噪声服从高斯分布，在实际应用中，大多数系统具有非线性特征，这使得 KF 在非线性系统中的适用性受限。为此，R.S. Bucy 提出了扩展卡尔曼滤波（Extended Kalman Filter，EKF），用于处理非线性系统。

4.1.1　EKF 算法的原理

EKF 的核心思想是通过一阶泰勒展开将非线性系统局部线性化，继而在局部线性模型下应用 KF 的预测和更新框架[83]。非线性离散系统的状态方程和观测方程为：

$$\begin{cases} x_{k+1} = f\left(x_k, u_k\right) + w_k \\ y_k = g\left(x_k, u_k\right) + v_k \end{cases} \tag{4-2}$$

其中，$f(\cdot)$为非线性系统的状态转移函数，$g(\cdot)$为非线性系统的观测函数，w_k

中国知网　https://www.cnki.net

和 v_k 分别为系统的过程噪声和测量噪声。

为了将上述非线性系统线性化，EKF 对 $f(\cdot)$和 $g(\cdot)$进行一阶泰勒展开，得到线性近似模型：

$$\begin{cases} A_k = \dfrac{\partial f\left(x_k, u_k\right)}{\partial x_k}\Big|_{\left(x_k, u_k\right)} \\ B_k = \dfrac{\partial f\left(x_k, u_k\right)}{\partial u_k}\Big|_{\left(x_k, u_k\right)} \\ C_k = \dfrac{\partial g\left(x_k, u_k\right)}{\partial u_k}\Big|_{\left(x_k, u_k\right)} \\ D_k = \dfrac{\partial g\left(x_k, u_k\right)}{\partial u_k}\Big|_{\left(x_k, u_k\right)} \end{cases} \tag{4-3}$$

此时，系统的线性化状态方程为：

$$\begin{cases} x_{k+1} \approx A_k x_k + B_k u_k + w_k \\ y_k \approx C_k x_k + D_k u_k + v_k \end{cases} \tag{4-4}$$

基于上述线性化模型，EKF 的主要步骤包括预测和更新两个阶段：

Step1：预测阶段。根据当前时刻的状态和控制输入，预测下一个时刻的状态和协方差矩阵：

$$\hat{x}_{k+1|k} = f\left(\hat{x}_k, u_k\right) \tag{4-5}$$

$$P_{k+1|k} = A_k P_k A_k^T + Q_k \tag{4-6}$$

其中，P_k 是当前状态的协方差矩阵，Q_k 是过程噪声协方差矩阵。

Step2：更新阶段。在获取到新的测量值之后，通过卡尔曼增益对状态进行修正。

$$K_{k+1} = P_{k+1|k} C_k^T \left(C_k P_{k+1|k} C_k^T + R_k\right)^{-1} \tag{4-7}$$

$$\hat{x}_{k+1} = \hat{x}_{k+1|k} + K_{k+1}\left(y_{k+1} - g\left(\hat{x}_{k+1|k}, u_k\right)\right) \tag{4-8}$$

$$P_{k+1} = \left(I - K_{k+1} C_k\right) P_{k+1|k} \tag{4-9}$$

其中，K_k 是卡尔曼增益，C_k 是测量矩阵，R_k 是测量噪声协方差，I 是单位矩阵。

4.1.2 CKF 算法的原理

尽管 EKF 在处理许多非线性系统时表现良好，但在处理高度非线性或复杂动态系统时，可能因线性化误差而影响估算精度。与 EKF 不同，容积卡尔曼滤波（CKF）

中国知网 https://www.cnki.net

不依赖于泰勒展开进行线性化，而是通过生成容积点直接近似非线性系统的状态转移和测量过程[84]。这使得 CKF 在应对高度非线性系统时能够提供更为精确的估算结果，有效避免了 EKF 中可能出现的线性化误差。

CKF 的基本思想可以分为以下几个步骤：

（1）生成容积点：根据当前的状态估计和协方差矩阵，生成若干个容积点。这些点用于在非线性系统中进行传播，近似状态变量的分布。

（2）传播容积点：将容积点通过系统的状态方程进行传播，即计算每个容积点在当前控制输入下的未来状态。

（3）计算预测状态和协方差：根据传播后的容积点，估算出系统的预测状态和协方差。

（4）测量更新：根据实际测量值，利用卡尔曼增益对预测状态进行修正，从而得到更新的状态估计。在介绍 CKF 算法步骤之前，首先对三阶球面径向容积准则进行简单阐述。

在笛卡尔坐标系下，假设有以下积分形式：

$$I(f)=\int_{R^n} f(X)e\left(-X^T X\right)dX \tag{4-10}$$

其中，$I(f)$表示所求积分，R^n 为 n 维积分域，$f(X)$表示非线性函数，X 是 n 维状态向量。

对上式积分的求解分为两步，一是通过球面径向准则将式中的状态向量 X 用方向向量 y 和半径 r 来表示的积分形式，其中令 $X=ry$，$y^Ty=1$，$r\in[0,+\infty)$，由此可得$x^Tx=r^2$。此时式双重积分形式可表示为：

$$I(f)=\int_0^{\infty}\int_{U_n} f(ry)r^{n-1}\exp\left(-r^2\right)d\sigma(y)dr \tag{4-11}$$

其中，$U_n=\{x\in R^n|y^Ty=1\}$表示球面，$\sigma(\cdot)$表示的是积分域 U_n 的微元。将上式拆分为球面积分和径向积分：

$$S(r)=\int_{U_n} f(ry)d\sigma(y) \tag{4-12}$$

$$I(f)=\int_0^{\infty} S(r)r^{n-1}\exp\left(-r^2\right)dr \tag{4-13}$$

二是提出三阶球面径向容积规则。对上面两个公式分别应用点数为 m_r 的高斯积分准则和点数为 m_s 的球面准则，由此可得：

中国知网 https://www.cnki.net

$$\int_0^{\infty} S(r) r^{n-1} \exp\left(-r^2\right) dr = \sum_{i=1}^{m_r} a_i S(r_i) \tag{4-14}$$

$$\int_{U_n} f(ry) d\sigma(y) = \sum_{j=1}^{m_s} b_j f\left(ry_j\right) \tag{4-15}$$

根据上式可得$mr \times ms$点球面径向容积准则：

$$I(f) = \int_{R_n} f(x) \exp\left(-x^T x\right) dx \approx \sum_{j=1}^{m_s} \sum_{i=1}^{m_r} a_i b_j f\left(r_i y_j\right) \tag{4-16}$$

因为在三阶球面径向容积准则中，m_r=1，m_s=2n，所以容积点共有 2n 个。由此可以得到标准的高斯加权积分计算：

$$I_N(f) = \int_{R_n} f(x) N(x;0,I) dx \approx \sum_{i=1}^{m} w_i f\left(\xi_i\right) \tag{4-17}$$

其中，$i = 1,2,\cdots,2n$，$m = 2n$，$\xi_i = \sqrt{n}[1]_i$表示容积点集，$w_i = \frac{1}{m}$代表各个容积点加权权值，且均为正值，[1]表示向量集合，如下式所示：

$$[1] = \left\{ \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{pmatrix}, \cdots, \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{pmatrix}, \begin{pmatrix} -1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \begin{pmatrix} 0 \\ -1 \\ \vdots \\ 0 \end{pmatrix}, \cdots, \begin{pmatrix} 0 \\ 0 \\ \vdots \\ -1 \end{pmatrix} \right\} \tag{4-18}$$

在以上分析中，已经对容积点的生成过程进行了详细推导介绍，其 CKF 算法的具体步骤如下：

Step1：初始化。初始化状态量 $\hat{x}_k$，误差协方差矩阵 P_k，过程噪声和观测噪声 Q、R。

Step2：计算容积点。

$$P_k = S_k S_k^T \tag{4-19}$$

$$x_k^i = \hat{x}_k \pm \xi_i \bullet S_k, i = 1,2,...,2n \tag{4-20}$$

其中，n为状态量的维数，ξ_i为容积点集，如下所示：

$$\xi_i = \begin{cases} \sqrt{n}[1]_i & i = 1,2,\ldots,2n \\ -\sqrt{n}[1]_i & i = n+1,n+2,\ldots,2n \end{cases} \tag{4-21}$$

上式中，[1]表示单位矩阵。

Step3：传播容积点。

$$x_{k+1|k}^i = f\left(x_k^i, u_k\right) \tag{4-22}$$

中国知网 https://www.cnki.net

Step4：状态预测及误差协方差预测。

$$\hat{x}_{k+1|k}=\frac{1}{2n}\sum_{i=1}^{2n}x_{k+1|k}^{i} \tag{4-23}$$

$$P_{k+1|k}=\frac{1}{2n}\sum_{i=1}^{2n}x_{k+1|k}^{i}\left(x_{k+1|k}^{i}\right)^{T}-\hat{x}_{k+1|k}\left(\hat{x}_{k+1|k}\right)^{T}+Q \tag{4-24}$$

Step5：计算容积点。

$$P_{k+1|k}=S_{k+1|k}S_{k+1|k}^{T} \tag{4-25}$$

$$X_{k+1|k}^{i}=S_{k+1|k}\xi_{i}+\hat{x}_{k+1|k} \tag{4-26}$$

Step6：传播容积点。

$$y_{k+1}^{i}=g\left(X_{k+1|k}^{i},u_{k+1}\right) \tag{4-27}$$

Step7：计算观测预测值。

$$\hat{y}_{k+1}=\frac{1}{2n}\sum_{i=1}^{2n}y_{k+1}^{i} \tag{4-28}$$

Step8：计算观测误差协方差和互协方差。

$$P_{k+1}^{y}=\frac{1}{2n}\sum_{i=1}^{2n}y_{k+1}^{i}\left(y_{k+1}^{i}\right)^{T}-\hat{y}_{k+1}\left(\hat{y}_{k+1}\right)^{T}+R \tag{4-29}$$

$$P_{k+1}^{xy}=\frac{1}{2n}\sum_{i=1}^{2n}X_{k+1|k}^{i}\left(y_{k+1}^{i}\right)^{T}-\hat{x}_{k+1|k}\left(\hat{y}_{k+1}\right)^{T} \tag{4-30}$$

Step9：计算卡尔曼增益，更新状态量及误差协方差。

$$\begin{cases}K_{k+1}=P_{k+1}^{xy}\left(P_{k+1}^{y}\right)^{-1}\\ \hat{x}_{k+1}=\hat{x}_{k+1|k}+K_{k+1}\left(y_{k+1}-\hat{y}_{k+1}\right)\\ P_{k+1}=P_{k+1|k}-K_{k+1}P_{k+1}^{y}K_{k+1}^{T}\end{cases} \tag{4-31}$$

4.1.3 SRCKF 算法的原理

传统 CKF 算法中要求协方差矩阵必须为正定矩阵和对称矩阵，且在迭代过程中一直保证其正定性和对称性，但在其运算过程中矩阵的平方根运算或求逆运算都有可能导致协方差的正定性和对称性消失[85]。平方根容积卡尔曼滤波（SRCKF）是一种基于 CKF 改进的算法，它通过在 CKF 算法中引入 Cholesky 更新与 QR 分解，利用状态协方差矩阵的平方根去代替状态协方差矩阵来求解迭代，进而能有效保持了协方差矩阵的正定性，显著提升算法的数值稳定性和计算精度。

中国知网 https://www.cnki.net

SRCKF 算法的状态协方差矩阵平方根主要通过两种线性代数计算：Cholesky 更新与 QR 分解。针对 Cholesky 更新过程，其数学表述为：

$$C^{'} = Cholupdate\left(C, v\right) \tag{4-32}$$

其中，$Cholupdate(\cdot)$为 Cholesky 分解的秩；C'为原始矩阵 A 的 Cholesky 分解上三角因子，即$C' = chol(A)$；v 为与矩阵维度匹配的列向量。该运算通过列向量 v 对 Cholesky 因子 C 进行秩修正，生成新矩阵$A + vv^T$的上三角 Cholesky 因子。

对于 QR 分解过程，设矩阵$B^T \in \mathbb{R}^{M\times N}$，其分解形式可表示为$B^T = QR$，其中$Q \in \mathbb{R}^{M\times N}$为正交矩阵，$R \in \mathbb{R}^{M\times N}$为上三角矩阵，由此可推导协方差矩阵的平方根特性：

$$S = BB^T = \left(QR\right)^T \left(QR\right) = R^T Q^T QR = R^T R \tag{4-33}$$

若定义$R' = R^T$，则矩阵平方根$R' \in \mathbb{R}^{M\times N}$满足$S = R'R^T$，表明通过 QR 分解可直接提取协方差矩阵的平方根因子。此特性可进一步推广至三对角化运算，即：

$$R = Trid\left(\left[\!\left[B^T \right]\!\right]\right)^T \tag{4-34}$$

SRCKF 可直接求解误差协方差预测值和状态量误差协方差估计值的平方根因子，从而可避开对其进行平方根运算。除此之外，SRCKF 在迭代中，可以一直保持协方差的对称与正定性，从而提升运算的准确性与可靠性。基于 SRCKF 算法的步骤如下：

Step1：初始化。初始化状态量 $\hat{x}_k$，误差协方差矩阵 P_k，过程噪声和测量噪声 Q、R。

Step2：基于 CKF 的容积规则计算容积点。

$$X_{j,k} = S_k \xi_j + \hat{x}_k \tag{4-35}$$

Step3：状态方程传播。

$$X^*_{j,k+1} = f\left(X_{j,k}, u_k\right) \tag{4-36}$$

Step4：计算状态预测值与误差协方差的平方根。

$$\begin{cases} \overline{x}_{k+1} = \dfrac{1}{2n}\sum_{j=1}^{2n} X^*_{j,k+1} \\ \overline{S}_{k+1} = Tria\left(\left[\!\left[\chi^*_{k+1}, S_Q \right]\!\right]\right) \end{cases} \tag{4-37}$$

其中，$Tria()$表示对矩阵进行 QR 分解，矩阵χ^*_{k+1}，S_Q 定义如下：

中国知网 https://www.cnki.net

$$\begin{cases} \lambda_{k+1}^{*}=\dfrac{1}{\sqrt{2n}}\left[X_{1,k+1}^{*}-\bar{x}_{k+1},X_{2,k+1}^{*}-\bar{x}_{k+1},\cdots,X_{2n,k+1}^{*}-\bar{x}_{k+1}\right] \\ S_Q=chol(Q) \end{cases} \tag{4-38}$$

其中，$chol(\cdot)$表示对矩阵进行科列斯基分解。

Step5：计算容积点。

$$X_{j,k+1}=\bar{S}_{k+1}\xi_j+\bar{x}_{k+1} \tag{4-39}$$

Step6：观测方程传播。

$$y_{j,k+1}=g\left(X_{j,k+1},u_{k+1}\right) \tag{4-40}$$

Step7：观测预测值计算。

$$\bar{y}_{k+1}=\frac{1}{2n}\sum_{i=1}^{2n}y_{j,k+1} \tag{4-41}$$

Step8：计算观测误差协方差矩阵的平方根。

$$S_{yy,k+1}=Tria\left(\left[\varsigma_{k+1},S_R\right]\right) \tag{4-42}$$

其中，矩阵ς_{k+1}，S_R定义为：

$$\begin{cases} \varsigma_{k+1}=\dfrac{1}{\sqrt{2n}}\left[y_{1,k+1}-\bar{y}_{k+1},y_{2,k+1}-\bar{y}_{k+1}\cdots,y_{2n,k+1}-\bar{y}_{k+1}\right] \\ S_R=chol(R) \end{cases} \tag{4-43}$$

Step9：计算状态与观测预测值的互协方差矩阵平方根。

$$P_{xy,k+1}=\lambda_{k+1}\varsigma^{T}{}_{k+1} \tag{4-44}$$

其中，矩阵λ_{k+1}定义为：

$$\lambda_{k+1}=\frac{1}{\sqrt{2n}}\left[X_{1,k+1}-\bar{x}_{k+1},X_{2,k+1}-\bar{x}_{k+1},\cdots,X_{2n,k+1}-\bar{x}_{k+1}\right] \tag{4-45}$$

Step10：更新卡尔曼增益K_{k+1}、状态估计$\hat{x}_{k+1}$及误差协方差平方根S_{k+1}。

$$\begin{cases} K_{k+1}=\left(P_{xy,k+1}/S_{yy,k+1}^{T}\right)/S_{yy,k+1} \\ \hat{x}_{k+1}=\bar{x}_{k+1}+K_{k+1}\left(y_{k+1}-\bar{y}_{k+1}\right) \\ S_{k+1}=Tria\left[\lambda_{k+1}-K_{k+1}\varsigma_{k+1}K_{k+1}S_R\right] \end{cases} \tag{4-46}$$

4.1.4 MIASRCKF 算法的原理

尽管 SRCKF 算法通过协方差矩阵的平方根分解能提高数值稳定性，但其在动

中国知网 https://www.cnki.net

态工况与复杂噪声环境下的 SOC 估计仍存在以下局限性：

1）固定噪声协方差假设：SRCKF 默认过程噪声协方差矩阵 Q 与观测噪声协方差矩阵 R 为静态参数。而在实际系统中，当传感器发生漂移或者受到外界环境因素的干扰时，过程噪声和观测噪声会发生变化，继续选定固定的噪声值可能会导致算法对系统状态量的估计出现偏差。

2）单新息局限性：传统 SRCKF 仅依赖单一时刻的新息进行状态修正。而在实际工况中，由于复杂多变的工作环境以及运行工况导致锂电池的状态不仅仅只受前一时刻的影响，只依赖单一时刻的新息修正，可能也会影响算法的估计精度。

针对 SRCKF 算法中其噪声协方差固定性的问题，文献[86]将基于电池模型输出电压残差序列的协方差思想引入 SRCKF 算法中，提出了自适应平方根容积卡尔曼滤波算法（ASRCKF）。

$$\begin{cases} R_k = F_k + \dfrac{1}{2n}\sum_{j=1}^{2n}\left(y_{j,k} - y_k\right)\left(y_{j,k} - y_k\right)^T \\ Q_k = K_k F_k K_k^{\ T} + F_k \end{cases} \tag{4-47}$$

其中，$F_k = \dfrac{1}{L}\sum_{i=k-L+1}^{k} e_i e_i^T$ 为 k 时刻电压残差协方差的近似值；$1/L$ 表示缩放因子，防止出现过度修正；e_i 为 i 时刻模型输出的端电压与实际测量端电压之间的差值。通过以上调整，ASRCKF 算法能够适应环境中的噪声变化，提高算法的估计精度。

针对 SRCKF 算法中单新息的局限性在 ASRCKF 算法中也同样适用，锂电池因其复杂的时变特性、不可预设的工作环境和运行工况不符合这一假设条件，其状态不仅仅只受前一时刻的影响。因此，为进一步提高卡尔曼滤波系列算法的估计精度，本文在 ASRCKF 算法基础上，通过结合多新息理论，提出多新息自适应平方根容积卡尔曼滤波（MIASRCKF），利用历史新息序列加权修正状态更新。具体来说，MIASRCKF 不再仅依赖单一时刻的新息，而是利用一个固定新息长度的窗口来存储过去若干时刻的观测新息。这些观测新息通过加权方式参与状态更新能够更好地平滑系统的状态修正过程，从而增强估计精度。

在标准的卡尔曼滤波中，状态更新公式为：

$$\hat{x}_k = \hat{x}_{k|k-1} + K_k \cdot \left(y_k - \hat{y}_{k|k-1}\right) \tag{4-48}$$

其中，$y_k - \hat{y}_{k|k-1}$称为新息，表示当前时刻的观测值与预测观测值之间的差值。在多新息方法中，引入新息长度为 M 的窗口构建一个多新息向量：

中国知网 https://www.cnki.net

$$\begin{bmatrix} \varepsilon_k \\ \varepsilon_{k-1} \\ \vdots \\ \varepsilon_{k-M+1} \end{bmatrix} = \begin{bmatrix} y_k - \hat{y}_{k|k-1} \\ y_{k-1} - \hat{y}_{k-1|k-2} \\ \vdots \\ y_{k-M+1} - \hat{y}_{k-M+1|k-M} \end{bmatrix} \tag{4-49}$$

将卡尔曼增益拓展为卡尔曼增益矩阵：

$$K_{M,k} = \left[K_k, K_{k-1}, \cdots, K_{k-M+1}\right] \tag{4-50}$$

由此，状态更新可通过多新息修正：

$$\hat{x}_k = \hat{x}_{k|k-1} + \sum_{m=1}^{M} \lambda_m K_{k-m+1} \cdot \varepsilon_{k-m+1} \tag{4-51}$$

其中，λ 表示不同时刻的增益中加入的权重因子，实现对累积干扰的校正。具体如下所示：

$$\begin{cases} \lambda_1 = 1 \\ \lambda_2 = \lambda_3 = \cdots \lambda_M = \dfrac{a}{M-1} \end{cases} \tag{4-52}$$

式中，λ_1 取 1 是为了确保当前增益的权重最大，a 为可调系数。

为实现 MIASRCKF 对电池的 SOC 进行估计，需要建立离散化后的电池状态空间方程获取所需的矩阵参数。在第三章 3.2 节中已经得到二阶 RC 电路模型的离散化状态方程式和输出方程式，联立上述方程即可得到所需的系统矩阵参数：

$$A_k = \begin{bmatrix} 1 & 0 & 0 \\ 0 & e^{-\frac{T}{\tau_1}} & 0 \\ 0 & 0 & e^{-\frac{T}{\tau_2}} \end{bmatrix} \quad B_k = \begin{bmatrix} -\dfrac{\eta T}{C_N} \\ R_1\left(1 - e^{-\frac{T}{\tau_1}}\right) \\ R_2\left(1 - e^{-\frac{T}{\tau_2}}\right) \end{bmatrix}$$

$$C_k = \begin{bmatrix} \dfrac{dU_{oc}\left(SOC(k)\right)}{d\left(SOC(k)\right)} & -1 & -1 \end{bmatrix} \quad D_k = \left[-R_0\right] \tag{4-53}$$

其中，τ_1=R_1C_1，τ_2=R_2C_2 分别为两个并联 RC 电阻网络的时间常数。

基于上述 MIASRCKF 算法的原理及实现步骤，理论上已能够实现对锂电池 SOC 的估算。为确保电池模型能够实时地且精确地反映当前时刻电池的实际状态，本节在进行电池状态估算的过程中，同步实施了模型参数的实时更新机制。采用了第三章验证的 AFFRLS 算法与 MIASRCKF 算法相结合的策略，从而实现电池模型的动态更新和锂电池 SOC 的在线估计。其 AFFRLS-MIASRCKF 在线估计 SOC 的流程图如图 32 所示。

中国知网 https://www.cnki.net

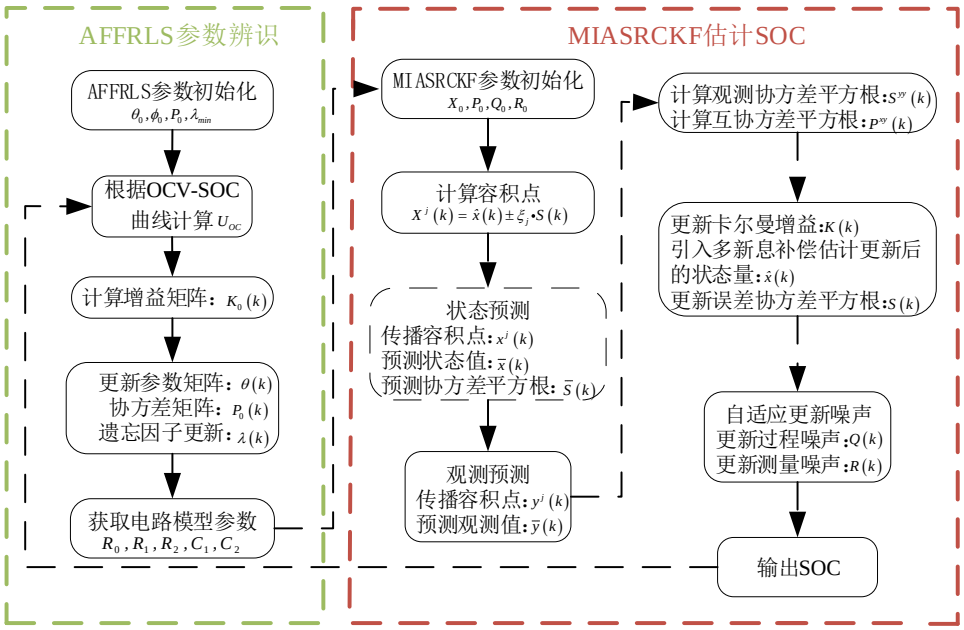


图 32 AFFRLS-MIASRCKF 算法估计 SOC 流程图

Fig.32 Flow diagram of SOC estimation by AFFRLS-MIASRCKF algorithm

4.2 AFFRLS-MIASRCKF 估计 SOC 分析

4.2.1 收敛性分析

在实际应用中，受环境效应的影响，可能会使电池初始 SOC 值出现偏差。因此，探究算法的误差校正能力对保障电池精准监测尤为关键。为了验证 AFFRLS-MIASRCKF 算法的收敛性，本节对 25℃下的 BJDST 工况和 FUDS 工况，分别在正确 SOC 初始值（90%）和错误 SOC 初始值（80%、70%和 60%）的情况下使用 AFFRLS-MIASRCKF 算法进行估计，两个工况下的估计图分别如图 33 和 34 所示。

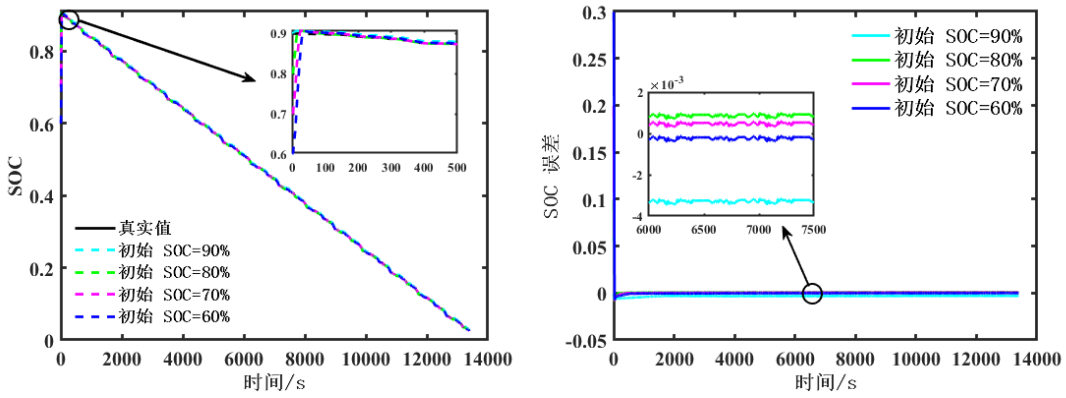


图 33 BJDST 工况下不同初始 SOC 值估计结果

Fig.33 Estimation of different initial SOC values under BJDST conditions

中国知网 https://www.cnki.net

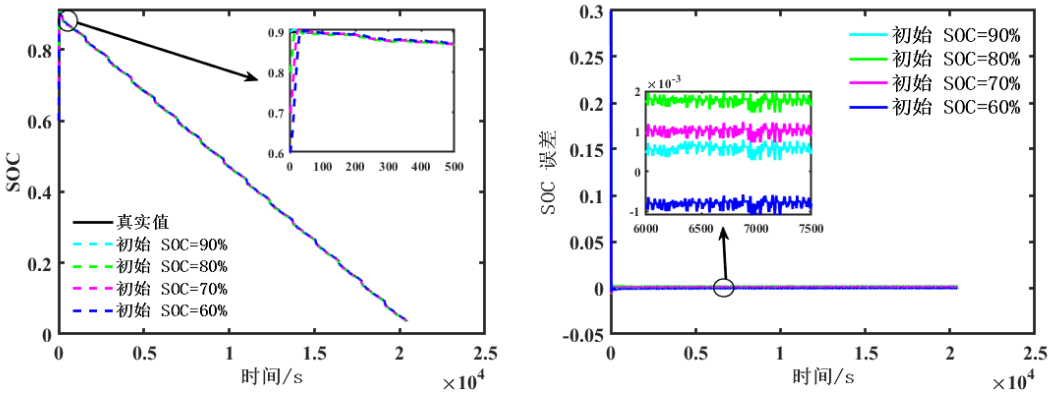


图 34 FUDS 工况下不同初始 SOC 值估计结果

Fig.34 Estimation of different initial SOC values under FUDS conditions

从图中可以看出，无论是在正确 SOC 初始值还是错误 SOC 初始值下，AFFRLS-MIASRCKF 算法都能快速收敛。由局部放大图可知，SOC 初始误差越大，收敛速度越慢。但在两种工况下，算法在不同 SOC 初始值下都能在 100s 之内收敛至正确值。表 6 给出了算法的具体误差评价指标结果，从表中可以看到，在不同 SOC 初始值下，AFFRLS-MIASRCKF 算法 SOC 估计的 MAE 和 RMSE 均不超过 1%，表明所提出的算法具有良好的初始误差纠正能力与鲁棒性。

表 6 算法收敛性评价指标

Table 6 Evaluation indicators of algorithm convergence

工况	SOC 初始值	MAE(%)	RMSE(%)
BJDST	90%	0.06	0.09
	80%	0.09	0.23
	70%	0.14	0.53
	60%	0.07	0.90
FUDS	90%	0.07	0.07
	80%	0.19	0.25
	70%	0.23	0.41
	60%	0.10	0.73

4.2.2　估计精度分析

为了验证 AFFRLS-MIASRCKF 算法在复杂条件下 SOC 估计效果，本节分别在 BJDST 工况和 FUDS 工况下，采用-10℃、25℃和 40℃三种不同温度进行 SOC 估计分析，SOC 初始值设置为 0.7。

（1）BJDST 工况

中国知网　https://www.cnki.net

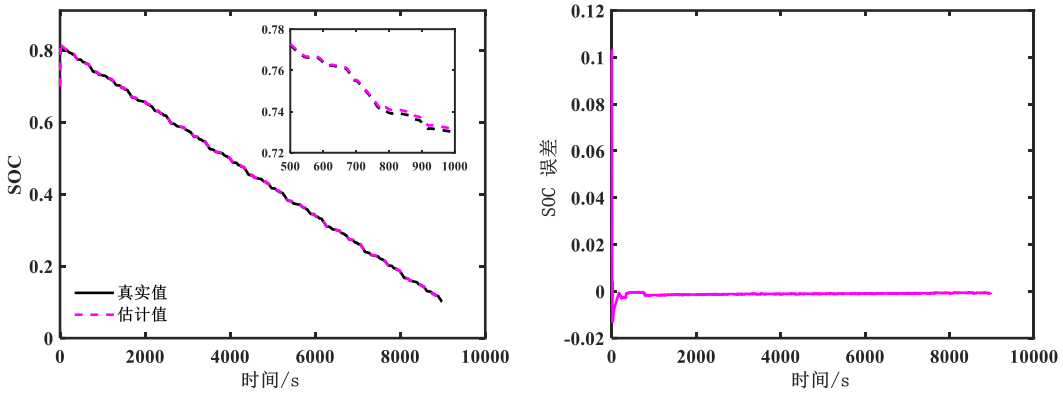


图 35 -10℃下 SOC 估计结果

Fig.35 SOC estimation at -10°C

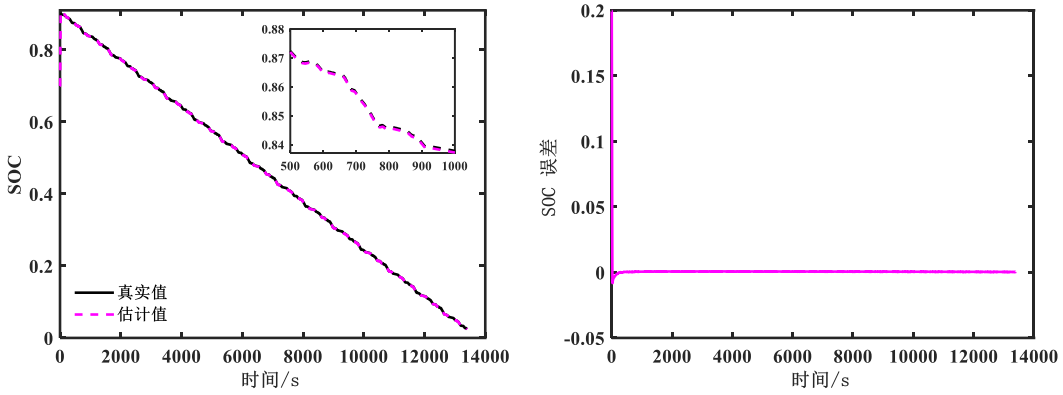


图 36 25℃下 SOC 估计结果

Fig.36 SOC estimation at 25°C

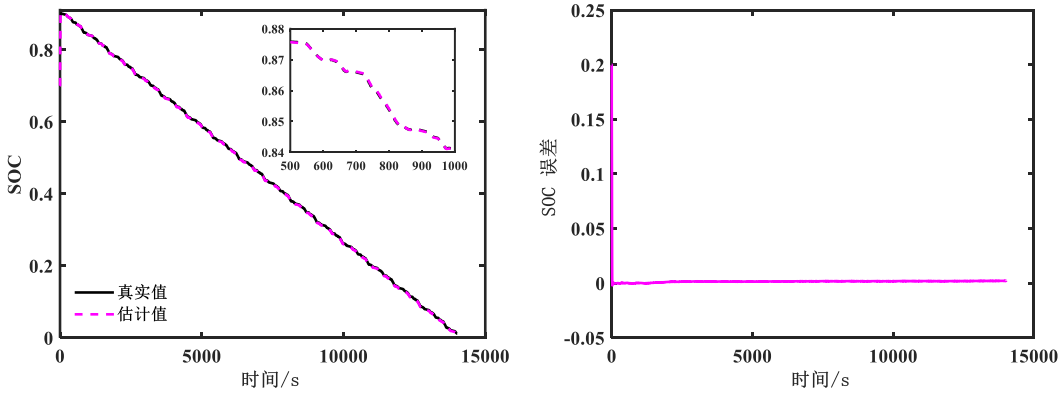


图 37 40℃下 SOC 估计结果

Fig.37 SOC estimation at 40°C

在 BJDST 工况下，采用 AFFRLS-MIASRCKF 算法在-10℃、25℃和 40℃三种温度下进行 SOC 估计结果如图 35-37 所示。从图中可以看出，AFFRLS-MIASRCKF

中国知网 https://www.cnki.net

算法在不同温度下，均能准确估计电池的 SOC 值，与真实值的变化接近一致。在-10℃时，AFFRLS-MIASRCKF 算法在 300s 左右收敛，随着温度的升高，SOC 估计的收敛速度逐渐加快，在 40℃下，SOC 估计的收敛速度最快，具体误差评估结果如表 7 所示。

表 7 BJDST 工况下三种温度 SOC 估计误差结果

Table 7 Estimation error results of SOC at three temperatures under BJDST conditions

工况	温度	MAE（%）	RMSE（%）
BJDST	-10	0.12	0.29
	25	0.14	0.53
	40	0.13	0.32

从表中可以看出，在 BJDST 工况下，AFFRLS-MIASRCKF 算法在-10℃、25℃和 40℃下估计的 MAE 分别为 0.12%、0.14%和 0.13%，RMSE 分别为 0.29%、0.53%和 0.32%，三种温度下的 MAE 与 RMSE 均不超过 0.53%，表明算法具有较高的准确性。

（2）FUDS 工况

在 FUDS 工况下，-10℃、25℃和 40℃三种不同温度下采用 AFFRLS-MIASRCKF 算法 SOC 估计结果如图 38-40 所示。

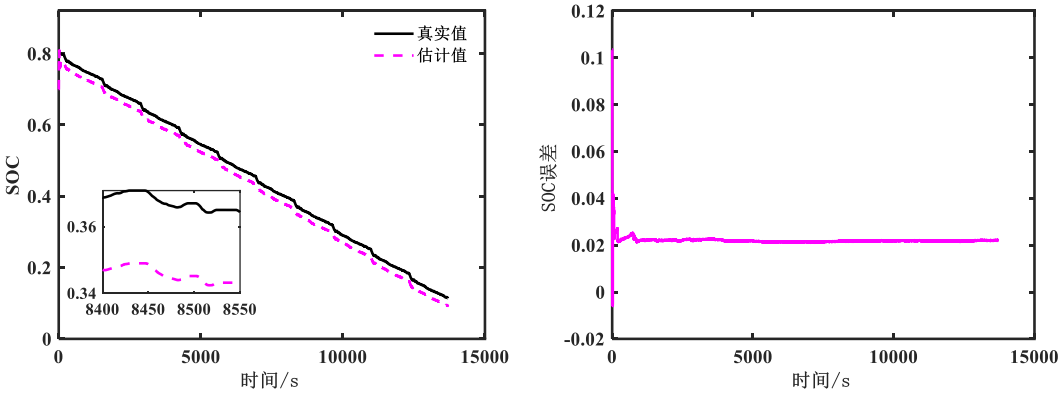


图 38 -10℃下 SOC 估计结果

Fig.38 SOC estimation at -10°C

中国知网　https://www.cnki.net

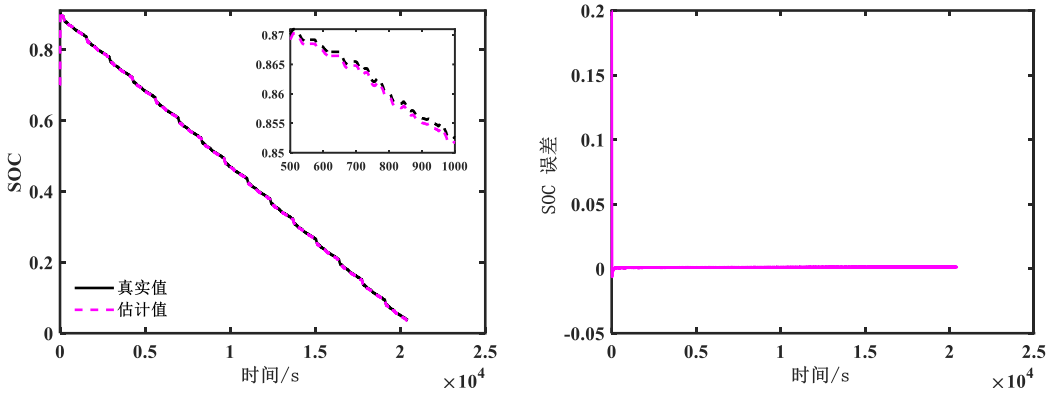


图 39 25℃下 SOC 估计结果

Fig.39 SOC estimation at 25℃

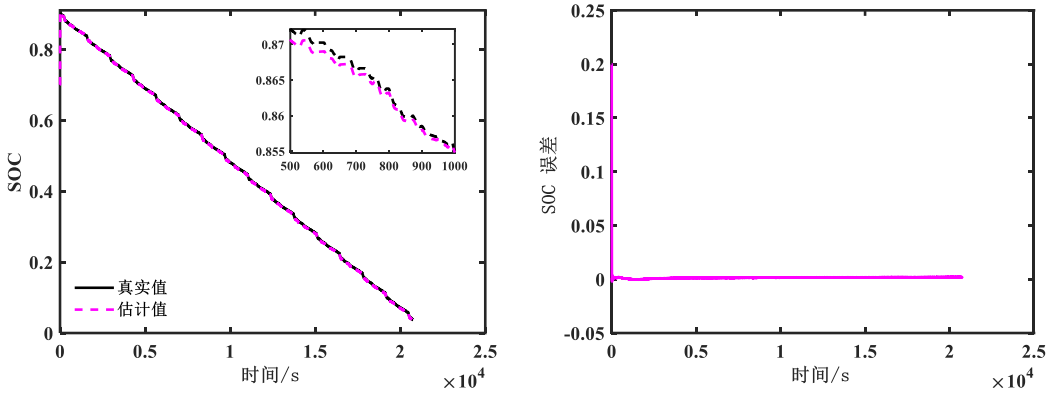


图 40 40°C下 SOC 估计结果

Fig.40 SOC estimation at 40°C

从图中可以看到，在 FUDS 工况下，随着温度的升高，SOC 估计的收敛速度也在逐渐加快。从表 8 可以看到，在-10°C 时，SOC 估计误差较大，MAE 和 RMSE 都超过了 2%。而在 25℃和 40°C 时，SOC 估计的误差较小，MAE 和 RMSE 均不超过 0.5%，具有较高的准确性。

表 8 FUDS 工况下三种温度 SOC 估计误差结果

Table 8 Estimation error results of SOC at three temperatures under FUDS conditions

工况	温度	MAE（%）	RMSE（%）
FUDS	-10	2.2	2.21
	25	0.23	0.41
	40	0.15	0.37

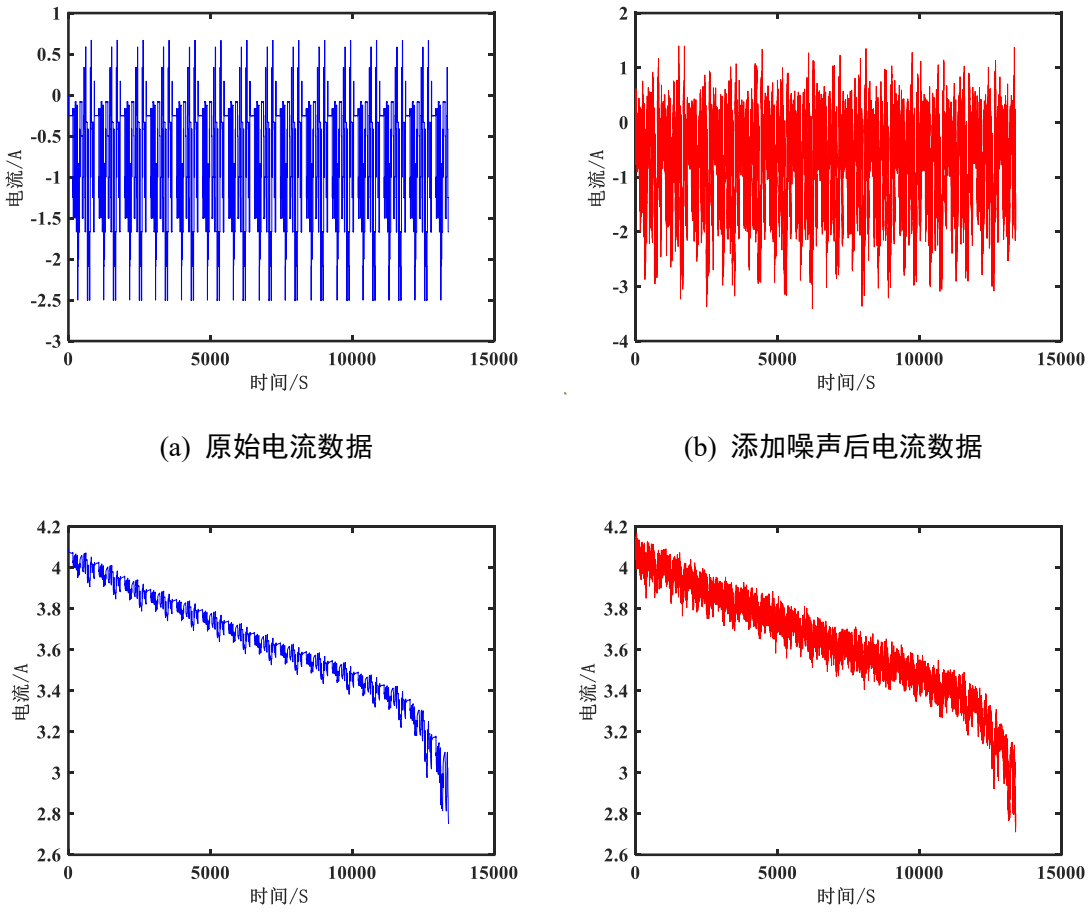
中国知网 https://www.cnki.net

4.2.3　电流和电压传感器噪声的影响

在实际应用中，由于噪声的干扰，很难从传感器中获得准确的数据。电流电压传感器所带来的噪声会降低电池状态的估计精度，因此为了模拟真实情况并评估 AFFRLS-MIASRCKF 算法的鲁棒性，将不同的高斯噪声附加到测量数据上。高斯噪声通过式 4-54 获得[87]。

$$\begin{cases} U_{Noise} = U + a \cdot randn(1, N) \\ I_{Noise} = I + 10a \cdot randn(1, N) \end{cases} \tag{4-54}$$

式中，U_{Noise} 和 I_{Noise} 为添加高斯噪声之后的电流电压数据，U 和 I 为原始的电流电压数据，a 为高斯噪声的倍率。以 BJDST 工况为例，当高斯噪声倍率 a=0.03 时，原始的电流电压数据与添加高斯噪声之后的电流电压数据对比图如图 41 所示。



(a) 原始电流数据　　(b) 添加噪声后电流数据

(c) 原始电压数据　　(d) 添加噪声后电压数据

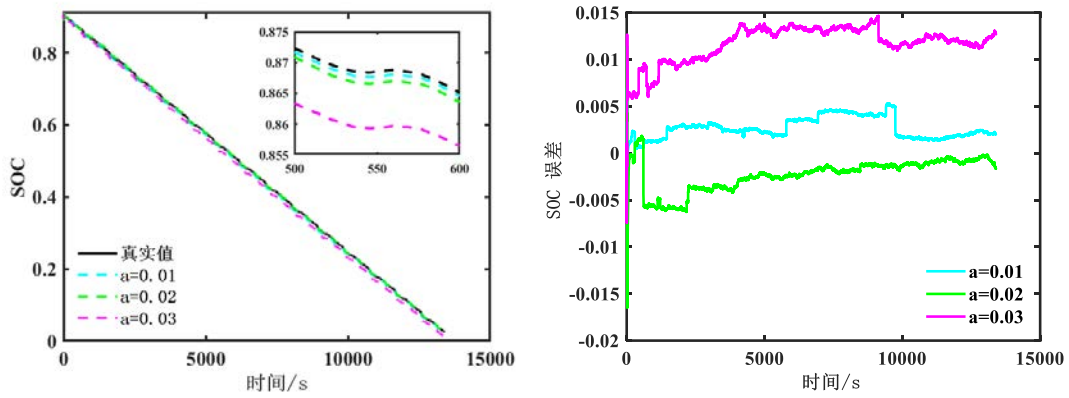
图 41　添加噪声前后电流电压对比图

Fig.41 Comparison of current and voltage before and after adding noise

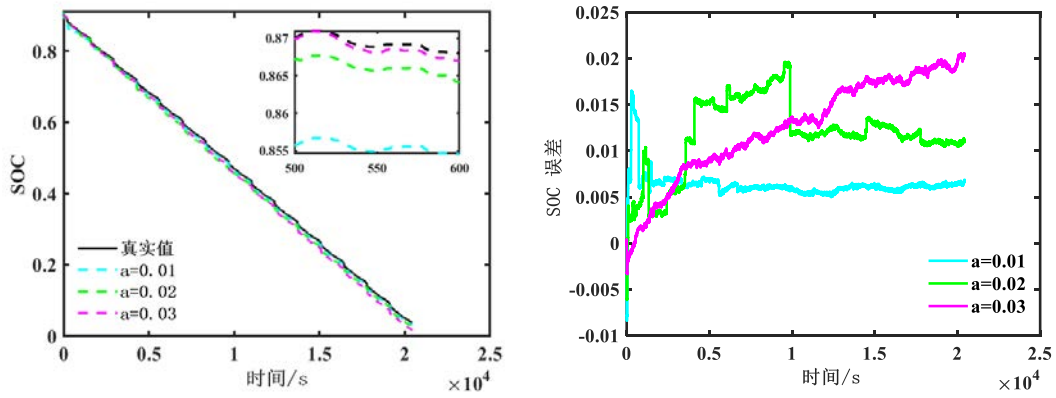
中国知网　https://www.cnki.net

（1）电流传感器噪声影响

在 25℃的温度条件下，为两种工况的原始电流数据分别添加噪声倍率为 0.01、0.02、0.03 的电流噪声，并使用 AFFRLS-MIASRCKF 算法进行 SOC 估计，结果如图 42 所示。从图中可以看出，为电流添加不同的噪声之后，AFFRLS-MIASRCKF 算法估计的电池 SOC 能够在 300s 内收敛于真实的 SOC。其中，随着电流噪声倍率的增大，两个工况下的电池 SOC 估计误差均有不同程度的增大，FUDS 工况较 BJDST 工况受电流噪声的影响更大，估计效果更差。表 9 为两个工况下算法的 SOC 估计误差结果，从表中观察到，两个工况下电池 SOC 估计的 MAE 和 RMSE 均控制在 1.5%以内，以 BJDST 工况为例，电池 SOC 估计的 MAE 分别为 0.27%、0.24%、1.17%，RMSE 分别为 0.29%、0.29%和 1.19%，表明即使存在电流噪声，AFFRLS-MIASRCKF 算法依然具有较高的估计精度。



(a) BJDST 工况结果



(b) FUDS 工况结果

图 42 添加电流噪声后的估计结果与误差

Fig.42 Estimation results and error after adding current noise

中国知网 https://www.cnki.net

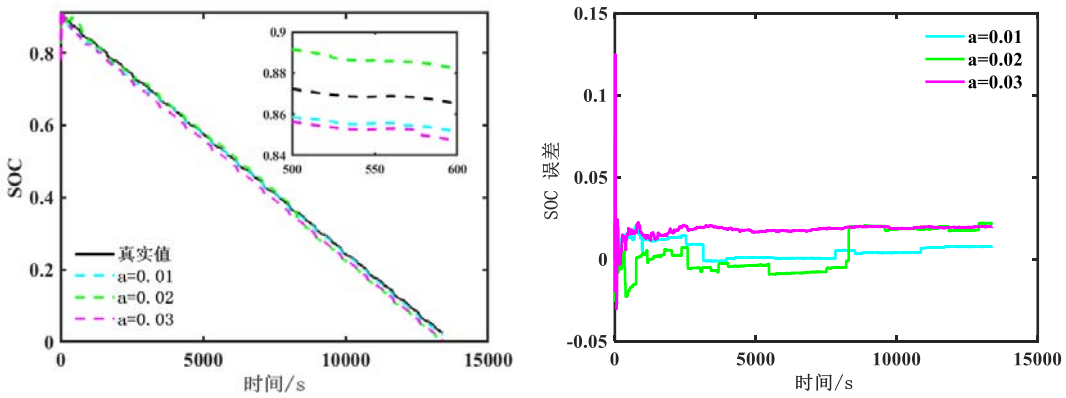
表 9 不同工况添加电流噪声后的误差结果

Table 9 Error results after adding current noise under different operating conditions

工况	噪声倍率 a	MAE（%）	RMSE（%）
BJDST	0.01	0.27	0.29
	0.02	0.24	0.29
	0.03	1.17	1.19
FUDS	0.01	0.64	0.65
	0.02	1.18	1.25
	0.03	1.26	1.37

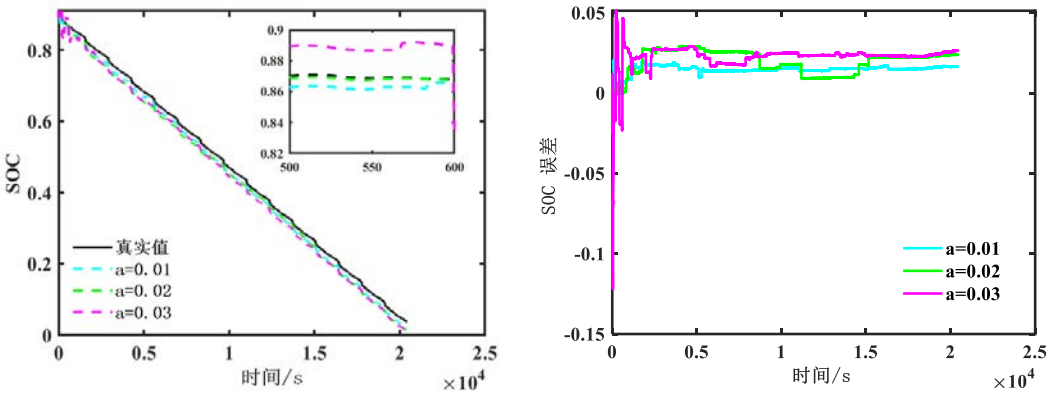
（2）电压传感器噪声影响

该部分同样采用 25℃温度条件下的 BJDST 工况和 FUDS 工况来验证电压传感器噪声对电池 SOC 估计的影响。电压传感器的噪声倍率 a 也分别设置为 0.01、0.02 和 0.03。图 43 为电池 SOC 估计的结果与误差。从图中可以看出，当为测量电压添加不同的噪声倍率之后，AFFRLS-MIASRCKF 算法也能准确估计 SOC 值，在 300s 内收敛于真实的 SOC。进一步从估计误差图中可以看出，相比于电流噪声，电压噪声对电池 SOC 估计的影响较大，这是由于电池内阻较小，电流噪声转化的内阻电压误差要小于电压噪声误差。表 10 为两个工况下添加电压噪声后电池 SOC 估计的误差结果，从表中观察到，在电压传感器噪声的影响下，随着电压噪声倍率的增大，两个工况下的电池 SOC 误差同样存在不同程度的增大，其中 FUDS 工况下的估计结果仍然要差于 BJDST 工况，但两个工况下的电池 SOC 估计的 MAE 和 RMSE 均控制在 3%以内。以 SOC 估计误差较大的 FUDS 工况为例，估计的 MAE 分别为 1.48%、1.98%、2.36%，RMSE 分别为 1.50%、2.11%和 2.40%，表明即使存在较大的电压噪声，AFFRLS-MIASRCKF 算法也依然具有较高的精度。



(a) BJDST 工况结果

中国知网　https://www.cnki.net



(b) FUDS 工况结果

图 43 添加电压噪声后的估计结果与误差

Fig.43 Estimation results and errors after adding voltage noise

表 10 不同工况添加电压噪声后的误差结果

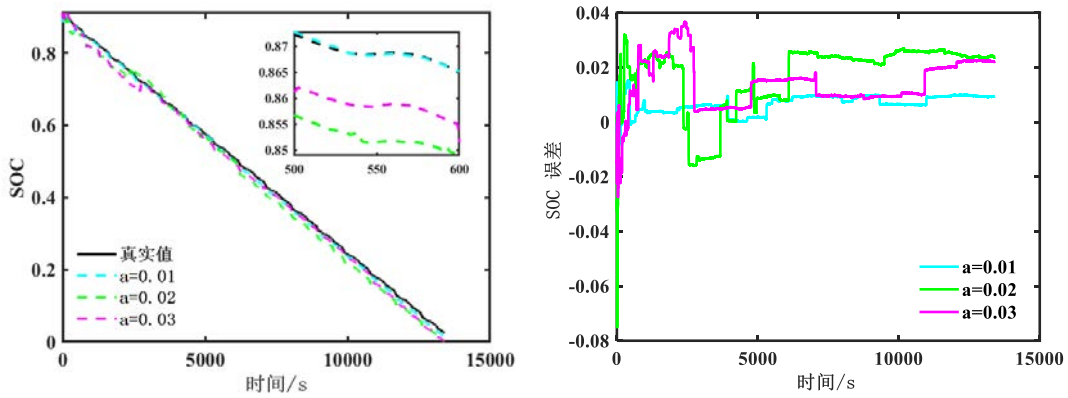
Table 10 Error results after adding voltage noise under different operating conditions

工况	噪声倍率 a	MAE（%）	RMSE（%）
BJDST	0.01	0.54	0.71
	0.02	1.09	1.13
	0.03	1.82	1.85
FUDS	0.01	1.48	1.50
	0.02	1.98	2.11
	0.03	2.36	2.40

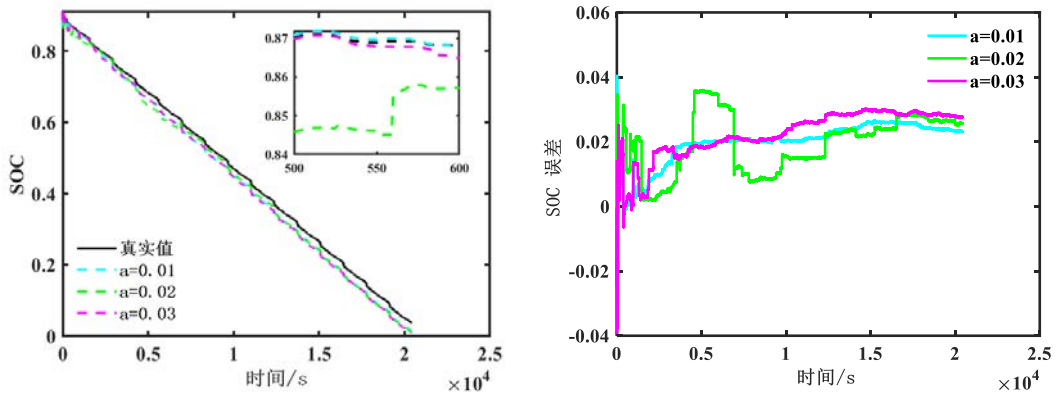
（3）电流和电压传感器噪声影响

以上分别讨论了不同的电流和电压噪声对电池 SOC 估计的影响，但是在实际的复杂环境中，可能同时存在电流和电压噪声。因此，需要同时探讨一下两者叠加对电池 SOC 估计的影响。如下图所示，图 44 为同时添加电流电压噪声之后，采用 AFFRLS-MIASRCKF 算法进行电池 SOC 估计的结果。从图中可以看出，相较于添加单一的噪声，当同时添加电流和电压噪声之后，估计电池 SOC 变得更加困难，误差较大，当算法在收敛于真实的 SOC 之后，仍然存在较大的误差波动。表 11 为两个工况下添加电流电压噪声后 SOC 估计的误差结果评价指标，从表中数据可以看出，随着电流和电压噪声倍率的增大，两个工况下的电池 SOC 误差整体出现不同程度的增大，但电池 SOC 估计的 MAE 和 RMSE 同样均控制在 3%。以 BJDST 工况为例，电池 SOC 估计的 MAE 分别为 0.68%、1.96%、1.46%，RMSE 分别为 0.74%、2.09%和 1.66%，这一结果表明即使同时存在电流与电压噪声，AFFRLS-MIASRCKF 算法也依然能够准确估计电池 SOC。

中国知网 https://www.cnki.net



(a) BJDST 工况结果



(b) FUDS 工况结果

图 44　添加电流电压噪声后的估计结果与误差

Fig.44 Estimation results and errors after adding current-voltage noise

表 11　不同工况添加电流电压噪声后的误差结果

Table 11 Error results after adding current-voltage noise under different operating conditions

工况	电流与电压噪声倍率 a	MAE（%）	RMSE（%）
BJDST	0.01	0.68	0.74
	0.02	1.96	2.09
	0.03	1.46	1.66
FUDS	0.01	1.99	2.08
	0.02	1.95	2.15
	0.03	2.26	2.36

中国知网　https://www.cnki.net

4.3 不同工况下各算法 SOC 估计对比分析

在前面几个小节中，对 AFFRLS-MIASRCKF 算法分别进行了收敛性、估计精度以及考虑噪声影响的验证。本节将通过与多种算法在 BJDST 和 FUDS 两种工况不同温度下 SOC 估计的对比分析，进一步验证算法的有效性。

4.3.1 BJDST 工况结果分析

如图 45-47 所示，分别展示了 AFFRLS-EKF、AFFRLS-CKF、AFFRLS-SRCKF、AFFRLS-ASRCKF 和 AFFRLS-MIASRCKF 五种算法在 BJDST 工况不同温度下的 SOC 估计结果图和误差结果图，SOC 初始值均设置为 0.7。从图中观察到，在-10℃、25℃和 40℃三种环境温度下，AFFRLS-SRCKF、AFFRLS-ASRCKF 和 AFFRLS-MIASRCKF 算法都能快速收敛，且 AFFRLS-MIASRCKF 算法收敛速度要略优于这两个算法。在-10℃时，AFFRLS-MIASRCKF 算法收敛误差至 0.003 左右趋于稳定，AFFRLS-SRCKF 和 AFFRLS-ASRCKF 算法均收敛误差至 0.01 左右趋于稳定，而 AFFRLS-CKF 和 AFFRLS-EKF 两种算法误差则收敛至 0.02 左右趋于稳定。在 25℃和 40℃时，AFFRLS-MIASRCKF 在 100s 内快速收敛，相对其它四种算法具有较快的收敛速度。在相同温度条件下，AFFRLS-CKF 算法的 SOC 估计精度优于 AFFRLS-EKF 算法，AFFRLS-SRCKF 和 AFFRLS-ASRCKF 算法的估计精度较 AFFRLS-CKF 算法有所提升，而 AFFRLS-MIASRCKF 算法表现出更优的估计精度。

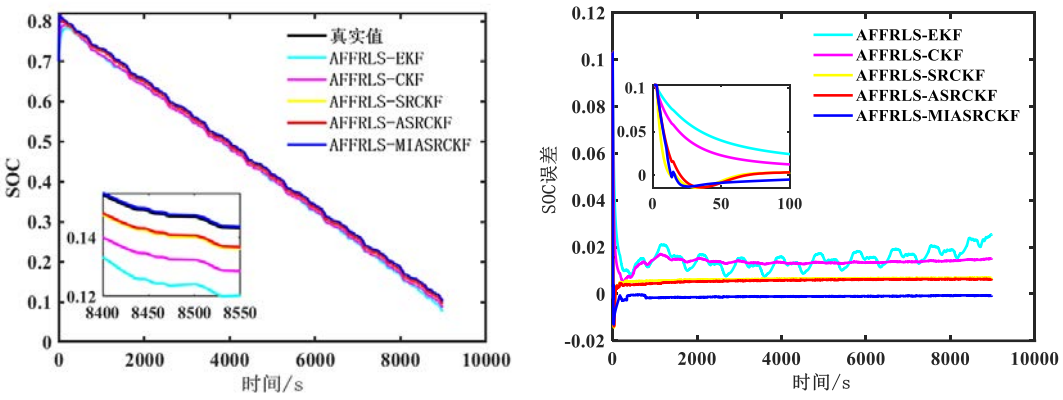


图 45 -10℃下五种算法的 SOC 估计结果

Fig.45 SOC estimation results for five algorithms at -10°C

中国知网 https://www.cnki.net

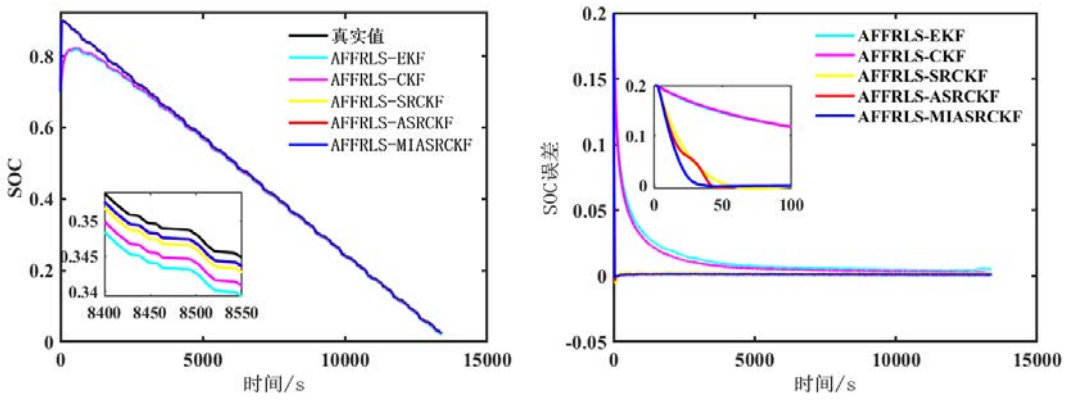


图 46 25℃下五种算法的 SOC 估计结果

Fig.46 SOC estimation results for five algorithms at 25°C

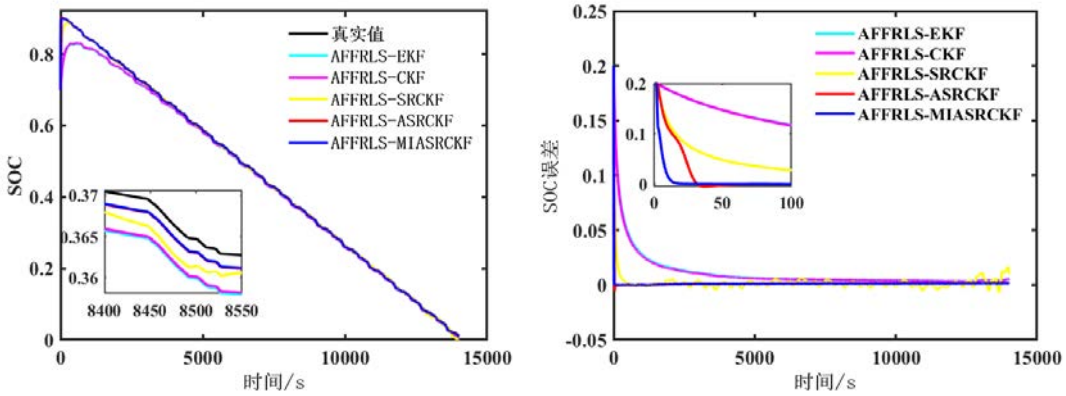


图 47 40℃下五种算法的 SOC 估计结果

Fig.47 SOC estimation results for five algorithms at 40°C

为了量化五种算法的表现差异，表 12 列出了 BJDST 工况下，五种算法在-10℃、25℃和 40℃温度下电池 SOC 估计的 MAE 和 RMSE。在-10℃下，AFFRLS-EKF 和 AFFRLS-CKF 算法的估计效果最差，其 RMSE 值分别为 1.63%和 1.42%。AFFRLS-SRCKF 与 AFFRLS-ASRCKF 算法的估计效果要优于上面两个算法，且估计误差较为接近，RMSE 分别为 0.67%和 0.63%；而 AFFRLS-MIASRCKF 算法通过结合多新息机制，MAE 降至 0.12%，RMSE 降至 0.29%，显著低于其他算法，相较于 AFFRLS-ASRCKF 算法，其 MAE 和 RMSE 分别降低了 79%和 54%，具有良好的低温适应性。在 25℃下，各算法估计误差更加平稳。以 AFFRLS-MIASRCKF 算法为例，SOC 跟踪曲线近乎重合于真实值，25℃下的 MAE 仅为 0.14%，表明 AFFRLS-MIASRCKF 算法能够准确估计 SOC。在 40℃下，AFFRLS-MIASRCKF 算法估计的 MAE 和 RMSE 为 0.13%和 0.32%，表明在高温下，AFFRLS-MIASRCKF 算法同样具有较高的估计精度。

中国知网 https://www.cnki.net

表 12 五种算法在 BJDST 工况下不同温度的 SOC 误差结果

Table 12 SOC error results of the five algorithms at different temperatures under BJDST conditions

算法	温度	MAE(%)	RMSE(%)
AFFRLS-EKF	-10°C	1.54	1.63
	25°C	1.3	2.3
	40°C	1.1	2.11
AFFRLS-CKF	-10°C	1.37	1.42
	25°C	1.08	2.16
	40°C	1.06	2.06
AFFRLS-SRCKF	-10°C	0.64	0.67
	25°C	0.24	0.63
	40°C	0.3	0.73
AFFRLS-ASRCKF	-10°C	0.58	0.63
	25°C	0.16	0.58
	40°C	0.15	0.53
AFFRLS-MIASRCKF	-10°C	0.12	0.29
	25°C	0.14	0.53
	40°C	0.13	0.32

4.3.2 FUDS 工况结果分析

图 48-50 分别展示了五种算法在 FUDS 工况不同温度下的 SOC 估计结果图和误差曲线图。从图中可以看出，随着温度的升高，五种算法的 SOC 估计误差在逐渐减小。以 AFFRLS-MIASRCKF 算法为例，在-10℃下，算法的误差收敛至 0.02 左右趋于稳定；而在 25℃和 40℃下，误差收敛至 0.003 左右趋于稳定，并且在相同温度条件下，AFFRLS-MIASRCKF 算法的 SOC 曲线更贴近于真实曲线。

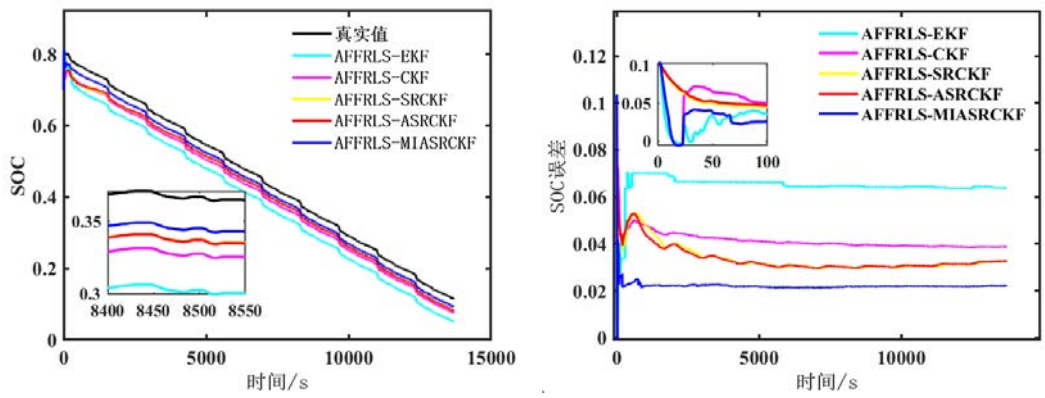


图 48 -10℃下五种算法的 SOC 估计结果

Fig.48 SOC estimation results for five algorithms at -10°C

中国知网 https://www.cnki.net

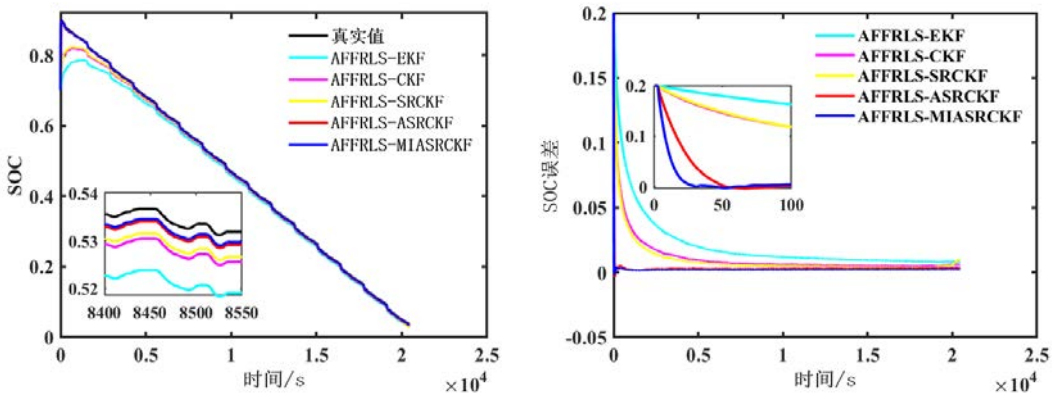


图 49 25℃下五种算法的 SOC 估计结果

Fig.49 SOC estimation results for five algorithms at 25°C

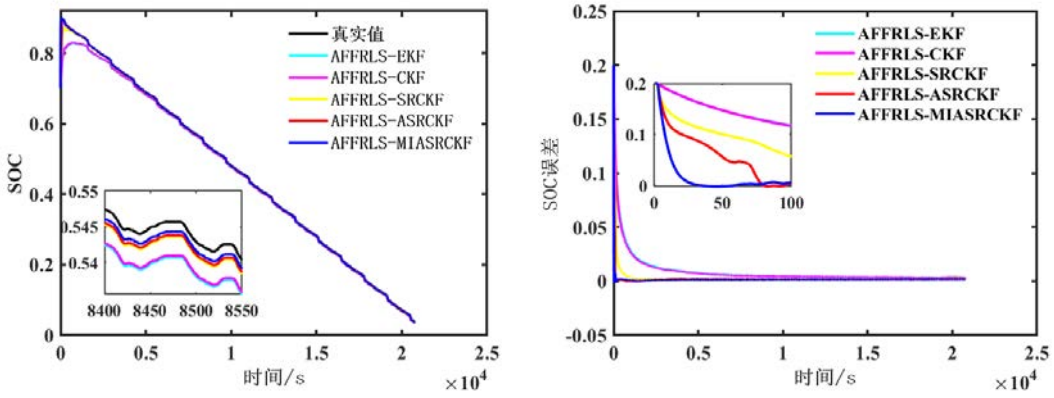


图 50 40℃下五种算法的 SOC 估计结果

Fig.50 SOC estimation results for five algorithms at 40°C

为了量化算法在不同温度条件下的具体表现，同样采用误差评价表来直观的对比五种算法，误差评估指标结果如表 13 所示。在 FUDS 工况下，AFFRLS-EKF 的估计效果略低于 AFFRLS-CKF，AFFRLS-SRCKF 与 AFFRLS-ASRCKF 优于 AFFRLS-EKF 和 AFFRLS-CKF，而 AFFRLS-MIASRCKF 则表现出最高的估计精度。其中，在 40°C 下，AFFRLS-MIASRCKF 的最大 RMSE 仅为 0.37%，相较于 AFFRLS-ASRCKF 算法，RMSE 降低了 37.2%，进一步表明多新息策略的有效性。

表 13 五种算法在 FUDS 工况下不同温度的 SOC 误差结果

Table 13 SOC error results of the five algorithms at different temperatures under FUDS conditions

算法	温度	MAE(%)	RMSE(%)
AFFRLS-EKF	-10°C	6.47	6.5
	25°C	2.06	3.18
	40°C	0.89	1.76

中国知网 https://www.cnki.net

算法	温度	MAE(%)	RMSE(%)
AFFRLS-CKF	-10°C	4.12	4.14
	25°C	1.11	1.94
	40°C	0.85	1.72
AFFRLS-SRCKF	-10°C	3.37	3.42
	25°C	0.96	1.82
	40°C	0.32	0.85
AFFRLS-ASRCKF	-10°C	3.36	3.4
	25°C	0.31	0.56
	40°C	0.22	0.59
AFFRLS-MIASRCKF	-10°C	2.2	2.21
	25°C	0.23	0.41
	40°C	0.15	0.37

基于以上分析可知，在 BJDST 和 FUDS 两种动态工况下，AFFRLS-MIASRCKF 算法在不同温度的 SOC 估计精度、鲁棒性及动态适应性均显著优于对比算法。因此，在实际复杂多变的环境下，AFFRLS-MIASRCKF 算法更适合用于锂离子电池的 SOC 估计。

4.4 本章小结

本章首先介绍了 EKF、CKF、SRCKF、ASRCKF 算法的原理，然后在 ASRCKF 算法的基础上通过引入多新息补偿机制，提出了 MIASRCKF 算法，并结合了参数实时更新的 AFFRLS 算法，探究 AFFRLS-MIASRCKF 算法在不同工况和温度下的适用性。首先验证了 AFFRLS-MIASRCKF 算法在 25℃时不同 SOC 初始值的收敛性，发现在两种工况下，无论 SOC 初始值如何，算法都能在 100s 之内收敛至正确值，估计的 MAE 和 RMSE 均不超过 1%，具有良好的初始误差纠正能力与鲁棒性。其次，通过为电流电压数据添加高斯噪声，检测了 AFFRLS-MIASRCKF 算法的抗噪声能力，在噪声干扰下，估计的 MAE 和 RMSE 均控制在 3%以内。最后，通过对比不同温度和工况下四种算法的实验结果，发现随着算法结构的优化，估计精度显著提升。其中 AFFRLS-MIASRCKF 在 25℃和 40℃的条件下，MAE 和 RMSE 均不超过 0.53%，展现出最优的估计精度和温度适应性。

中国知网 https://www.cnki.net

5 结论与展望

5.1 结论

随着电池技术的不断进步和绿色能源的推广，锂离子电池在能源存储、动力传输以及智能电网等领域的应用愈加广泛。因此，对于锂离子电池的状态评估，尤其是 SOC 估计的重要性逐渐凸显。本文围绕单体锂离子电池的 SOC 估计方法展开研究。通过搭建锂离子电池测试实验平台，获取了锂离子电池充放电实验数据，并分析了其相关特性。建立了二阶 RC 等效电路模型，分别讨论了离线和在线辨识方法对锂离子电池模型精度的影响。搭建了基于 AFFRLS-MIASRCKF 算法的 SOC 在线估计框架，并在不同动态工况和工作温度下进行了验证分析。主要结论如下：

（1）针对锂离子电池的特性实验的分析结果表明，在不同温度下锂离子电池的放电容量是不一致的，锂离子电池的放电容量随工作温度的升高而逐渐增加。不同温度对 OCV-SOC 关系曲线有着影响显著，随着温度的升高，曲线的斜率逐渐增大，表现出较大的电压变化范围。

（2）研究了锂离子电池离线和在线参数辨识方法，基于灰狼优化算法的离线参数辨识方法在 HPPC 工况下辨识精度良好，RMSE 不超过 11.3 mV，然而在动态工况中辨识精度却显著下降。比较了 FFRLS 与 AFFRLS 两种在线参数辨识方法，两种方法均能在动态工况中准确辨识模型参数，可见在线辨识方法具有一定优势。同时，AFFRLS 方法在不同温度下的整体误差表现要优于 FFRLS 方法，RMSE 均不超过 28.3 mV。

（3）在 ASRCKF 算法的基础上通过引入多新息补偿机制，提出 MIASRCKF 算法，并结合了参数实时更新的 AFFRLS 算法，探究了 AFFRLS-MIASRCKF 算法在不同工况和温度下的适用性。结果表明，在不同工况、不同 SOC 初始值和噪声干扰下，AFFRLS-MIASRCKF 算法展现出了较高的估计精度和鲁棒性。最后对比了 AFFRLS-EKF、AFFRLS-CKF、AFFRLS-SRCKF、AFFRLS-ASRCKF 与 AFFRLS-MIASRCKF 五种算法在不同温度和工况条件下的估计性能，结果显示，AFFRLS-MIASRCKF 算法在估计精度上表现最优，在 25℃和 40℃下，MAE 和 RMSE 均不超过 0.53%。

5.2 展望

由于时间和个人学术水平有限，本文仍有很多不足需要进一步深入研究并加以完善，如：

中国知网 https://www.cnki.net

（1）本文在锂离子电池 SOC 估计中采用的是实验测试数据，具有一定局限性，未来可以采集实际的车辆动力电池数据用于验证，提高所提方法的实用性。

（2）本文的研究对象是单体电池，在实际应用中，通常应用的是由单体电池组成的电池组。因此，为了更贴近实际应用场景，未来可拓展至电池组的研究。

（3）本文在研究中未将电池老化因素考虑在内，由于在实际应用中，锂离子电池的容量会随充放电循环次数的增加而降低，因此在未来的工作中，可将电池的老化考虑进 SOC 估计中。

中国知网 https://www.cnki.net

参考文献

[1] 夏煜宸, 韩刚团. “双碳”背景下电动汽车充电设施规划探索与实践[J]. 综合运输, 2024, 46(12): 20-25.

[2] 曾家瑞, 张晋晋, 张潇化等. 经济视角下全球动力电池产业的演变与趋势[J]. 电池, 2024, 54(06): 855-860.

[3] 张斌鹏, 吕炎, 宋国荣等. 锂离子电池荷电状态和内部缺陷的超声透射特性仿真研究[J]. 北京工业大学学报, 2025, 51(03): 258-268.

[4] Chen G, Peng W, Yang F. An LSTM-SA model for SOC estimation of lithium-ion batteries under various temperatures and aging levels[J]. Journal of Energy Storage, 2024, 84: 110906.

[5] Zhu Z, Zhu J, Gao W, et al. Estimation methods for the state of charge and capacity in various states of health of LiFePO4 batteries[J]. Journal of Energy Storage, 2024, 88: 111381.

[6] 冀京润. 基于分数阶模型的锂离子电池参数辨识与荷电状态估计研究[D]. 西安理工大学, 2021.

[7] 彭纪昌, 刘凯龙, 孟锦豪等. 基于变参数结构的锂离子电池建模方法[J]. 机械工程学报, 2024, 60(14): 298-305.

[8] 龙潘, 耿光超, 江全元等. 储能系统锂电池电热耦合建模及参数辨识方法研究[J]. 太阳能学报, 2024, 45(04): 318-327.

[9] 王萍, 弓清瑞, 程泽等. 基于 AUKF 的锂离子电池 SOC 估计方法[J]. 汽车工程, 2022, 44(07): 1080-1087.

[10] 姚芳, 张楠, 黄凯. 估算锂电池 SOC 的基于 LM 的 BP 神经网络算法[J]. 电源技术, 2019, 43(09): 1453-1457.

[11] Zheng Y, Shi Z, Guo D, et al. A simplification of the time-domain equivalent circuit model for lithium-ion batteries based on low-frequency electrochemical impedance spectra[J]. Journal of Power Sources, 2021, 489: 229505.

[12] 黄莉莉, 任星星, 苗博博等. 基于改进 Rint 模型锂离子电池 SOC 估计[J]. 电池工业, 2022, 26(04): 177-180.

[13] 陈正, 王志得, 牟文彪等. 基于 PNGV 模型与自适应卡尔曼滤波的铅炭电池荷电状态评估[J]. 储能科学与技术, 2023, 12(03): 941-950.

[14] 李欢, 王顺利, 邹传云等. 基于 Thevenin 模型和自适应卡尔曼的 SOC 估算研究[J]. 自动化仪表, 2021, 42(01): 46-51.

[15] 李煜, 蔡玉梅, 曾凯等. 基于 EKF 算法的纯电动汽车锂电池 SOC 与 SOH 联合估算[J]. 邵

中国知网 https://www.cnki.net

阳学院学报(自然科学版), 2024, 21(02):45-55.

[16] 邱新宇. 稳健的锂电池等效电路模型参数辨识及荷电状态估计研究[D]. 西安理工大学, 2019.

[17] 田茂飞, 安治国, 陈星等. 基于在线参数辨识和 AEKF 的锂电池 SOC 估计[J]. 储能科学与技术, 2019, 8(04): 745-750.

[18] 高文凯, 郑岳久, 许霜霜等. 基于增量误差的卡尔曼滤波算法全区间荷电状态估计[J]. 电源学报, 2019, 17(05): 162-169.

[19] Wei J, Chen C, Dong G. Global sensitivity analysis for impedance spectrum identification of lithium-ion batteries using time-domain response[J]. IEEE Transactions on Industrial Electronics, 2022, 70(4): 3825-3835.

[20] Dong G, Chen Z, Wei J. Sequential Monte Carlo filter for state-of-charge estimation of lithium-ion batteries based on auto regressive exogenous model[J]. IEEE Transactions on Industrial Electronics, 2019, 66(11): 8533-8544.

[21] Wang Q K, He Y J, Shen J N, et al. State of charge-dependent polynomial equivalent circuit modeling for electrochemical impedance spectroscopy of lithium-ion batteries[J]. IEEE Transactions on Power Electronics, 2017, 33(10): 8449-8460.

[22] 陈晓辉, 周骏, 蒋超. 遗传算法优化理论在航空锂电池 SOC 测算中的应用[J]. 科技创新与生产力, 2024, 45(05): 116-120.

[23] Wang Y, Gao G, Li X, et al. A fractional-order model-based state estimation approach for lithium-ion battery and ultra-capacitor hybrid power source system considering load trajectory[J]. Journal of Power Sources, 2020, 449: 227543.

[24] 宋春宁, 苏有平, 莫伟县等. 基于 COA-ASRCKF 的单液流锌镍电池 SOC 估计[J]. 电池, 2021, 51(04): 351-355.

[25] Hamida M A, El-Sehiemy R A, Ginidi A R, et al. Parameter identification and state of charge estimation of Li-Ion batteries used in electric vehicles using artificial hummingbird optimizer[J]. Journal of Energy Storage, 2022, 51: 104535.

[26] 段双明, 张胜利. 基于自适应多层 RLS 的锂离子电池参数辨识[J]. 储能科学与技术, 2024, 13(02): 712-720.

[27] 王郑, 卢昊, 程静等. 基于 FFRLS 和 GSAPF 的锂电池剩余电量估计[J]. 装备机械, 2024, (03): 78-81+72.

[28] 赵转, 曹以龙, 杜君莉等. 遗忘因子递推最小二乘法辨识锂离子电池参数[J]. 电池, 2023, 53(06): 629-633.

中国知网 https://www.cnki.net

[29] Liu D, Wang S, Fan Y, et al. State of energy estimation for lithium-ion batteries using adaptive fuzzy control and forgetting factor recursive least squares combined with AEKF considering temperature[J]. Journal of Energy Storage, 2023, 70: 108040.

[30] 葛科. 基于 AFFRLS-AEKF 的电池 SOC 估计方法[J]. 信息技术与信息化, 2024, (12): 179-185.

[31] 范兴明, 封浩, 张鑫. 最小二乘算法优化及其在锂离子电池参数辨识中的应用[J]. 电工技术学报, 2024, 39(05): 1577-1588.

[32] Xie Y, Chen N, Chen J, et al. Co-estimation of state of charge and model parameters for lithium-ion batteries based on variational Bayesian under time-varying noise and temperature conditions[J]. Journal of Energy Storage, 2024, 96: 112600.

[33] 高昕,韩嵩. 基于分数阶模型的锂离子电池 SOC 与 SOH 协同估计[J]. 电源技术, 2021, 45(09): 1140-1143+1208.

[34] Lin X, Tang Y, Ren J, et al. State of charge estimation with the adaptive unscented Kalman filter based on an accurate equivalent circuit model[J]. Journal of Energy Storage, 2021, 41: 102840.

[35] 李超凡, 杨林. 基于电化学阻抗谱的锂离子电池荷电状态估计[J]. 电源技术, 2024, 48(12): 2404-2409.

[36] Peng S, Miao Y, Xiong R, et al. State of charge estimation for a parallel battery pack jointly by fuzzy-PI model regulator and adaptive unscented Kalman filter[J]. Applied energy, 2024, 360: 122807.

[37] Xiao D, Li B, Shan J, et al. SOC estimation of vanadium redox flow batteries based on the ISCSO-ELM algorithm[J]. ACS omega, 2023, 8(48): 45708-45714.

[38] Yao Q, Lu D D C, Lei G. Rapid open-circuit voltage measurement method for lithium-ion batteries using one-cycle bipolar-current pulse[J]. IEEE Journal of Emerging and Selected Topics in Industrial Electronics, 2020, 2(2): 132-141.

[39] Wu S L, Chen H C, Tsai M Y. AC Impedance-based Online State-of-charge Estimation for Li-ion Batteries[J]. Sensors & Materials, 2018, 30(3): 539-550.

[40] 崔相东, 黄彦淇, 邬小玫. 锂电池剩余电量估算方法及应用研究综述[J]. 电子测量技术, 2024, 47(20): 41-59.

[41] Lashway C R, Mohammed O A. Adaptive battery management and parameter estimation through physics-based modeling and experimental verification[J]. IEEE Transactions on Transportation Electrification, 2016, 2(4): 454-464.

[42] Wang Q K, He Y J, Shen J N, et al. State of charge-dependent polynomial equivalent circuit

中国知网 https://www.cnki.net

modeling for electrochemical impedance spectroscopy of lithium-ion batteries[J]. IEEE Transactions on Power Electronics, 2017, 33(10): 8449-8460.

[43] Nejad S, Gladwin D T, Stone D A. A systematic review of lumped-parameter equivalent circuit models for real-time estimation of lithium-ion battery states[J]. Journal of Power Sources, 2016, 316: 183-196.

[44] 夏天, 刘代飞, 岳家辉等. 基于蜣螂算法优化卡尔曼滤波的锂离子电池模型参数辨识[J]. 中国电力, 2025, 58(01): 196-204.

[45] Wang J, Meng J, Peng Q, et al. Lithium-ion battery state-of-charge estimation using ele ctrochemical model with sensitive parameters adjustment[J]. Batteries, 2023, 9(3): 180.

[46] 丁洁, 姚建鑫, 万佑红等. 基于加权多新息H∞滤波的锂离子电池SOC估计[J]. 电池, 2020, 50(05): 432-435.

[47] Zong Y, Su S, Gao Y, et al. An improved attitude estimation algorithm for suppressing magnetic vector disturbance based on extended Kalman filter[J]. Measurement Science and Technology, 2024, 35(4): 045006.

[48] Fariña B, Toledo J, Acosta L. Sensor fusion algorithm selection for an autonomous wheelchair based on EKF/UKF comparison[J]. International Journal of Mechanical Engineering and Robotics Research, 2023, 12(1): 1-7.

[49] Wang L, Han J, Liu C, et al. State of charge estimation of lithium-ion based on VFFRLS-noise adaptive CKF algorithm[J]. Industrial & Engineering Chemistry Research, 2022, 61(22): 7489-7503.

[50] Shiekh S S, Khan K L, Mir T N, et al. Analysis of Extended Kalman Filter for SOC Estimation in Lithium-ion Batteries[C]//2022 Second International Conference on Power, Control and Computing Technologies (ICPC2T). IEEE, 2022: 1-6.

[51] 刘秭杉, 孙立清. 锂离子电池模型参数和荷电状态联合估算算法[J]. 中国科技论文, 2019, 14(04): 410-416.

[52] Wang L, Lu D, Liu Q, et al. State of charge estimation for LiFePO4 battery via dual extended kalman filter and charging voltage curve[J]. Electrochimica Acta, 2019, 296: 1009-1017.

[53] 侯瑞磊. 基于 MIAUKF 算法的锂电池 SOC 与 SOH 联合估计[D]. 青岛大学, 2021.

[54] Jin S, Yang X, Wang C, et al. A novel robust back propagation neural networkdual extended Kalman filter model for state-ofcharge and state-of-health co-estimation of lithiumion batteries[C]//2023 IEEE PES Conference on Innovative Smart Grid Technologies-Middle East (ISGT Middle East). IEEE, 2023: 1-5.

中国知网 https://www.cnki.net

[55] Linghu J, Kang L, Liu M, et al. Estimation for state-of-charge of lithium-ion battery based on an adaptive high-degree cubature Kalman filter[J]. Energy, 2019, 189: 116204.

[56] Tian Y, Huang Z, Tian J, et al. State of charge estimation of lithium-ion batteries based on cubature Kalman filters with different matrix decomposition strategies[J]. Energy, 2022, 238: 121917.

[57] 朱浩, 段洋. 基于 ASRCKF 算法的锂电池 SOC 估算[J]. 机械设计与制造, 2021, (04): 53-55+61.

[58] Chen L, Yu W, Cheng G, et al. State-of-charge estimation of lithium-ion batteries based on fractional-order modeling and adaptive square-root cubature Kalman filter[J]. Energy, 2023, 271: 127007.

[59] Shi Z, Xu J, Wu M, et al. An improved adaptive square root cubature Kalman filter method for estimating state-of-charge of lithium-ion batteries[J]. Journal of Energy Storage, 2023, 72: 108245.

[60] 赵志康,钟勇,武强等. 宽温度下基于AFFRLS-ASECKF联合仿真的锂电池SOC估计[J/OL]. 重庆工商大学学报(自然科学版), 1-12.

[61] Xu Y, Chen X, Zhang H, et al. Online identification of battery model parameters and joint state of charge and state of health estimation using dual particle filter algorithms[J]. International Journal of Energy Research, 2022, 46(14): 19615-19652.

[62] 霍梦梦. 基于 PI 状态观测器的电池 SOC 估计算法的研究[D]. 湖南大学, 2019.

[63] Tong L, Gong M, Chen Y, et al. State of Health Estimation of Lithium-Ion Battery for Electric Vehicle Based on VMD-DBO-SVR Model[J]. Journal of The Electrochemical Society, 2024, 171(8): 080504.

[64] Ge D, Jin G, Wang J, et al. A novel data-driven IBA-ELM model for SOH/SOC estimation of lithium-ion batteries[J]. Energy, 2024, 305: 132395.

[65] Jiao M, Wang D, Qiu J. A GRU-RNN based momentum optimized algorithm for SOC estimation[J]. Journal of Power Sources, 2020, 459: 228051.

[66] 李嘉波, 魏孟, 叶敏等. 基于高斯过程回归的锂离子电池 SOC 估计[J]. 储能科学与技术, 2020, 9(01): 131-137.

[67] Tian J, Xiong R, Shen W, et al. State-of-charge estimation of LiFePO4 batteries in electric vehicles: A deep-learning enabled approach[J]. Applied Energy, 2021, 291: 116812.

[68] Li Y, Wang S, Chen L, et al. Research on state-of-charge estimation of lithium-ion batteries based on improved sparrow search algorithm-BP neural network[J]. International Journal of

中国知网 https://www.cnki.net

Electrochemical Science, 2022, 17(8): 220845.

[69] 寇发荣, 杨天祥, 罗希等. 基于 ISSA-ELM 算法的锂电池 SOC 估计[J/OL]. 电源学报, 1-8.

[70] Tian Y, Lai R, Li X, et al. A combined method for state-of-charge estimation for lithium-ion batteries using a long short-term memory network and an adaptive cubature Kalman filter[J]. Applied Energy, 2020, 265: 114789.

[71] 于丽阳, 李仲夏. 煤矿用锂离子蓄电池设计及保护[J]. 中国矿业, 2024, 33(S2): 380-383.

[72] 陈雨墨. 基于自适应扩展卡尔曼滤波的锂电池 SOC 估计[D]. 东北电力大学, 2024.

[73] 陈豪, 王海滨, 李娜等. 储能锂电池组串现场容量试验方法研究[J]. 中国电力, 2014, 47(11): 89-94.

[74] 何山, 赵宇明, 田爱娜等. 基于充电片段和 PSO-BP 的锂电池 SOH 在线估计方法[J]. 电源技术, 2025, 49(02): 383-389.

[75] 王健俊, 陈豪, 付元承. 基于集成学习与数据驱动的电动汽车动力电池多维度故障预警[J]. 汽车安全与节能学报, 2024, 15(03): 368-378.

[76] 程贤福, 李晓静, 刘霏霏等. 基于温变 RC 模型与 SMFEKF 算法的电池 SOC 估计[J]. 湖南大学学报(自然科学版), 2024, 51(12): 57-66.

[77] 葛科. 基于 PSO-FEKF 的二阶分数阶锂离子电池 SOC 估计[J]. 中国新技术新产品, 2025, (03): 1-7.

[78] 宋海飞, 王乐红, 原义栋等. 基于改进自适应卡尔曼滤波算法的锂离子电池荷电状态估计[J]. 电力系统保护与控制, 2024, 52(20): 72-82.

[79] 袁建华, 刘雅萍, 赵子玮等. 基于 IGWO-PF 算法的无人机锂电池 SOC 估计[J]. 储能科学与技术, 2022, 11(05): 1601-1607.

[80] 许耀辉, 张丽霞, 刘大勇等. 基于二阶 RC 网络模型的 UKPF-VFFRLS 电池 SOC 预测估计[J]. 电源技术, 2023, 47(05): 644-649.

[81] WANG S, LU S, CHEN Z, et al. SOC Estimation of Six-Wheeled-Legged Robot Battery Based on FFRLS-AEKF[J]. Transactions of Beijing institute of Technology, 2022, 42(3): 271-278.

[82] Ndzana N D M, Nelem A T, Abanda Y A, et al. Lithium-ion point-of-care ultrasound battery joint state of charge estimation[J]. Scientific African, 2024, 24: e02232.

[83] 徐保荣, 王兴成, 张齐等. 自适应扩展卡尔曼滤波电池荷电状态估算方法[J]. 哈尔滨工业大学学报, 2021, 53(07): 92-98.

[84] 卢庆春, 张俊, 许沛东等. 考虑量测相关性的容积卡尔曼滤波动态状态估计[J]. 电测与仪表, 2022, 59(10): 161-167+200.

[85] 相飞华, 王杰贵. 基于改进 SRCKF 的固定单站无源定位算法[J]. 探测与控制学报, 2022,

中国知网 https://www.cnki.net

44(01): 29-33

[86] 朱浩, 段洋. 基于 ASRCKF 算法的锂电池 SOC 估算[J]. 机械设计与制造, 2021, (04): 53-55+61.

[87] 段文献. 锂离子电池状态估计与剩余使用寿命预测的研究[D]. 吉林大学, 2023.

中国知网 https://www.cnki.net