第46卷 第12期
2025年12月

太 阳 能 学 报
ACTA ENERGIAE SOLARIS SINICA

Vol. 46, No. 12
Dec., 2025

DOI:10.19912/j.0254-0096.tynxb.2025-0830 文章编号:0254-0096(2025)12-0011-11

基于SUKF-EKF融合的锂电池状态估计方法

王期文[1], 盛 强[1], 何玉财[2]

(1. 湖州职业技术学院新能源工程与汽车学院, 湖州 313099; 2. 常州大学生物与食品工程学院, 常州 213164)

摘 要: 针对锂离子电池状态估计中扩展卡尔曼滤波(EKF)精度不足及参数变化适应性差的问题,提出一种通过EKF实现电池参数的在线辨识与更新,同时融合滑模观测器(SMO)与无迹卡尔曼滤波(UKF)的锂电池状态估计方法(SUKF)。该方法构建双层时间尺度协同估计架构,利用EKF进行电池参数在线识别并估计SOH,同时结合SMO的鲁棒特性与UKF的非线性处理能力实现SOC高精度估计。通过高速公路燃效测试工况、新型欧洲行驶周期与城区动态驾驶循环3种代表性环境进行验证,结果表明,融合算法SOC估计平均误差分别为0.13%、0.25%和0.14%,最大误差控制在0.46%以内,相比传统EKF算法精度提升超过85%;SOH估计在不同复杂度工况下平均误差为0.02%~0.16%,最大误差不超过0.53%;在5%噪声强干扰环境下,算法仍保持良好的估计精度和收敛性能。随着工况复杂度增加,融合算法性能优势更为明显,显著提高了电池状态估计的准确性和鲁棒性,为动力电池管理系统提供了有效解决方案。

关键词: 锂离子电池; 状态估计; 滑模观测器; 无迹卡尔曼滤波; 荷电状态; 健康状态

中图分类号: TM912 **文献标志码**: A

0 引 言

电动汽车与储能系统的快速发展使锂离子电池管理技术面临更高要求,其中电池荷电状态(state of charge, SOC)和健康状态(state of health, SOH)作为电池电气性能的双重核心指标,构成了电池组状态监测的基础框架,精确估算SOC与SOH能提升电池组使用效率,延长其服役寿命,还能确保系统运行的可靠性与安全性[1]。然而,这两项关键参数无法通过直接测量获取,必须依靠相关物理量采集和专门算法进行计算。

当前,SOC/SOH估算方法主要分为定义特性法、数据驱动法和基于等效电路模型的算法3类[2]。定义特征法虽原理简明但面临测量偏差累积问题,数据驱动方法包括传统机器学习算法如支持向量机[3]、BP神经网络[4],以及深度学习算法[5]等。这些方法能直接从历史数据中学习电池状态与可测量参数之间的复杂非线性映射关系,无需建立精确的物理模型。然而,数据驱动方法存在明显局限性:需大量覆盖各种工况和老化状态的训练数据;模型泛化能力受限,对训练集外的新工况适应性差;缺乏物理可解释性,难以保证极端工况下的估计可靠性。相比之下,基于等效电路模型的方法具有明确的物理意义,但受限于模型精度和参数时变特性,然而,等效电路建模方法在解决电池状态监测问题上展现出一定优势[6]。考虑到锂电池内部电化学过程的非线性特征,非线性滤波算法在电池状态估计领域得到深入研究。扩展卡尔曼滤波器(extended Kalman filter, EKF)通过局部线性化处理非线性系统,但在SOC低于20%或高于90%等强非线性区域存在精度损失,误差可达5%~8%[7]。为克服线性化带来的截断误差,无迹卡尔曼滤波(unscented Kalman filter, UKF)利用Sigma点采样技术捕捉高阶统计特性,避免了线性化带来的截断误差,在强非线性区域的估计误差可降至1%~3%,但其计算复杂度约为EKF的2.5倍,限制了其在资源受限系统中的应用[8]。此外,滑模观测器(sliding mode observer, SMO)对系统参数扰动具有鲁棒抗干扰能力和较高计算效率,在动态工况下表现出特定优势。研究表明,即使在电流波动达到150%额定值的恶劣工况下,SMO仍能将SOC估计误差控制在2.5%以内[9-10]。

在电动汽车实际运行过程中,由于电池状态实时估计计算复杂、计算量大,单一算法在有限时间内易产生较大误差甚至失效,因此需将多种算法融合,构建混合算法以实现对电动汽车动力电池状态的精确估计[11]。研究结果显示,EKF在恒流充放电工况下误差约为1.2%[12],但其对复杂动态条件的适应性较弱。相比之下,UKF在变温环境下依然能保持较高估计精度,表现出较好的鲁棒性[13]。进一步地,为克服传统算法在温度变化条件下精度下降的问题,吕高等[14]提出一

收稿日期: 2025-05-14
基金项目: 湖州市科技计划项目(2024YZ10); 浙江省教育厅一般科研项目(Y202455633)
通信作者: 王期文(1988—), 男, 博士、副研究员, 主要从事储能电池管理及性能评估等方面的研究。wangqiwenyy@163.com

中国知网 https://www.cnki.net

种考虑温度影响的改进 UKF 算法，通过融合温度自适应滑模观测技术，有效提升了 SOC 估计在复杂热环境下的准确性与稳定性。为克服单一算法在 SOC 和 SOH 联合估计中的局限性，王志福等[15]提出多算法融合策略显著提高了电池状态估计的精度和抗噪声能力。多算法融合方法通过权重自适应机制发挥各算法的互补性。李心月等[16]构建融合估计策略，显著提高了锂离子电池荷电状态和健康状态的联合估算精度，健康状态估算偏差控制在 6% 以内。进一步的研究结果表明，在-20~60 ℃的宽温度范围内，融合算法依然能保持较高的估计精度，其精度衰减仅约 15%，而单一算法在极端温度条件下的精度衰减高达约 40%[17]。此外，孙玉树等[18]基于深度学习的融合方法证明，相比单一算法，融合算法精度提升了 5% 的同时，计算效率提高了 37.03%；董磊等[19]、李谦等[20]基于等效电路模型通过算法改进对 SOC 和 SOH 进行联合估计，实验结果充分证明了算法改进带来的精度显著提升。

基于以上分析，虽然等效电路模型方法在动力电池应用中具备较高应用价值，但仍面临参数识别偏差与模型精度不足等问题，单一算法在强非线性区域精度损失显著。本文在上述研究的基础上，提出一种基于 SMO-UKF 融合的锂电池状态估计方法，SMO 可有效应对电流波动，UKF 避免 EKF 线性化带来的截断误差，该方法利用 EKF 进行电池参数在线识别，获取模型参数变化趋势并估计 SOH，同时通过 SMO 与 UKF 的融合实现 SOC 估计。通过构建双层结构充分利用各算法优点，即利用 EKF 的参数自适应能力用于电池模型参数更新，同时结合 SMO 的鲁棒特性与 UKF 的非线性处理能力相互补充（sliding-mode unscented Kalman filter，SUKF），实现动力电池 SOC/SOH 状态的实时估计。

1 锂电池实验平台搭建与建模

1.1 实验平台搭建

图 1 展示了本研究所用实验平台构成，测试全程在恒温环境下进行，控制室温稳定在 25 ℃。

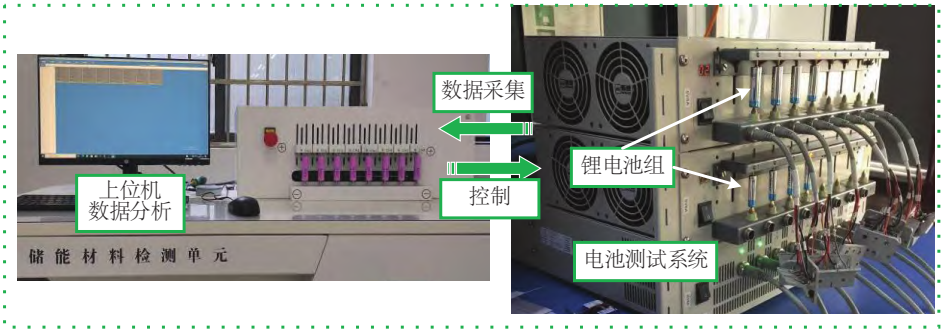


图1 电池测试实验平台

Fig. 1 Battery testing experimental platform

实验选用 ICR18650-26H 规格锂电池作为研究对象，其核心特性参数见表 1 数据。

表 1 ICR18650-26H 锂离子电池参数

Table 1 Parameters of ICR18650-26H lithium-ion battery

标称容量/Ah	标称电压/V	充电截止电压/V	放电截止电压/V
2.60	3.63	4.20	2.75

1.2 等效电路模型

锂离子电池等效电路模型凭借其简洁构造与高效运算特性，在适当参数配置下能精确表征电池电气行为。采用并联电阻和电容（resistor and capacitor，RC）结构可有效刻画电池动态极化特性，模型阶数与仿真精度呈正相关，但同时计算负担亦随之攀升[11]。权衡建模精确性与实施难度，本文基于图 2 展示的二阶电路等效模型构建理论体系，为后续参数辨识奠定理论基础。

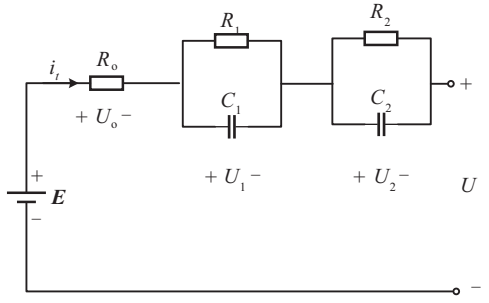


图2 二阶等效电路模型

Fig. 2 Second-order equivalent circuit model

基于二阶等效电路模型，根据基尔霍夫定律得：

$$\begin{cases} U_1 = -\dfrac{1}{R_1 C_1} U_1 + \dfrac{1}{C_1} I_t \\ U_2 = -\dfrac{1}{R_2 C_2} U_2 + \dfrac{1}{C_2} I_t \\ U_{oc} = U + R_0 I_t + U_1 + U_2 \end{cases} \tag{1}$$

式中：U_1、U_2——电化学极化电容 C_1 和浓度极化电容 C_2 对应

中国知网 https://www.cnki.net

的电压，V；R_1——对应电化学极化电阻，mΩ；C_1——对应电化学极化电容，kF；I_t——t 时刻的工作电流，A，在放电过程中为正，在充电过程中为负；R_2——浓度极化电阻，mΩ；C_2——浓度极化电容，kF；U_{oc}——开路电压，V，与 SOC 有关；U——端电压，V；R_0——欧姆电阻，mΩ；。

在电池等效模型验证、参数辨识与 SOC 估算过程中，开路电压（open-circuit voltage，OCV）与 SOC 关系曲线是关键依据。获取此特性曲线需进行完整放电实验，随后应用测得数据对 OCV 及对应 SOC 进行 8 次多项式拟合，拟合函数关系式如式（2）所示，拟合曲线如图 3 所示。通过均方根误差公式验证拟合精度，放电状态下误差仅为 0.0813%，表明曲线拟合具备高精确性。

$$U_{oc} = 3.45 - 1.61s + 32.51s^2 - 188.88s^3 + 552.04s^4 - 903.90s^5 + 847.62s^6 - 426.80s^7 + 89.74s^8 \tag{2}$$

式中：s——SOC。

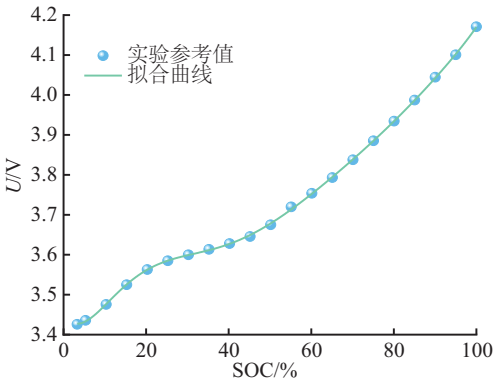


图3　OCV-SOC拟合曲线

Fig. 3　OCV-SOC fitting curve

2　参数辨识

基于二阶 RC 等效电路模型，根据 EKF 算法建立非线性离散系统的状态空间方程，方程为：

$$\begin{cases} \boldsymbol{x}_{k+1} = \boldsymbol{A}_k \boldsymbol{x}_k + \boldsymbol{B}_k u_k + \boldsymbol{w}_k \\ y_k = \boldsymbol{C}_k \boldsymbol{x}_k + \boldsymbol{D}_k u_k + v_k \end{cases} \tag{3}$$

$$\begin{cases} \boldsymbol{A}_k = \begin{bmatrix} 1 & 0 & 0 \\ 0 & e^{-\frac{\Delta t}{R_1 C_1}} & 0 \\ 0 & 0 & e^{-\frac{\Delta t}{R_2 C_2}} \end{bmatrix} \\ \boldsymbol{B}_k = \left[-\frac{\eta \Delta t}{Q_n}, R_1\left(1 - e^{-\frac{\Delta t}{R_1 C_1}}\right), R_2\left(1 - e^{-\frac{\Delta t}{R_2 C_2}}\right) \right]^{\mathrm{T}} \\ \boldsymbol{C}_k = \left[-1 \quad -1 \quad \frac{\partial U_{oc}}{\partial s} \right] \\ \boldsymbol{D}_k = -R_0 \end{cases} \tag{4}$$

式中：$\boldsymbol{A}_k$、$\boldsymbol{B}_k$——状态方程系数矩阵；$\boldsymbol{x}_k$——状态向量，$\boldsymbol{x}_k = [U_{1,k}\ U_{2,k}\ s_k]^{\mathrm{T}}$（其中 s_k 为 t_k 时刻电池荷电状态，$U_{1,k}$ 为电化学极化电压，$U_{2,k}$ 为浓度极化电压，V）；u_k——t_k 时刻测量得到的端电压，V；w_k、v_k——过程噪声和测量噪声，且相关独立，均为白噪声；y_k——k 时刻的观测端电压，V；$\boldsymbol{C}_k$、$\boldsymbol{D}_k$——观测方程系数矩阵；Δt——采样时间，s。

采用最小二乘法对电池等效电路模型进行离线参数辨识[21]，辨识结果为：$R_0 = 28.4$ mΩ，$R_1 = 16.4$ mΩ，$R_2 = 29.8$ mΩ，$C_1 = 3.3$ kF，$C_2 = 59.9$ kF。为检验所构建模型可靠性与准确程度，将离线辨识的参数代入式（1）和式（2）进行模拟分析。比较模型输出电压与实测数据后发现，二阶 RC 电池等效电路展现较高精度与动态响应特性，电压对比结果如图 4 所示。

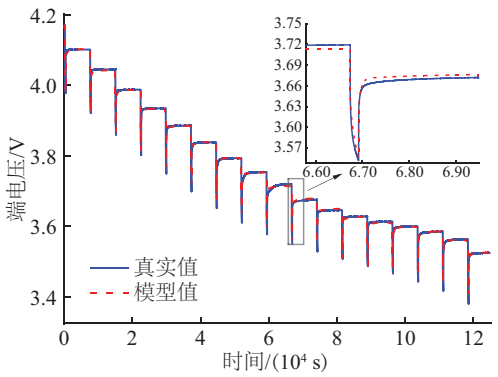


图4　模型端电压与真实值对比

Fig. 4　Comparison between model terminal voltage and actual measured values

3　SUKF-EKF联合估计SOC和SOH

结合状态方程式（3）和参数更新机制，构建双时间尺度的非线性动态系统：

$$\begin{cases} \boldsymbol{x}_{k,l+1} = f(\boldsymbol{x}_{k,l}, \boldsymbol{\theta}_k, \boldsymbol{u}_{k,l}) + w_{k,l} \\ \boldsymbol{y}_{k,l} = g(\boldsymbol{x}_{k,l}, \boldsymbol{\theta}_k, \boldsymbol{u}_{k,l}) + v_{k,l} \end{cases} \tag{5}$$

式中：$\boldsymbol{\theta}_k$——参数向量，$\boldsymbol{\theta}_k = [R_0,\ R_1,\ C_1,\ R_2,\ C_2,\ Q_k]^{\mathrm{T}}$（其中 Q_k 为 k 时刻电池容量，Ah）；$f(\cdot)$——状态转移函数；$g(\cdot)$——非线性测量函数；k——系统参数宏观采样指标，60 s；l——系统状态微观采样尺度，采样周期为 1 s，$1 \leqslant l \leqslant L$（其中 L 为宏观尺度）。

3.1　SUKF算法

SMO 是一种具有强鲁棒性的非线性状态观测工具，能有效抵抗模型参数扰动，显著降低系统参数变化与外界干扰对状态估计的影响[22]。滑模控制理论的核心机制在于设计适当滑动模态，使系统状态在有限时间内到达该模态并沿其稳定运动，从而对参数波动和外部扰动表现出较强不敏感性。相比之下，UKF 通过 Sigma 点采样技术保留系统非线性特性，在噪声环境中表现出优良处理能力，但对基础模型精度依赖较高。

本文提出的联合算法实现了两种技术优势的互补：首先将经典 SMO 设置为前端状态评估器，充分利用其对建模误差的固有鲁棒性，有效抑制系统参数不确定性和外部干扰对状

中国知网　https://www.cnki.net

态预测的影响;随后,将 SMO 输出作为 UKF 的先验信息输入,构建序贯结构,有效缓解因模型不精确导致的滤波性能退化或发散现象。这种串级结构不仅继承了 SMO 的抗干扰能力,同时吸收了 UKF 处理非线性系统的优势,实现了状态估计性能的协同提升。基于 SUKF 的 SOC 估计实现过程如下:针对式(5)离散状态方程,忽略系统过程噪声和观测噪声,构建的离散滑模观测器[23],如式(6)所示,用 l 代表系统状态采样时间间隔,该参数直接影响观测器动态响应特性,合理配置可实现观测速度与稳定性的最优平衡。

$$\begin{cases}\hat{\boldsymbol{x}}_{k,l+1}=\boldsymbol{A}_{k,l}\hat{\boldsymbol{x}}_{k,l}+\boldsymbol{B}_{k,l}\boldsymbol{u}_{k,l}+G\left(\boldsymbol{y}_{k,l}-\hat{\boldsymbol{y}}_{k,l}\right)+\lambda\mathrm{sng}\left(\dfrac{\boldsymbol{y}_{k,l}-\hat{\boldsymbol{y}}_{k,l}}{\delta}\right)\\ \hat{\boldsymbol{y}}_{k,l}=\boldsymbol{C}_{k,l}\hat{\boldsymbol{x}}_{k,l}+\boldsymbol{D}_{k,l}\boldsymbol{u}_{k,l}\end{cases}\tag{6}$$

SUKF 算法迭代过程如下:

1)确定状态值初始值 $x_{0,0}$ 和后验状态误差协方差初始值 $P_{0,0}$。

2)计算采样点

$$\begin{cases}x_{k,l}^{0}=\hat{x}_{k,l}\\ x_{k,l}^{i}=x_{k,l}+\sqrt{(n+\lambda)P_{k,l-1}},i=1,2,\cdots,n\\ x_{k,l}^{i}=x_{k,l}-\sqrt{(n+\lambda)P_{k,l-1}},i=n+1,n+2,\cdots,2n\end{cases}\tag{7}$$

式中:n——状态向量的长度,本文中状态向量长度为 3。

权值计算:

$$\begin{cases}W_m^0=\dfrac{\lambda}{n+\lambda}\\ W_c^0=\dfrac{\lambda}{n+\lambda}+1-\alpha^2+\beta\\ W_m^i=W_c^i=\dfrac{1}{2(n+\lambda)},\ i=1,2,\cdots,2n\end{cases}\tag{8}$$

式中:α=0.01;k_i=0;β=2;$\lambda=\alpha^2(n+k_i)-n$。

3)先验状态方程

$$\boldsymbol{x}_{k,l+1}^{i}=\boldsymbol{A}_{k,l}\boldsymbol{x}_{k,l}^{i}+\boldsymbol{B}_{k,l}\boldsymbol{I}_{k,l}+G\left(\boldsymbol{U}_{k,l}-\hat{\boldsymbol{U}}_{k,l}\right)+\lambda\mathrm{sng}\left(\frac{\boldsymbol{U}_{k,l}-\hat{\boldsymbol{U}}_{k,l}}{\delta}\right)\tag{9}$$

4)更新先验状态值 $\bar{x}_{k,l+1}$ 和系统方差预测值 $\boldsymbol{P}_{xx}$。

$$\bar{x}_{k,l+1}=\sum_{i=0}^{2n}W_m^i x_{k,l+1}^i\tag{10}$$

$$\boldsymbol{P}_{xx}=\sum_{i=0}^{2n}[W_c^i(x_{k,l+1}^i-\bar{x}_{k,l+1})(x_{k,l+1}^i-\bar{x}_{k,l+1})^{\mathrm{T}}]+\boldsymbol{Q}_{k,l+1}\tag{11}$$

式中:$\boldsymbol{Q}_{k,l+1}$——系统噪声协方差矩阵。

5)更新观测值 $\hat{y}_{k,l+1}$ 和观测方差预测值 $\boldsymbol{P}_{yy}$。

$$\hat{y}_{k,l+1}=\sum_{i=0}^{2n}W_m^i y_{k,l+1}^i\tag{12}$$

$$\boldsymbol{P}_{yy}=\sum_{i=0}^{2n}(W_c^i(y_{k,l+1}^i-\hat{y}_{k,l+1})(y_{k,l+1}^i-\hat{y}_{k,l+1})^{\mathrm{T}})+R_{k,l+1}\tag{13}$$

6)更新协方差 $\boldsymbol{P}_{xy}$,计算卡尔曼增益 $\boldsymbol{K}_{k,l}$ 和后验状态值 $\hat{x}_{k,l+1}$,进而更新后验状态误差协方差 $\boldsymbol{P}_{k,l}$。

$$\boldsymbol{P}_{xy}=\sum_{i=0}^{2n}W_c^i(x_{k,l}^i-\bar{x}_{k,l+1})(y_{k,l}^i-\hat{y}_{k,l+1})^{\mathrm{T}}\tag{14}$$

$$\boldsymbol{P}_{xy}=\sum_{i=0}^{2n}W_c^i(x_{k,l}^i-\bar{x}_{k,l+1})(y_{k,l}^i-\hat{y}_{k,l+1})^{\mathrm{T}}\tag{15}$$

$$\boldsymbol{K}_{k,l}=\frac{\boldsymbol{P}_{xy}}{\boldsymbol{P}_{yy}}\tag{16}$$

$$\hat{x}_{k,l+1}=\bar{x}_{k,l+1}+\boldsymbol{K}_{k,l}(y_{k,l+1}-\hat{y}_{k,l+1})\tag{17}$$

$$\boldsymbol{P}_{k,l}=\boldsymbol{P}_{xx}-\boldsymbol{K}_{k,l}\boldsymbol{P}_{xy}^{\mathrm{T}}\tag{18}$$

3.2 在线参数辨识

基于电池参数 θ_k 变化缓慢与状态变化迅速的时间尺度差异特性,在线参数辨识技术通过实时采集锂电池前一时刻的电流与电压数据,进行动态辨识计算,获取每个时刻最新的模型特征参数,能使电池模型参数随工况动态调整,实现自适应更新,从而提高模型精度和状态估计准确性。

EKF 在线参数辨识具体算法流程如下:

为构建基于 EKF 算法的锂离子电池参数在宏观尺度在线辨识系统,需建立完整的状态空间表达,如式(19)所示。

$$\begin{cases}\boldsymbol{\theta}_k=\boldsymbol{\theta}_{k-1}+\boldsymbol{\rho}_{k-1}\\ \boldsymbol{y}_k=\boldsymbol{C}_k^{\theta}\boldsymbol{\theta}_k+\boldsymbol{d}_k\end{cases}\tag{19}$$

式中:$\boldsymbol{\rho}_{k-1}$——参数过程噪声矩阵,其协方差矩阵为 $\boldsymbol{Q}_{\theta}$;$\boldsymbol{d}_k$——测量噪声,其协方差矩阵为 $\boldsymbol{R}_{\theta}$。

具体步骤如下:

第 1 步:初始化

$$\begin{cases}\hat{\boldsymbol{\theta}}_0=E(\boldsymbol{\theta}_0)\\ P_{\boldsymbol{\theta}_0}=E\left[\left(\boldsymbol{\theta}_0-\hat{\boldsymbol{\theta}}_0\right)\left(\boldsymbol{\theta}_0-\hat{\boldsymbol{\theta}}_0\right)^{\mathrm{T}}\right]\end{cases}\tag{20}$$

第 2 步:时间更新

$$\begin{cases}\hat{\boldsymbol{\theta}}_k^{-}=\hat{\boldsymbol{\theta}}_{k-1}\\ \boldsymbol{P}_{\boldsymbol{\theta}_0}^{-}=\boldsymbol{P}_{\boldsymbol{\theta}_{k-1}}+\boldsymbol{Q}_{k-1}^{\theta}\end{cases}\tag{21}$$

第 3 步:卡尔曼增益计算 $\boldsymbol{K}_k$

$$\boldsymbol{K}_k=\boldsymbol{P}_{\boldsymbol{\theta}_k}^{-}(\boldsymbol{C}_k^{\theta})^{\mathrm{T}}\left[\boldsymbol{C}_k^{\theta}\boldsymbol{P}_{\boldsymbol{\theta}_k}^{-}(\boldsymbol{C}_k^{\theta})^{\mathrm{T}}+\boldsymbol{R}_k^{\theta}\right]^{-1}\tag{22}$$

第 4 步:测量更新

$$\begin{cases}\hat{\boldsymbol{\theta}}_k=\hat{\boldsymbol{\theta}}_k^{-}+\boldsymbol{K}_k\left(y_k-\boldsymbol{C}_k^{\theta}\hat{\boldsymbol{\theta}}_k^{-}\right)\\ \boldsymbol{P}_{\boldsymbol{\theta}_k}=(\boldsymbol{I}-\boldsymbol{K}_k\boldsymbol{C}_k^{\theta})\boldsymbol{P}_{\boldsymbol{\theta}_0}^{-}\end{cases}\tag{23}$$

式中:$\boldsymbol{I}$——单位矩阵。

3.3 SUKF-EKF 的联合估计 SOC 和 SOH

锂电池 SUKF-EKF 联合算法流程图如图 5 所示,采用多时域协同估计理念,初始化阶段依据离线识别数据完成 EKF 参数设定,同时实现 SMO-UKF 模块初值配置。运行中,宏观层 EKF 算法先执行时间更新,随后将先验估算结果传入 SMO-UKF 单元,启动微观范围 SOC 计算流程。微观尺度 l 以步长为 1 递增,即 $l=1,2,\cdots,L$,记为 $l=l$:1,当微观尺度 l 累计至阈值 L 时,标志着一个完整宏观周期结束,此时系统

中国知网 https://www.cnki.net

通过尺度转换机制使宏观时间指标 k 推进至 $k+1$ 时刻，随后执行宏观尺度 EKF 参数估计的测量更新步骤，并将更新后结果反馈至时间更新环节，构成完整循环结构，根据当前电池容量与额定容量的百分比关系[24]计算 SOH，采样时间转换机制如式(24)所示。该联合算法可实现不同时间尺度计算单元间的参数与状态信息交换机制，使模型参数辨识与 SOC 评估过程相互影响，增强系统对电池动态特性变化的跟踪能力及估计准确性。

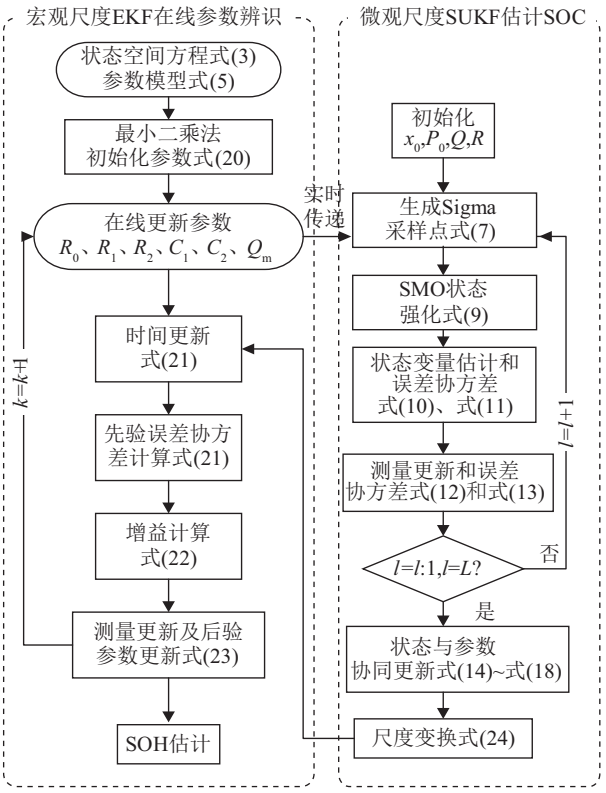


图5　SUKF-EKF算法流程

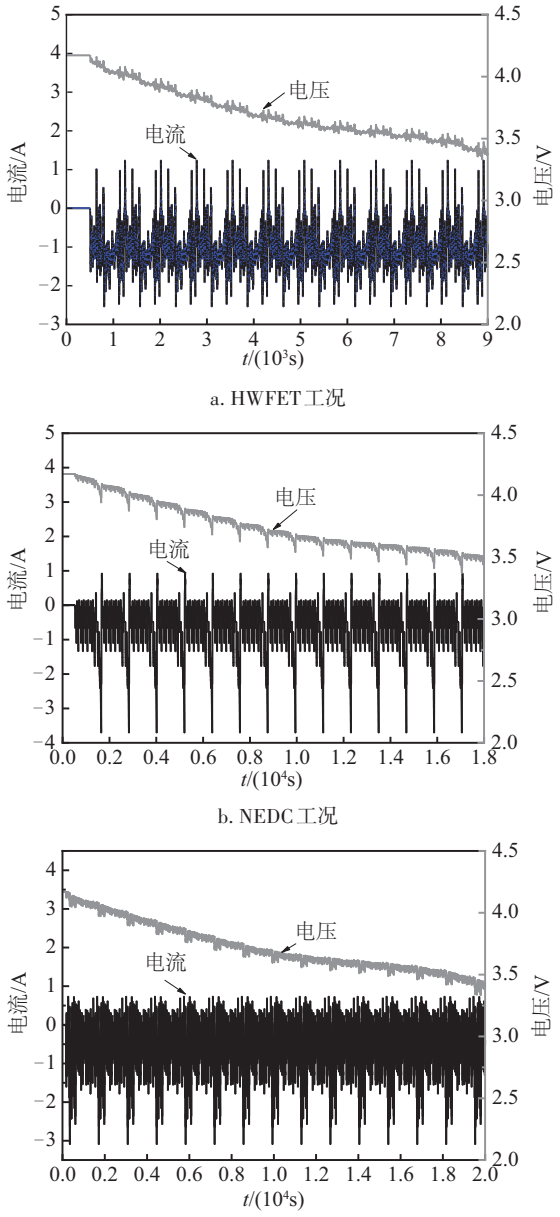
Fig. 5　Flow chart of SUKF-EKF algorithm

当 $l=L$ 时，转换到下一参数周期，完成从状态滤波器到参数滤波器的时间转换。

$$\begin{cases}\hat{\boldsymbol{\theta}}_k=\hat{\boldsymbol{\theta}}_{k,0:L},\boldsymbol{P}_{\theta_{k,0}}=\boldsymbol{P}_{\theta_{k-1,L}}\\ \hat{\boldsymbol{x}}_{k,0}=\hat{\boldsymbol{x}}_{k-1,L},\boldsymbol{P}_{x_{k,0}}=\boldsymbol{P}_{x_{k-1,L}}\\ y_{k,0}=y_{k-1,L}\end{cases}\tag{24}$$

4　仿真验证

为验证算法在实际工况下的性能，选取高速公路燃油测试循环(highway fuel economy test，HWFET)、新欧洲驾驶规程(new European driving cycle，NEDC)与城区动态行驶工况(urban dynamometer driving schedule，UDDS)作为代表性测试工况，测试曲线如图 6 所示。通过比较 SOC 估计精度，评估 SUKF-EKF 联合算法的在线参数辨识能力与电池状态估计准确性，同时利用该框架中的 EKF 模块实现 SOH 的监测。



a. HWFET工况

b. NEDC工况

c. UDDS工况

图6　测试工况曲线

Fig. 6　Testing condition curves

为定量评价算法性能，采用平均绝对误差(mean absolute error，MAE)、最大绝对误差(maximum absolute error，MAX)、运行时间(runtime，RT)和收敛时间(convergence time，CT)作为评价指标作为评价指标。其中，收敛时间定义为估计误差稳定到 1% 以内所需的时间。

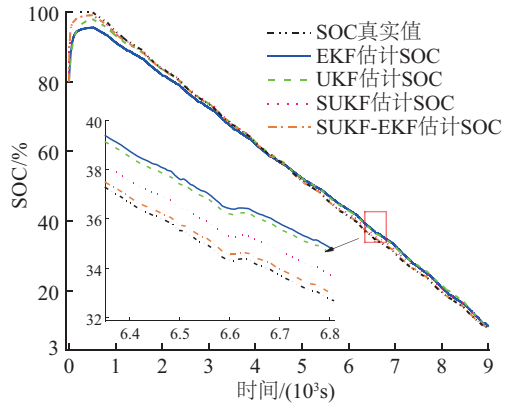
4.1　锂电池SOC估计精度验证

将 EKF 算法离线和在线辨识的模型参数代入 SUKF 算法中更新状态方程与观测方程系数，在每次迭代中对系统状态变量预测并更新，输出各时刻 SOC 估计值，并与采用离线辨识参数的 EKF、UKF 和 SUKF 方法对照分析。

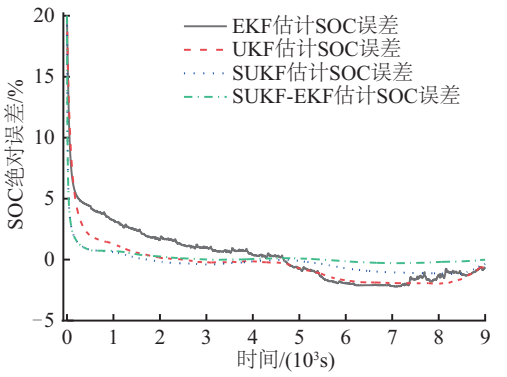
首先在 HWFET 工况下进行验证，如图 7 所示，在图 7a

中国知网　https://www.cnki.net

中，SUKF-EKF 方法的 SOC 估计曲线与真实值高度吻合，在局部放大区域(32%~40%)尤为明显，而其他算法均出现不同程度偏差。图 7b 展示了各算法在 HWFET 工况下的 SOC 估计误差曲线。EKF 算法初期收敛缓慢，前 500 s 误差维持在高位，整个过程中波动显著，中后期误差仍约为 1%，MAX 达到 2.11%，表现最弱。UKF 算法表现稍好，最大绝对误差为 2.00%。SUKF 方法表现更佳，收敛速度提高，约 200 s 内 MAE 降至 1% 以下，全程保持稳定估计水平，MAE 为 0.57%。



a. 不同算法估计SOC与真实SOC对比



b. 不同算法估计SOC误差的比较

图7 不同算法估计SOC的结果(HWFET工况)

Fig. 7 SOC estimation results of different algorithms (HWFET driving condition)

对 HWFET 工况下的 SOC 估计误差进行量化评价，如表 2 所示，分析表明，SUKF-EKF 方法 MAE 为 0.13%，MAX 为 0.29%，分别比 EKF 算法的 1.24% 和 2.11% 降低了约 89% 和 86%；SUKF-EKF 方法的 CT 为 370 s，短于传统 EKF 的 2747 s 和 UKF 的 1187 s，分别缩短了 86.5% 和 68.8%；在计算资源方面，SUKF-EKF 的 RT 为 1.16 s，虽略高于 EKF 的 0.23 s，算法在计算效率与精度之间达到了良好的平衡。在较简单工况下，融合方法已展现出显著优势。

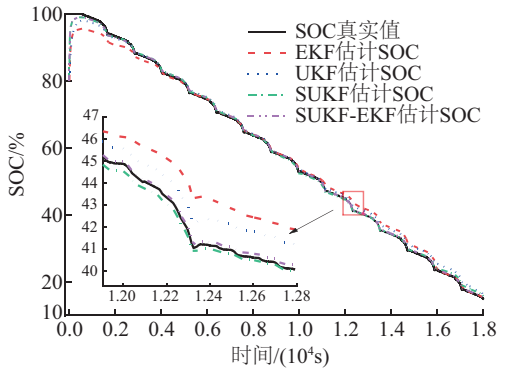
保持其他条件不变，进一步选用 NEDC 工况再次对比，如图 8 所示。在图 8a 中，局部放大图(40%~46%)清晰显示，随着负载波动加剧，EKF 和 UKF 算法在电流波动较大区域产生明显偏移，而 SUKF-EKF 方法保持高度跟踪精度。图 8b

表2 不同算法估计SOC比较(HWFET工况)

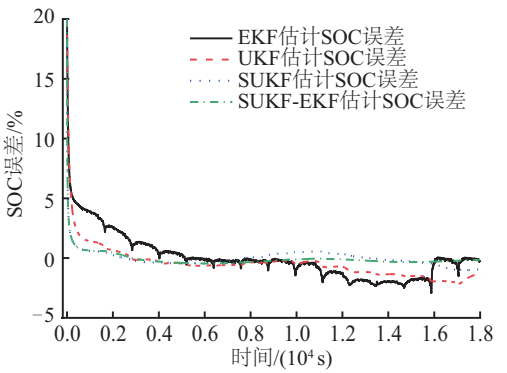
Table 2 Comparison of SOC estimation by different algorithms (HWFET driving condition)

算法	MAE/%	MAX/%	RT/s	CT/s
EKF	1.24	2.11	0.23	2747
UKF	1.01	2.00	0.72	1187
SUKF	0.57	1.18	0.96	622
SUKF-EKF	0.13	0.29	1.16	370

展示了 NEDC 工况下各算法 SOC 估计误差变化情况。EKF 算法起始误差最高，约 5%，收敛过程缓慢，全程波动明显，后期出现约 2% 负向偏移。UKF 方法初始下降较快，约 2000 s 达到稳定，后期同样呈负偏离趋势。SUKF 算法约 1000 s 内即进入低误差区间，稳定性明显提升。SUKF-EKF 融合方案效果最佳，收敛最快，误差控制在±0.5% 范围内，全程稳定。



a. 不同算法估计SOC与真实SOC对比



b. 不同算法估计SOC误差的比较

图8 不同算法估计SOC的结果(NEDC工况)

Fig. 8 SOC estimation results of different algorithms (NEDC driving condition)

对 NEDC 工况下 SOC 估计进行量化，如表 3 所示，融合方法的 MAE 和 MAX 分别为 0.25% 和 0.46%，相比 EKF 的 MAE 分别为 0.90% 和 2.93%，精度提升约 72% 和 84%。SUKF-EKF 的 CT 为 394 s，在所有对比方法中表现最优。相比 UKF 方法，收敛速度提升约 76%，显著缩短了参数 CT。综

中国知网 https://www.cnki.net

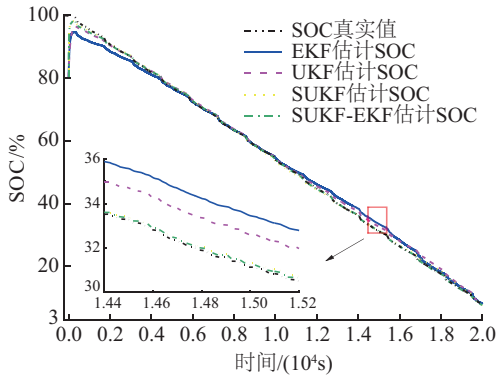
合收敛性能和估计精度，SUKF-EKF 在 NEDC 动态工况下展现出明显的综合优势。

表3　不同算法估计SOC比较（NEDC工况）

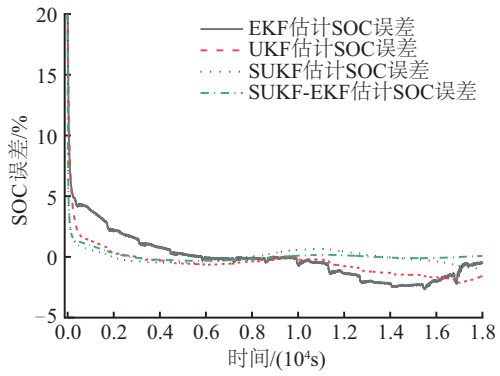
Table 3　Comparison of SOC estimation by different algorithms (NEDC driving condition)

算法	MAE/%	MAX/%	RT/s	CT/s
EKF	0.90	2.93	0.31	2856
UKF	0.83	2.25	1.48	1617
SUKF	0.37	1.01	1.89	850
SUKF-EKF	0.25	0.46	1.98	394

最后采用 UDDS 城市工况测试系统极限，该工况具有频繁启停、急剧加减速等典型城市驾驶特征，电流变化最为复杂多变，SOC 估计结果如图 9 所示。在图 9a 中，30%~36% 区间放大分析发现，EKF 和 UKF 算法已与真实值产生显著差距，而 SUKF 与 SUKF-EKF 表现接近但后者略优。在图 9b 中，EKF 算法初始误差最大，接近 10%，收敛过程延迟明显，全程波动较大，中后期出现 1%~2% 负偏差。UKF 方法起始表现较好，但后期同样呈现负向偏移。SUKF-EKF 融合算法性能最优，全程稳定在±0.5% 范围内。



a. 不同算法估计SOC与真实SOC对比



b. 不同算法估计SOC误差的比较

图9　不同算法估计SOC的结果（UDDS工况）

Fig. 9　SOC estimation results of different algorithms (UDDS driving condition)

表4误差统计表明，SUKF-EKF 的 MAE 和 MAX 分别为 0.14% 和 0.33%，较 EKF 算法的 0.96% 和 2.68% 提高超过 85% 和 87%。从收敛性能来看，SUKF-EKF 的 CT 为 406 s，相比 EKF 的 3249 s 和 UKF 的 1430 s 分别提升约 88% 和 72%，虽然 SUKF-EKF 的 RT 为 2.86 s，但其在估计精度和收敛速度方面的显著优势充分证明了算法的综合性能。

表4　不同算法估计SOC比较（UDDS工况）

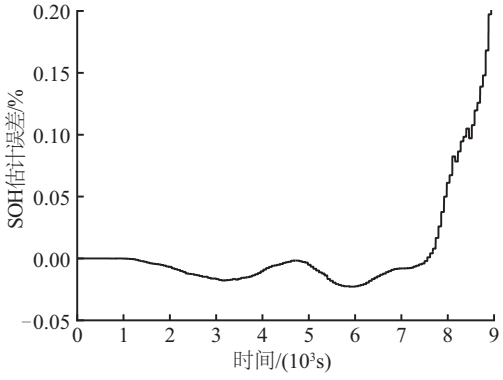
Table 4　Comparison of SOC estimation by different algorithms (UDDS driving condition)

算法	MAE/%	MAX/%	RT/s	CT/s
EKF	0.96	2.68	0.36	3249
UKF	0.80	2.16	2.21	1430
SUKF	0.40	0.94	2.44	985
SUKF-EKF	0.14	0.33	2.86	406

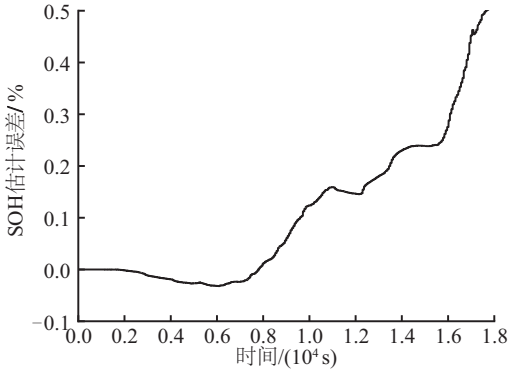
综合3类递增复杂度工况实验结果表明，随着测试工况变得更加复杂多变，本文提出的融合方法优势愈发明显。这主要归功于该方法有效结合了 EKF 参数自适应机制与 SUKF 处理非线性系统的优势，实现了对电池动态特性的准确把握，为电动车辆在各种实际道路工况下的电池管理提供了可靠解决方案。

4.2　锂电池SOH估计精度验证

图 10 展示了 SUKF-EKF 融合算法在 3 种工况下的 SOH 估计误差曲线。

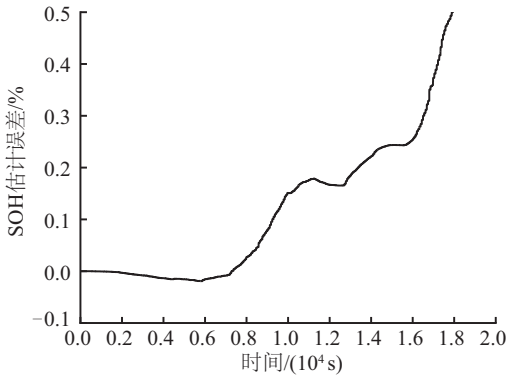


a. HWFET工况



b. NEDC工况

中国知网　https://www.cnki.net



c. UDDS工况

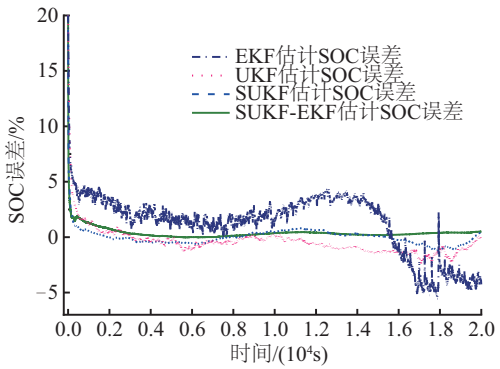
图10 不同工况下SUKF-EKF算法估计SOH误差

Fig. 10 SOH estimation errors of SUKF-EKF algorithm under different operating conditions

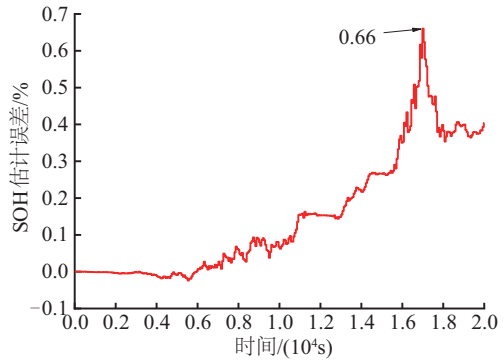
从图10a可看出，在HWFET工况下，SOH估计误差在0~6000 s内保持在±0.02%范围内波动，随后在深度放电阶段(7000~9000 s)误差增大，最大值为0.21%，MAE为0.023%；从图10b可看出，NEDC工况测试中，误差在初始阶段较低，之后呈阶梯状上升，峰值达0.48%，MAE为0.12%；从图10c可看出，UDDS城市工况下，误差曲线与NEDC相似，但中后期(14000~18000 s)出现明显平台，MAX为0.53%，MAE为0.16%。综合分析表明，随着工况复杂度增加，SOH估计误差虽然逐步增大，但MAX差增幅为0.32%，MAE增幅为0.14%。即使在最复杂的UDDS工况下，算法仍将MAX控制在0.53%范围内，表现出较好的鲁棒性。在各工况急剧变化区间，误差曲线未出现突变或发散现象，而是呈现平稳过渡特性，表明SUKF-EKF算法具有对电流波动、SOC变化等多重干扰因素的强适应能力，为电池全寿命周期管理和可靠性评估提供了坚实技术基础。

4.3 算法稳定性验证

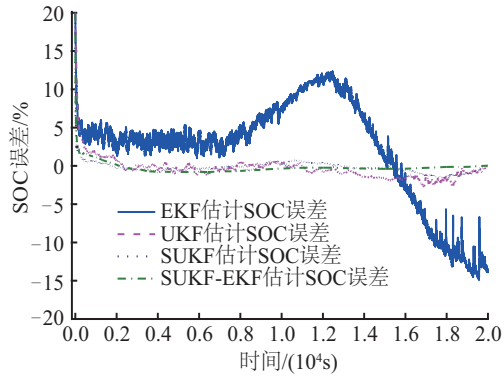
实际BMS应用中，电流和电压传感器的测量噪声会直接影响SOC和SOH估计的准确性。为验证SUKF-EKF算法在噪声环境下的鲁棒性能，选择复杂的UDDS工况，通过在电流和电压测量信号中叠加3%和5%两个强度的高斯白噪声进行稳定性测试，相应的误差分析结果如图11所示。



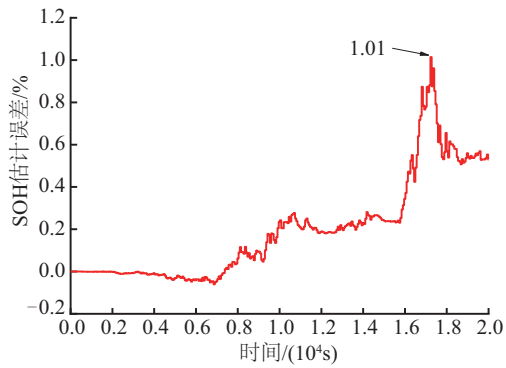
a. 3%噪声条件下SOC估计误差



b. 3%噪声条件下SOH估计误差



c. 5%噪声条件下SOC估计误差



d. 5%噪声条件下SOH估计误差

图11 基于UDDS工况噪声环境下SUKF-EKF算法SOC/SOH估计误差分析

Fig. 11 SOC/SOH estimation error analysis of SUKF-EKF algorithm in noisy UDDS condition

从图11a可看出，在3%噪声条件下，SUKF-EKF的SOC估计误差曲线最为平稳，MAE为0.27%，显著优于其他算法；图11b显示其SOH估计误差最大仅为0.66%，体现了良好的参数辨识稳定性。当噪声增至5%时；图11c表明SUKF-EKF的SOC估计MAE仅增至0.42%，而EKF误差急剧恶化至6.39%，误差波动剧烈；图11d进一步证实了SUKF-EKF在高噪声下的SOH估计仍保持优异性能，最大误差控制在1.01%以内。

中国知网 https://www.cnki.net

5 结　论

针对传统SMO与UKF在电池状态估计过程中分别存在抗噪声性不足与模型依赖度高的问题，本文在二阶RC等效电路模型基础上，提出一种基于SUKF-EKF融合的锂电池状态估计方法。通过构建双层时间尺度协同估计架构，利用EKF进行参数在线辨识以获取模型参数变化趋势并估计SOH，同时结合SMO的鲁棒特性与UKF的非线性处理优势实现SOC高精度估计。通过3种典型驾驶工况的实验验证，得出以下主要结论：

1）SUKF-EKF融合算法通过整合SMO的抗干扰能力与UKF的非线性处理特性，实现了对不同工况下电池参数的精确辨识，有效解决了传统算法在复杂环境中参数识别不稳定的问题，为SOC/SOH联合估计提供了可靠模型基础。

2）相比传统EKF方法，SUKF-EKF算法在HWFET、NEDC和UDDS工况下SOC估计的MAE分别降低45.6%、55.3%和68.4%，SOH估计平均误差控制在0.16%以内，有效提升模型参数辨识和状态估计能力。

3）噪声稳定性验证表明，在5%高斯白噪声环境下，SUKF-EKF算法的SOC估计误差仍控制在0.42%以内，SOH估计误差平均为0.21%，充分验证了算法在恶劣工况下的鲁棒性能，为实际BMS工程应用提供了可靠技术保障。

4）融合算法采用双时间尺度协同估计结构，实现了参数辨识与状态评估的有效结合，随着工况复杂度增加，其性能优势更为显著，证明了该方法在实际车载应用环境中的适应性。未来研究将进一步验证算法在不同健康状态下的参数辨识精度和状态估计性能，以全面评估算法在电池全寿命周期的适用性。

[参考文献]

[1] 谭泽富，彭涛，代妮娜，等. 电动汽车BMS关键技术研究进展[J]. 电源技术，2022，46(9)：954-957.
TAN Z F，PENG T，DAI N N，et al. Research progress on key technologies of BMS for electric vehicles[J]. Chinese journal of power sources，2022，46(9)：954-957.

[2] XIONG R，CAO J Y，YU Q Q，et al. Critical review on the battery state of charge estimation methods for electric vehicles[J]. IEEE access，2017，6：1832-1843.

[3] 张宇，李维嘉，吴铁洲. 基于BP-DCKF-LSTM的锂离子电池SOC估计[J]. 电源技术，2025，49(1)：155-166.
ZHANG Y，LI W J，WU T Z. Lithium ion battery SOC estimation based on BP-DCKF-LSTM[J]. Chinese journal of power sources，2025，49(1)：155-166.

[4] 黄佳茵，白俊琦，贤燕华. 基于DOD-LN-GPR模型的锂离子电池SOH估计方法[J]. 太阳能学报，2025，46(2)：60-69.
HUANG J Y，BAI J Q，XIAN Y H. SOH estimation method of lithium-ion batteries based on DOD-LN-GPR model[J]. Acta energiae solaris sinica，2025，46(2)：60-69.

[5] KIM E，KIM M，KIM J，et al. Data-driven methods for predicting the state of health，state of charge，and remaining useful life of Li-ion batteries：a comprehensive review[J]. International journal of precision engineering and manufacturing，2023，24(7)：1281-1304.

[6] 付诗意，吕桃林，闵凡奇，等. 电动汽车用锂离子电池SOC估算方法综述[J]. 储能科学与技术，2021，10(3)：1127-1136.
FU S Y，LYU T L，MIN F Q，et al. Overview of SOC estimation methods for lithium-ion batteries for electric vehicles[J]. Energy storage science and technology，2021，10(3)：1127-1136.

[7] 王越，李立伟. 基于扩展卡尔曼滤波器的锂电池SOC估算仿真研究[J]. 计算机与数字工程，2020，48(1)：206-211.
WANG Y，LI L W. Simulation research of lithium battery SOC estimation based on extended Kalman filter[J]. Computer & digital engineering，2020，48(1)：206-211.

[8] 李锦满，李儒欢，李浩南，等. 基于无迹卡尔曼滤波的动力电池状态估计[J]. 电池，2024，54(3)：340-343.
LI J M，LI R H，LI H N，et al. State estimation of power battery based on unscented Kalman filter[J]. Battery，2024，54(3)：340-343.

[9] HUANGFU Y G，XU J N，ZHAO D D，et al. A novel battery state of charge estimation method based on a super-twisting sliding mode observer[J]. Energies，2018，11(5)：1211.

[10] 钱伟，王浩宇，郭向伟，等. 联合改进滑模观测器的自适应卡尔曼滤波荷电状态估计[J]. 电工技术学报，2025，40(6)：1984-1994.
QIAN W，WANG H Y，GUO X W，et al. State of charge estimation using adaptive Kalman filter with improved sliding mode observer[J]. Transactions of China Electrotechnical Society，2025，40(6)：1984-1994.

[11] 赵轩，李美莹，余强，等. 电动汽车动力锂电池状态估计综述[J]. 中国公路学报，2023，36(6)：254-283.
ZHAO X，LI M Y，YU Q，et al. Review on state estimation of power lithium battery for electric vehicle[J]. China journal of highway and transport，2023，36(6)：254-283.

[12] ZHANG Y Z，XIONG R，HE H W，et al. A LSTM-RNN method for the lithuim-ion battery remaining useful life prediction[C]//2017 Prognostics and System Health Management Conference (PHM-Harbin). Harbin，China，2017：1-4.

[13] PENG N，ZHANG S Z，GUO X，et al. Online parameters

中国知网　https://www.cnki.net

identification and state of charge estimation for lithium-ion batteries using improved adaptive dual unscented Kalman filter[J]. International journal of energy research, 2021, 45(1): 975-990.

[14] 吕高, 樊郭宇, 张嘉蕾, 等. 温度自适应SMO算法估计锂离子电池的SOC[J]. 电池, 2024, 54(3): 334-339.
LYU G, FAN G Y, ZHANG J L, et al. SOC estimation for Li-ion battery used by temperature adaptive SMO algorithm [J]. Battery bimonthly, 2024, 54(3): 334-339.

[15] 王志福, 罗崴, 闫愿, 等. 基于多方法融合的锂离子电池SOC-SOH联合估计[J]. 北京理工大学学报, 2023, 43(6): 575-584.
WANG Z F, LUO W, YAN Y, et al. Joint SOC-SOH estimation for Li-ion batteries based on multi-method fusion [J]. Transactions of Beijing Institute of Technology, 2023, 43(6): 575-584.

[16] 李心月, 储江伟. 混合电动汽车锂离子电池状态融合估计策略[J]. 电源技术, 2023, 47(2): 204-209.
LI X Y, CHU J W. Novel fusion estimation strategy for state of charge and state of health of hybrid electric vehicle Li-ion batteries [J]. Chinese journal of power sources, 2023, 47(2): 204-209.

[17] WEI Z B, LI X L, XU L J, et al. Comparative study of computational intelligence approaches for NO_x reduction of coal-fired boiler[J]. Energy, 2013, 55: 683-692.

[18] 孙玉树, 李宏川, 王波, 等. 电池储能系统SOC神经网络融合估计方法[J]. 湖南大学学报(自然科学版), 2023, 50(10): 31-40.
SUN Y S, LI H C, WANG B, et al. SOC neural network fusion estimation method for battery energy storage system [J]. Journal of Hunan University (natural sciences), 2023, 50(10): 31-40.

[19] 董磊, 赖纪东, 苏建徽, 等. 基于IMAFFRLS-EKF的锂电池在线参数辨识和SOC估计方法[J]. 太阳能学报, 2024, 45(6): 66-74.
DONG L, LAI J D, SU J H, et al. Online parameter identification and SOC estimation of lithium battery based on IMAFFRLS-EKF [J]. Acta energiae solaris sinica, 2024, 45(6): 66-74.

[20] 李谦, 姜帆, 韩乔妮, 等. 基于一阶ECM-IGPR的锂离子电池SOC及SOH联合估计框架[J]. 太阳能学报, 2024, 45(5): 240-250.
LI Q, JIANG F, HAN Q N, et al. Joint first order SOC and SOH estimation framework for Li-ion battery based on ECM-IGPR [J]. Acta energiae solaris sinica, 2024, 45(5): 240-250.

[21] LIU Y Y, CAI T T, LIU J B, et al. State of charge estimation for Li-ion batteries based on an unscented H-infinity filter [J]. Journal of electrical engineering & technology, 2020, 15(6): 2529-2538.

[22] BEHNAMGOL V, ASADI M, MOHAMED M A A, et al. Comprehensive review of lithium-ion battery state of charge estimation by sliding mode observers[J]. Energies, 2024, 17(22): 5754.

[23] LIU W Z, HUO Z Y, LUO X W. Lithium-ion batteries SOC estimation using an ANFIS-based adaptive sliding mode observer for electric vehicle applications infrastructures [J]. International journal of critical infrastructures, 2024, 20(6): 538-556.

[24] 邓涛, 罗卫兴. 电动汽车动力电池SOH估计方法探讨[J]. 现代制造工程, 2018(5): 43-49.
DENG T, LUO W X. Research on estimation methods of battery SOH for electric vehicle[J]. Modern manufacturing engineering, 2018(5): 43-49.

中国知网 https://www.cnki.net

LITHIUM-ION BATTERY STATE ESTIMATION METHOD BASED ON SUKF-EKF FUSION

Wang Qiwen[1], Sheng Qiang[1], He Yucai[2]

(1. *School of New Energy Engineering and Automobile Industry*, *Huzhou Vocational and Technical College*, *Huzhou* 313099, *China*;
2. *School of Biology and Food Engineering*, *Changzhou University*, *Changzhou* 213164, *China*)

Abstract: To address the insufficient accuracy and poor adaptability to parameter variations of Extended Kalman Filter (EKF) in lithium-ion battery state estimation, this paper proposes a method utilizing EKF for online battery parameter identification and updating, while integrating Sliding Mode Observer (SMO) and Unscented Kalman Filter (UKF) for lithium battery state estimation (SUKF). The method establishes a dual-layer temporal scale collaborative estimation architecture, employing EKF for online battery parameter identification and State of Health (SOH) estimation, while combining SMO's robustness with UKF's nonlinear processing capabilities to achieve high-precision State of Charge (SOC) estimation. Verification through three representative testing environments—highway fuel economy test conditions, New European driving cycle, and urban dynamometer driving schedule—demonstrates that the fusion algorithm achieves average SOC estimation errors of 0.13%, 0.25%, and 0.14% respectively, with maximum errors constrained within 0.46%, representing over 85% improvement in accuracy compared to traditional EKF algorithms. SOH estimation under varying complexity conditions exhibits average errors ranging from 0.022% to 0.16%, with maximum errors not exceeding 0.53%. Under 5% noise disturbance conditions, the algorithm demonstrates robust estimation accuracy and convergence performance. As operational complexity increases, the performance advantages of the fusion algorithm become more pronounced, significantly enhancing the accuracy and robustness of battery state estimation, thus providing an effective solution for power battery management systems.

Keywords: lithium-ion battery; state estimation; sliding mode observer; unscented Kalman filter; state of charge; state of health

中国知网 https://www.cnki.net