DOI:10. 3969/j. issn. 2097-0706. 2025. 12. 003

基于灰狼优化算法和组合核函数GPR模型的锂电池剩余使用寿命预测

Prediction of remaining useful life of lithium batteries based on grey wolf optimization and combined kernel function GPR model

胡林静,李在伟
HU Linjing, LI Zaiwei

(内蒙古工业大学 电力学院,呼和浩特 010080)
(College of Electric Power, Inner Mongolia University of Technology, Hohhot 010080, China)

摘 要: 准确地预测锂离子电池剩余使用寿命(RUL)可以帮助用户制定合理的维护策略。高斯过程回归(GPR)算法作为一种数据驱动方法能够很好地捕捉特征和变量之间的非线性关系,被广泛应用于锂电池RUL估计。传统的单核GPR对特征捕捉能力不足,为此提出一种基于灰狼优化算法(GWO)的组合核GPR模型。通过组合核函数来增强模型对非线性特征的捕捉能力,同时利用GWO解决组合核函数超参数优化中的困难。采用美国国家航空航天局(NASA)锂电池循环老化数据集进行对该模型进行验证,并将其与基于粒子群优化(PSO)的单核GPR模型进行对比。试验结果显示:GWO优化的组合核GPR模型较PSO优化的单核GPR模型的均方根误差(RMSE)下降了37.89%,平均绝对误差(MAE)下降了70.42%,对容量衰减的捕捉能力更强。结果表明相比于传统GPR模型,灰狼优化的组合核GPR模型对锂电池RUL预测的准确性更高。

关键词: 锂离子电池;剩余使用寿命;高斯过程回归;灰狼优化算法;电池老化;容量衰减;预测误差;粒子群优化算法
中图分类号: TM 912 **文献标志码:** A **文章编号:** 2097-0706(2025)12 - 0025 - 09

Abstract: Accurately predicting the remaining useful life (RUL) of lithium-ion batteries can help users formulate reasonable maintenance strategies. As a data-driven method, Gaussian process regression (GPR) algorithm can effectively capture the nonlinear relationship between features and variables, and thus is widely used in the RUL estimation of lithium batteries. To address the deficiency of traditional single-kernel GPR in feature capture, a combined kernel GPR model based on the grey wolf optimization (GWO) algorithm was proposed. By combining kernel functions, the model's ability to capture nonlinear features was enhanced, and the GWO algorithm was utilized to overcome the difficulty in optimizing the hyperparameters of the combined kernel function. The NASA lithium battery cycle aging dataset was adopted to verify this model, and the single-kernel GPR model based on particle swarm (PSO) optimization was selected for comparison. The experimental results showed that the GWO-optimized combined kernel GPR model achieved a 37.89% reduction in root mean square error (RMSE) and a 70.42% reduction in mean absolute error (MAE) compared with the PSO-optimized single-kernel GPR model, demonstrating a stronger ability to capture capacity degradation. The results indicate that compared with the traditional GPR model, the GWO-optimized combined kernel GPR model has higher accuracy for the RUL prediction of lithium batteries.

Keywords: lithium-ion battery; remaining useful life; Gaussian process regression; grey wolf optimization algorithm; battery aging; capacity degradation; prediction error; particle swarm optimization

0 引言

锂离子电池具有能量密度高、温度范围宽、自放电率低、无污染等特点[1],不需要完全放电即可充电,且生命周期较长[2],被各领域广泛应用。在实际使用过程中,随着充放电次数的增加,锂电池内部会逐渐老化,导致其使用寿命逐渐缩短、性能降低,进而引发电气设备故障甚至安全事故。因此,对锂电池剩余使用寿命(Remaining Useful Life, RUL)做出准确的预测,可以方便用户了解电池所处的寿命阶段,建立更好的维修策略,使电池得到更有效的

基金项目: 内蒙古自然科学基金项目(2025LHMS05031)
Inner Mongolia Natural Science Foundation Project(2025LHMS 05031)

中国知网 https://www.cnki.net

使用[3]。

锂电池 RUL 的预测方法主要包括基于模型的预测方法和数据驱动预测法[4]。(1)基于模型的方法主要包括基于老化机理的方法、基于电化学阻抗谱(EIS)的方法、等效电路模型法等。由于锂离子电池具有复杂的电化学动力系统,基于模型的方法通常复杂且难以实现[5],且不同的锂电池内部机理并不相同,因此基于模型的方法并不适用于所有类型的电池[6]。(2)数据驱动法则不需要了解电池工作原理和电池模型,只需要收集与老化相关的数据,预测精度高[7],因此数据驱动方法在 RUL 预测中的应用更广泛。Wei 等[8]针对使用传统粒子滤波算法预测锂电池 RUL 时出现的粒子多样性丧失现象,提出了基于线性优化重采样粒子滤波的预测方法,提升了预测的精度和稳定性,但是对退化模型参数的影响研究不足。Fang 等[9]提出了一种融合方法,通过探索特征的时空关系来估计历史可用容量,并用长短期记忆网络模型预测锂电池 RUL。该方法能够在电池历史容量数据未知的情况下提供可靠预测,但也导致模型复杂度提高。Pang 等[10]融合小波分解技术和非线性自回归神经网络捕捉容量再生现象,但是线性自回归神经网络对非线性关系的捕捉能力有限。冯娜娜等[11]提出蚁狮优化的高斯过程回归(Gaussian Process Regression, GPR)模型,解决了超参数寻优结果不理想的问题,但该模型的性能受限于核函数。

在基于数据驱动的方法之中,GPR 能够出色地处理高维、小样本、非线性的复杂回归问题。同时由于 GPR 是一种概率模型[12],建立在贝叶斯框架之中,因此它的预测输出可以用基于概率的形式来解释,结果具有可靠性。GPR 模型的预测能力取决于核函数[13]且参数优化困难。传统 GPR 通常由经验给出超参数的初始估计,通过交叉验证或贝叶斯优化动态调整参数的选择[14];在超参数优化时,通常采用共轭梯度法,该方法对初始点较为敏感,可能导致陷入局部最优解。针对该问题,优化算法可以提供解决方案[15],即寻找最佳的超参数组合从而更好地拟合模型,同时带来更佳的泛化性。灰狼优化算法(Grey Wolf Optimizer,GWO)作为一个受灰狼群体行为启发的智能优化算法,可以更全面地搜索参数空间,具有较强的全局搜索能力,有助于避免陷入局部最优。本文提出一种基于 GWO 的组合核函数 GPR 模型,相比于单核函数的 GPR 模型,组合核函数 GPR 模型能够拟合更复杂的回归问题,同时利用 GWO 优化核参数。与传统单核 GPR 模型相比,GWO 优化的多核 GPR 模型能够对锂电池 RUL 进行更精准的预测。

1 试验准备

1.1 数据介绍

本次试验数据来自美国国家航空航天局(NASA)的电池老化数据集。采用 18650 型锂电池,编号分别为 B0005,B0006,B0007,B0018,额定容量均为 2.0 A·h。电池的循环老化操作为:(1)采用 1.50 A 恒流充电模式充电,当电压到达 4.2 V 后进行恒压充电,直到电流减小到 0.02 A;(2)放电时以 2.00 A 恒定电流分别放电至 2.7,2.5,2.2,2.5 V。充放电的环境温度为 24 ℃,记录循环次数共 168 次,每次充电放电为一次循环,每次循环记录充放电时间、电流、电压。电流、电压每秒记录一次,数据中的若干缺失值采用均值填补。当电池容量下降到额定容量的 70%(即 1.4 A·h)时,认为电池寿命终止,电池容量随循环次数下降的曲线如图 1 所示。

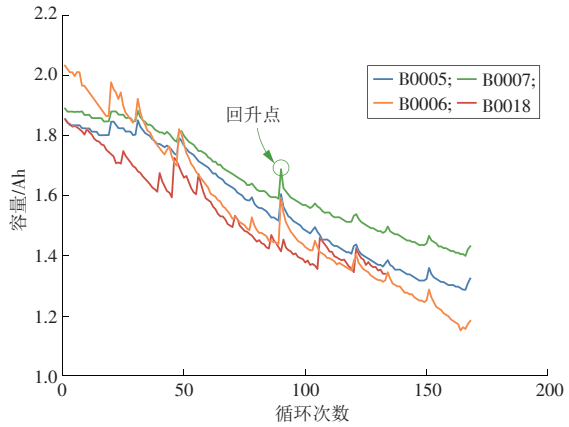


图 1 电池容量下降曲线

Fig. 1 Battery capacity decrease curves

电池容量是表征电池寿命变化的最直观因素[16-18]。由于电池内阻不易测量,为了预测锂电池 RUL,需要预测剩余所有循环的剩余容量[19]。本试验将根据电池循环老化过程中测得的电压、电流、容量等数据,预测容量老化轨迹。

电池容量的下降是一个非线性过程,还伴有容量回升现象,这是由于电池经过短暂放置之后其内部的化学过程和有机结构会重新排列,性能得到缓慢恢复。4 种电池的初始容量都不相同,B0018 号电池在 132 次循环时截止,其他 3 个电池在 168 次循环时截止。因此,本次试验选用数据更充分的 B0005,B0006,B0007 号电池。

1.2 特征提取

通常锂电池第 1 次充满电后使用时间最长,随着电池充放电次数增加,电池充满电后的供电时间不断缩短[20],对应的锂电池充放电过程的各种数据

中国知网 https://www.cnki.net

也会产生变化。对锂电池的RUL预测首要任务是从试验数据中提取有效的老化特征。图2—4分别为B0005号电池充电过程电流、充电过程电压以及放电过程电压曲线。

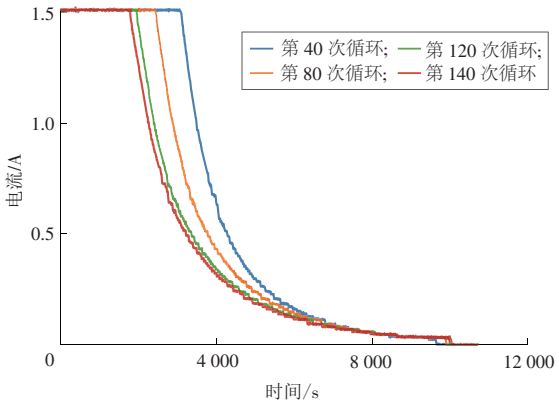


图2　充电过程电流

Fig. 2　Current during charging process

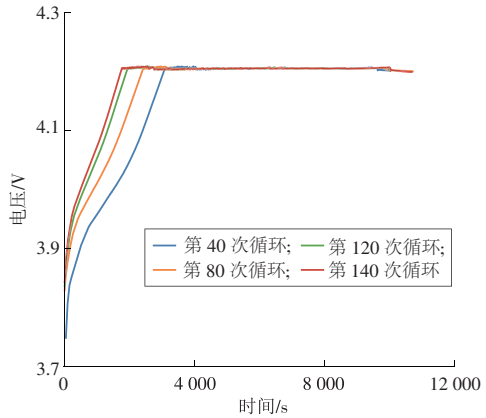


图3　充电过程电压

Fig. 3　Voltage during charging process

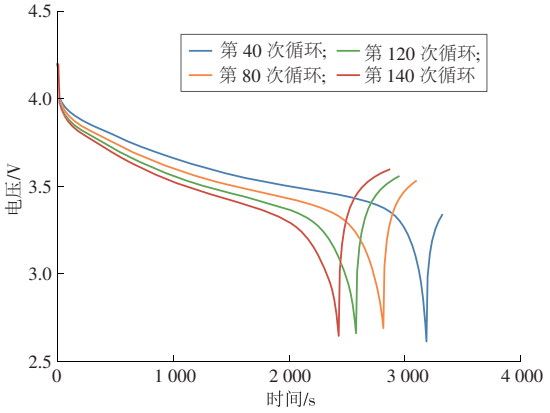


图4　放电过程电压

Fig. 4　Voltage during discharge process

由图2—4可以看出:随着电池循环次数增加,恒流充电阶段电压达到4.2 V所用的时间逐渐减少;同时恒压充电过程中电流下降的速度越来越快;在放电过程中,电压达到最小值的时间也越来越快。这些特征的变化与锂电池的老化过程呈现高度相关性,因此试验需要提取随电池老化过程波动较大的变量作为表征电池老化的特征。本次试验共从中提取了4个特征:恒压充电阶段900 s后的电流减少量H_1;放电电压达到最小值的时间H_2;充电电压从3.9 V上升到4.2 V所用时间H_3;从充电电压达3.9 V开始600 s后的电压增加量H_4。为了消除量纲和分布差异,通过数据标准化使不同特征具有可比性。标准分数表示为

$$Z = \frac{X - \mu}{\sigma}, \tag{1}$$

式中:μ为数据均值;σ为数据标准差;X为原数据。

为了验证提取的4种特征和容量变化之间的相关性,计算得到每个特征与容量的Pearson相关性,见表1。由表1可知,4种特征与容量衰减之间均存在较强的相关性。

表1　特征与容量的Pearson相关性

Table 1　Pearson correlation between characteristics and capacity

电池编号	与容量的Pearson相关性			
	H_1	H_2	H_3	H_4
B0005	0.908	0.982	0.988	−0.972
B0006	0.918	0.971	0.983	−0.970
B0007	0.785	0.978	0.979	−0.959

1.3　主成分分析

主成分分析(Principal Components Analysis,PCA)可以较为快速、简单地分析比较待测序列和参考序列的相似性,在尽可能保留原始数据信息的前提下将高维数据投影到低维空间。考虑到4种不同特征潜在的数据共线性,采用PCA可以分离冗余信息和有效信息,减小后期的计算量。

PCA分析步骤如下。

步骤1:提取参与分析的m个主成分组成下述矩阵,矩阵由n个具有m个特征的元素构成,X_{ij}为$\boldsymbol{X}$中的i行第j列的元素,

$$\boldsymbol{X} = \begin{bmatrix} X_{11} & \cdots & X_{1n} \\ \vdots & \ddots & \vdots \\ X_{m1} & \cdots & X_{mn} \end{bmatrix}。 \tag{2}$$

步骤2:对$\boldsymbol{X}$中的数据X_{ij}进行标准化。

$$X_{ij}^{*} = \frac{X_{ij} - \bar{X}_j}{s_j} = \frac{X_{ij} - \sum_{i=1}^{m} \frac{X_{ij}}{m}}{\sqrt{\sum_{i=1}^{m} (X_{ij} - \bar{X}_j)^2 / (m-1)}}, \tag{3}$$

式中:X_{ij}^{*}为X_{ij}的标准化数据;$\bar{X}_j$为第j列的均值;s_j为第j列标准差。

步骤3:使用对称矩阵$\boldsymbol{X}_{\text{rotate}}$($\boldsymbol{X}_{\text{rotate}} = \boldsymbol{Q}^{\mathrm{T}}\boldsymbol{X}$,$\boldsymbol{Q}$为特征向量矩阵)对$X_{ij}^{*}$的相关系数矩阵进行特征值分解,并将数据旋转投影到主成分轴上。

步骤4:计算主成分贡献率。

中国知网　https://www.cnki.net

$$v_h = \lambda_h / \sum_{h=1}^{n} \lambda_h, \tag{4}$$

$$v_{\mathrm{cum}}(k) = \sum_{h=1}^{n} \lambda_k / \sum_{h=1}^{n} \lambda_h, \tag{5}$$

式中：v_h为第h个主成分的贡献率；$v_{\mathrm{cum}}(k)$为前k个主成分的累计贡献率；λ_h与λ_k分别为第h个与第k个特征值。

将选出的4种特征值进行PCA降维，根据信息表达能力从大到小排列获得主成分1—4，各主成分的方差贡献率见表2。

表2 各主成分方差贡献率

Table 2 Variance contribution rates of main components

电池编号	主成分1	主成分2	主成分3	主成分4
B0005	0.804 1	0.169 0	0.014 4	0.012 5
B0006	0.900 0	0.090 1	0.007 9	0.002 1
B0007	0.692 3	0.246 2	0.033 2	0.028 2

由表2可知：主成分1对3种电池的方差贡献率分别达到了0.804 1，0.900 0和0.692 3；主成分1和主成分2对3种电池容量衰减的累计贡献率分别为0.973 1，0.990 1和0.938 5，已经解释了大部分方差。但是主成分2与容量衰减相关性较小，主成分1与容量衰减相关性较强，综合考虑，采用主成分1作为最终的融合特征。

2 预测方法原理

2.1 GPR

GPR是一种以数据驱动为基础的算法，它能够捕捉特征和目标变量之间复杂的非线性关系，通过学习电池的历史特征数据，能够获得有效的后验估计和概率分布，适用于小样本、非线性系统的建模。GPR模型的性能主要由其均值函数$m(x)$和协方差函数$k(x,x')$决定，$m(x)$描述了函数在任意输入点x的期望值，$k(x,x')$衡量了不同输入点之间函数值的相关性。GPR模型的数据表达为

$$f(x) \sim \mathrm{GP}(m(x), k(x,x')), \tag{6}$$

$$m(x) = E[f(x)], \tag{7}$$

$$k(x,x') = E\{[f(x) - m(x)][f(x') - m(x')]\}。 \tag{8}$$

一般的函数观测值(y)含有噪声，可表示为

$$y = f(x) + \varepsilon, \tag{9}$$

式中：ε为方差为σ_n^2的白噪声，$\varepsilon \sim \mathrm{N}(0, \sigma_n^2)$。则$y$的先验分布可以表示为

$$y \sim \mathrm{N}(0, K_f(x,x) + \sigma_n^2 I_n), \tag{10}$$

式中：n为样本量；$K_f(x,x)$为数据点x处的相似性；I_n表示噪声的协方差结构。

在测试数据x^*处，锂电池的观测集y与预测集$\hat{y}$的联合先验分布可以表示为

$$\begin{bmatrix} y \\ \hat{y} \end{bmatrix} \sim \mathrm{N}\left(0, \begin{bmatrix} K_f(x,x) + \sigma_n^2 I_n & K_f(x,x^*) \\ K_f(x,x^*)^{\mathrm{T}} & K_f(x^*,x^*) \end{bmatrix}\right)。 \tag{11}$$

根据上式，可以得到后验分布

$$p(\hat{y}|x,y,x^*) = \mathrm{N}(\hat{y}|\hat{y}^*, \mathrm{cov}(\hat{y}^*)), \tag{12}$$

$$\hat{y}^* = K_f(x,x^*)^{\mathrm{T}}[K_f(x,x) + \sigma_n^2 I_n]^{-1} y, \tag{13}$$

$$\mathrm{cov}(\hat{y}^*) = K_f(x^*,x^*) - y^* y K_f(x,x^*), \tag{14}$$

式中：$\hat{y}^*$为模型输出的预测均值；$\mathrm{cov}(\hat{y}^*)$为预测协方差函数，反映模型预测的不确定性。

对于GPR模型来说，核函数$K_f(x,x')$很大程度上影响着模型的性能，因此，核函数的选择具有关键的作用。

2.2 GWO

GPR模型中超参数过多，通过优化参数提高预测精度是一项艰巨的任务[21]。GWO是一种基于群体智能的优化算法，其核心思想是通过模拟灰狼的领导层次和狩猎策略，在空间中寻找最优解。灰狼群体中按领导力分解为4层：α狼为群里的领导者，负责决策，对应了当前最优解；β狼为辅助领导者，协助α狼，对应了次优解；δ狼为侦察兵，负责探索和警戒，对应了第3优解；ω狼为普通乘员，跟随前三者，对应候选解。

GWO的整体算法流程如图5所示，狼群狩猎行为分为3个阶段：包围猎物、骚扰猎物、攻击猎物。

(1)包围猎物，灰狼个体向猎物(当前最优解)移动。

$$\boldsymbol{D} = \left|\boldsymbol{C}\boldsymbol{X}_{\mathrm{prey}}(t) - \boldsymbol{X}(t)\right|, \tag{15}$$

$$\boldsymbol{X}(t+1) = \boldsymbol{X}_{\mathrm{prey}}(t) - \boldsymbol{A}\boldsymbol{D}, \tag{16}$$

式中：$\boldsymbol{D}$为距离向量；$\boldsymbol{X}(t)$为灰狼当前位置(候选解)；$\boldsymbol{X}_{\mathrm{prey}}(t)$为猎物位置；$\boldsymbol{A}$和$\boldsymbol{C}$均为系数向量，分别控制移动的方向和步长。

$$\begin{cases} \boldsymbol{A} = 2a\boldsymbol{r}_1 - a \\ \boldsymbol{C} = 2\boldsymbol{r}_2 \end{cases}, \tag{17}$$

式中：a为收敛因子，它随着迭代次数从2线性递减到0；$\boldsymbol{r}_1$，$\boldsymbol{r}_2$均为[0,1]内的随机向量。

(2)协作狩猎，由α，β，δ狼引导其他狼更新到位置$\boldsymbol{X}(t+1)$。

$$\boldsymbol{X}(t+1) = \frac{\boldsymbol{X}_\alpha + \boldsymbol{X}_\beta + \boldsymbol{X}_\delta}{3}, \tag{18}$$

式中：$\boldsymbol{X}_\alpha$，$\boldsymbol{X}_\beta$，$\boldsymbol{X}_\delta$为前三优解的位置。

(3)攻击与探索，当方向控制系数$|\boldsymbol{A}|<1$时，灰狼向猎物靠近(局部搜索)，当$|\boldsymbol{A}|\geqslant 1$时，灰狼分散寻找新猎物。

在本次试验中根据问题维度(即权重、长度尺度l、信号方差σ^2)，将灰狼算法种群数量设置为30，

中国知网 https://www.cnki.net

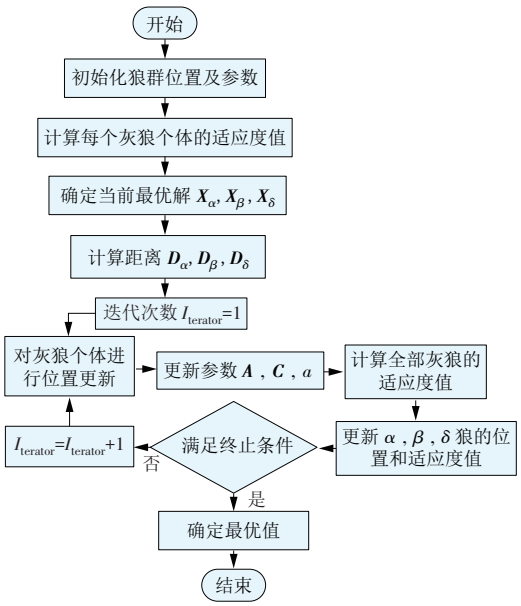


图5　GWO算法流程

Fig. 5　Flowchart of GWO

最大迭代次数为150。

2.3　组合核GPR模型预测流程

在GPR模型中核函数对于模型的性能起到了关键作用。单一核函数有高斯核函数(RBF核函数)、马顿(Matern)核函数、线性核(LIN)函数、有理二次(RQ)核函数[22-24]等,常见的单一核函数见表3(σ_0^2为常数项方差;p为周期参数)。

表3　常见单一核函数

Table 3　Common simple kernel functions

函数	数学表达式
高斯核	$k(x,x')=\sigma^2\exp(-\frac{\|x-x'\|^2}{2l^2})$
马顿核	$k(x,x')=\sigma^2(1+\frac{\sqrt{3}\|x-x'\|}{l})\exp(-\frac{\sqrt{3}\|x-x'\|}{l})$
线性核	$k(x,x')=\sigma_0^2+xx'$
周期核	$k(x,x')=\sigma^2\exp(-\frac{2\sin^2(\pi\|x-x'\|/p)}{l^2})$
指数核	$k(x,x')=\sigma^2\exp(-\frac{\|x-x'\|}{l})$
拉普拉斯核	$k(x,x')=\exp(-\frac{\|x-x'\|}{l})$

单一核函数只能捕捉数据中的一种模式,无法充分建模。当遇到不同区域的数据突变时,采用单一核函数的GPR可能无法有效拟合[25]。相比于单一核函数,组合核函数能够适应更加复杂的数据结构,捕捉多维特征。同时,组合核函数能够允许不同核成分自动调整权重,适应不同特征的强度,提升预测准确性。线性核能够使得模型捕捉输入数据之间的线性关系,但是无法拟合非线性模式,高斯核能够赋予模型学习复杂非线性关系的能力。由于相加后组合核函数更易优化,因此本试验选择线性核与高斯核的加权相加组合核(LIN+RBF)作为GPR模型的核函数。

本文采用的LIN+RBF组合核函数计算流程如图6所示。首先从充/放电过程中提取特征,然后通过Pearson相关性分析验证特征与目标变量的相关性,利用组合核函数构建GPR模型。GWO的优化目标为核函数超参数:长度尺度、方差、周期、组合核权重。

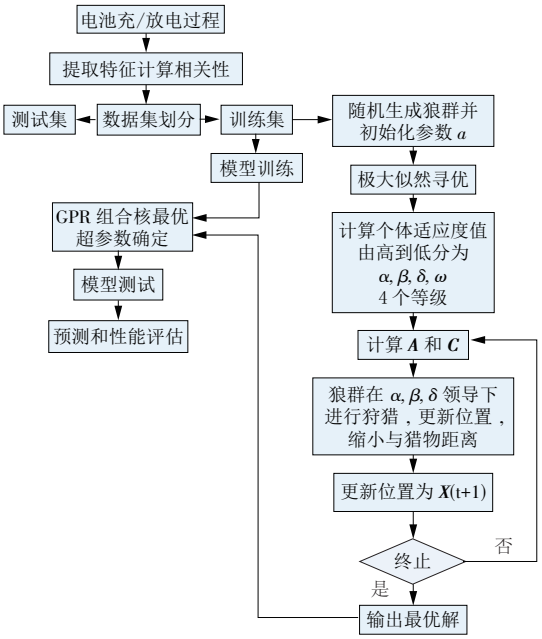


图6　LIN+RBF组合核函数计算流程

Fig. 6　Calculation flowchart of LIN+RBF combined kernel function

3　试验结果与分析

3.1　模型评价指标

本次试验采取平均绝对误差(MAE)和均方根误差(RMSE)分析误差,对模型的预测精度进行评价。

$$E_{MAE}=\frac{1}{N}\sum_{i=1}^{N}|y_i-\hat{y}_i|, \tag{19}$$

$$E_{RMSE}=\sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i-\hat{y}_i)^2}, \tag{20}$$

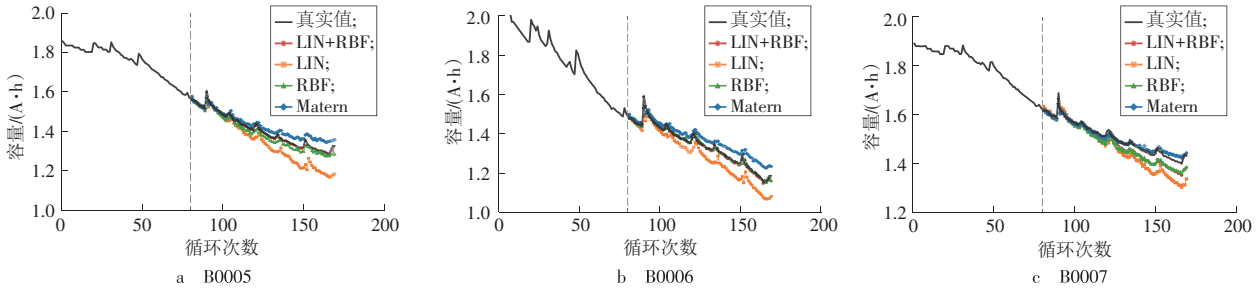
式中:N为待测数据集中的样本总数;y_i为电池的容量观测值;$\hat{y}_i$为电池容量预测值。RMSE和MAE越小,说明模型的预测结果越好。

3.2　模型对比

本试验采取NASA锂电池循环老化数据集,采用数据充分的B0005,B0006,B0007号电池进行试验。为了比较组合核函数GPR模型与传统单核模型下电池的性能变化,试验采用LIN+RBF,LIN,RBF以及Matern核函数GPR模型做对比试验,分别

中国知网　https://www.cnki.net

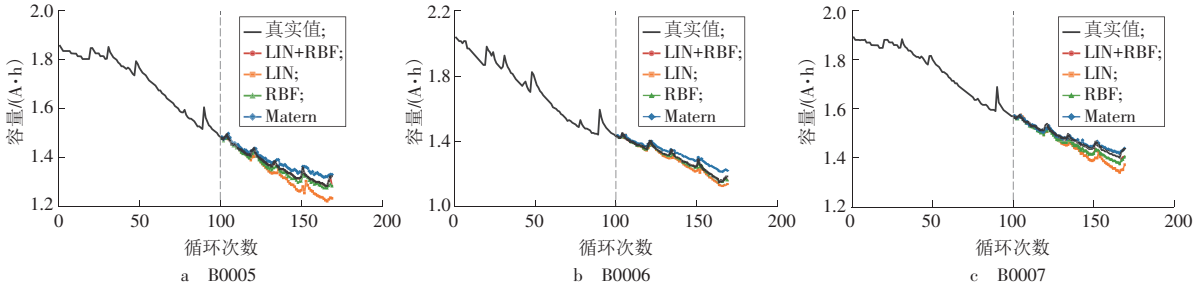
选择循环次数80,100,120为预测起点,并以预测起点前20次循环为验证集,其余为训练集,预测起点之后循环为测试集,比较不同预测起点下的电池性能。预测结果如图7—9所示。



a B0005 b B0006 c B0007

图7 以循环次数80为预测起点的预测结果

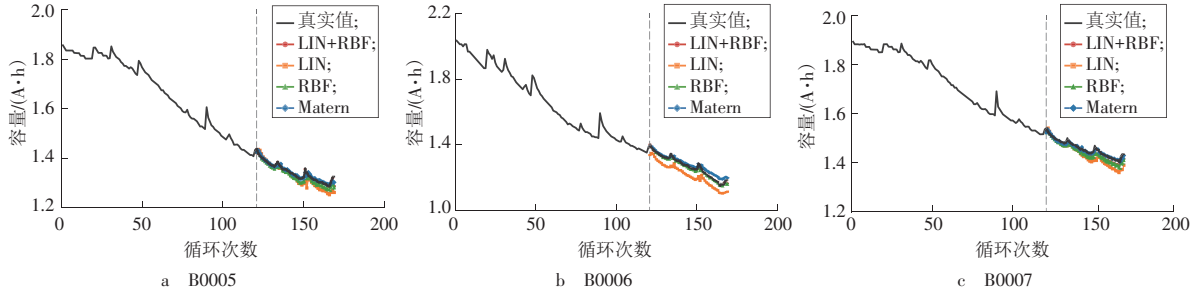
Fig. 7 Results of the prediction starting from 80th cycle



a B0005 b B0006 c B0007

图8 以循环次数100为预测起点的预测结果

Fig. 8 Results of the prediction starting from 100th cycle



a B0005 b B0006 c B0007

图9 以循环次数120为预测起点的预测结果

Fig. 9 Results of the prediction starting from 120th cycle

横向来看,RBF核模型与本文提出的LIN+RBF组合核模型对不同电池的数据特征表现出较好的适应性,预测误差见表4。

由表4可知,LIN+RBF组合核模型的预测误差显著小于传统单核GPR模型。随着预测起始点循环数的增加,各个模型的预测精度均出现较为明显的提升。以B0005号电池为例,以循环次数120为预测起点较以循环次数80为预测起点时,LIN+RBF,LIN,RBF,Matern核模型的预测结果RMSE分别减小了3.28%,64.74%,22.68%,84.50%,这是由于训练集的增大能够使模型能够充分学习数据特征,使预测结果更精确。

粒子群优化(Particle Swarm Optimization,PSO)与GWO同作为群体智能优化算法[26-27],也具有强大的全局搜索能力,经常被用于GPR模型的超参数优化。为了验证GWO对模型性能的影响,选择将无优化模型、GWO优化模型、PSO优化模型进行对比,优化前后的LIN+RBF组合核GPR模型预测结果如图10所示。以B0005号电池为例,经GWO,PSO优化前后的LIN+RBF模型预测误差见表5。

预测结果显示,经PSO优化后的模型相比于未优化的模型误差均有所下降,其中以循环次数120为预测起点的预测结果中RSME和MAE分别减小了47.22%和45.38%。采用GWO可以进一步提升预测精度,GWO优化后的模型误差相比PSO优化模型的RMSE减小了37.89%,MAE减小了70.42%。误差数据表明,本文提出的经GWO优化后的LIN+RBF组合核GPR模型在锂电池RUL预测中具有较高的精准度。

中国知网 https://www.cnki.net

表4　不同核函数的预测结果误差

Table 4　Prediction result errors of different kernel functions　A·h

项目		RMSE			MAE		
		以80为起点	以100为起点	以120为起点	以80为起点	以100为起点	以120为起点
LIN+RBF核模型	B0005	0.006 1	0.005 1	0.005 9	0.003 7	0.001 8	0.002 1
	B0006	0.005 9	0.004 3	0.004 1	0.004 6	0.003 2	0.002 8
	B0007	0.027 3	0.016 2	0.012 4	0.023 2	0.014 0	0.011 1
LIN核模型	B0005	0.070 9	0.039 6	0.025 0	0.058 4	0.031 9	0.019 6
	B0006	0.059 5	0.022 8	0.052 6	0.051 4	0.018 7	0.051 0
	B0007	0.052 6	0.035 2	0.028 6	0.041 9	0.028 9	0.024 6
RBF核模型	B0005	0.019 4	0.013 2	0.015 0	0.017 5	0.011 0	0.012 6
	B0006	0.011 6	0.008 0	0.010 2	0.008 2	0.005 9	0.008 1
	B0007	0.028 6	0.018 9	0.017 0	0.025 4	0.016 7	0.015 5
Matern核模型	B0005	0.058 7	0.029 9	0.009 1	0.048 6	0.026 3	0.008 0
	B0006	0.053 5	0.035 4	0.021 4	0.046 6	0.030 7	0.018 6
	B0007	0.026 5	0.016 2	0.008 3	0.020 0	0.013 1	0.007 2

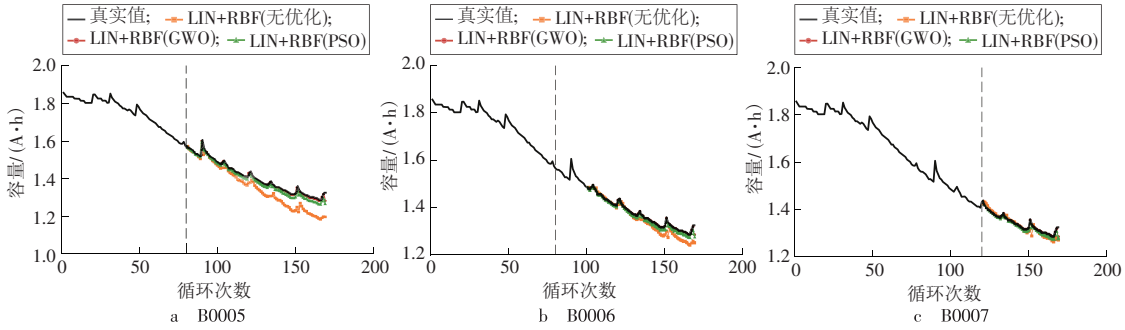


图10　不同优化算法下的预测结果

Fig. 10　Prediction results under different optimization algorithms

表5　不同优化算法下的预测误差

Table 5　Prediction errors under different optimization algorithms　A·h

起始循环次数	RMSE			MAE		
	GWO	无优化	PSO	GWO	无优化	PSO
80	0.006 1	0.062 6	0.016 7	0.003 7	0.052 3	0.013 9
100	0.005 1	0.028 0	0.010 9	0.001 8	0.012 5	0.008 6
120	0.005 9	0.018 0	0.009 5	0.002 1	0.013 0	0.007 1

4　结论

本文提出了一种GWO优化后的LIN+RBF组合核函数GPR模型,用于预测锂电池RUL。利用LIN+RBF组合核函数可将多维特征输入到GPR模型中,解决了单核函数模型对数据特征挖掘能力的不足的问题;利用GWO优化核函数超参数,解决了核函数优化易陷入局部最优的问题。

通过NASA锂电池循环老化数据集,分别对不同模型从不同预测起点开始的预测试验进行比较,验证了GWO优化的LIN+RBF组合核GPR模型的有效性。

参考文献:

[1]喻子逸,黄晓凡,李佳瑞,等.梯次利用动力电池储能系统综合效益分析[J].综合智慧能源,2024,46(7):63-73.
HUANG Xiaofan, LI Jiarui, LIU Hui, et al. Comprehensive benefit analysis on the cascade utilization of a power battery system [J]. Integrated Intelligent Energy, 2024, 46(7): 63-73.

[2]刘月峰,张公,张晨荣,等.锂离子电池RUL预测方法综述 计算机工程[J].2020,46(4):11-18.
LIU Yuefeng, ZHANG Gong, ZHANG Chenrong, et al. Review of RUL prediction method for lithium-ion batteries.

中国知网　https://www.cnki.net

computer engineering[J]. 2020, 46(4): 11-18.

[3]张若可, 郭永芳, 余湘媛, 等. 基于数据驱动的锂离子电池RUL预测综述[J]. 电源学报, 2023, 21(5): 182-190.
ZHANG Ruoke, GUO Yongfang, YU Xiangyuan, et al. Summary of data-driven prediction of RUL for lithium-ion batteries [J]. Journal of Power Supply, 2023, 21(5): 182-190.

[4]刘大同, 宋宇晨, 武巍, 等. 锂离子电池组健康状态估计综述[J]. 仪器仪表学报, 2020, 41(11): 1-18.
LIU Datong, SONG Yuchen, WU Wei, et al. Review of state of health estimation for lithium-ion battery pack [J]. Chinese Journal of Scientific Instrument, 2020, 41(11): 1-18.

[5]LI L, SONG Y C, PENG Y, et al. Lithium-ion battery remaining useful life prognostics using data-driven deep learning algorithm [C]//Prognostics and System Health Management Conference, 2018.

[6]熊庆, 邸振国, 汲胜昌. 锂离子电池健康状态估计及寿命预测研究进展综述[J]. 高电压技术, 2024, 50(3): 1182-1195.
XIONG Qing, DI Zhenguo, JI Shengchang. Review on health state estimation and life prediction of lithium-ion batteries [J]. High Voltage Engineering, 2024, 50(3): 1182-1195.

[7]胡晓亚, 郭永芳, 张若可. 锂离子电池健康状态估计方法研究综述[J]. 电源学报, 2022, 20(1): 126-133.
HU Xiaoya, GUO Yongfang, ZHANG Ruoke. Review of state-of-health estimation methods for lithium-ion battery [J]. Journal of Power Supply, 2022, 20(1): 126-133.

[8]韦海燕, 安晶晶, 陈静, 等. 基于改进粒子滤波算法实现锂离子电池RUL预测[J]. 汽车工程, 2019, 41(12): 1377-1383.
WEI Haiyan, AN Jingjing, CHEN Jing, et al. RUL prediction of lithium-ion battery based on improved particle filtering algorithm [J]. Automotive Engineering, 2019, 41(12): 1377-1383.

[9]FANG P Y, SUI X X, ZHANG A H, alt. Fusion model based RUL prediction method of lithium-ion battery under working conditions[J]. Maintenance and Reliability, 2024, 26(3):186537

[10]PANG X Q, HUANG R, WEN J, et al. A lithium-ion battery RUL prediction method considering the capacity regeneration phenomenon[J]. Energies, 2019, 12(12). : 12122247.

[11]冯娜娜, 杨明, 惠周利, 等. 基于蚁狮优化高斯过程回归的锂电池剩余使用寿命预测[J]. 储能科学与技术, 2024, 13(5): 1643-1652.
FENG Nana, YANG Ming, HUI Zhouli, et al. Prediction of the remaining useful life of lithium batteries based on antlion optimization Gaussian process regression [J]. Energy Storage Science and Technology, 2024, 13(5): 1643-1652.

[12]刘迎迎, 张孝远, 刘梦楠, 等. 基于自适应最优组合核函数高斯过程回归的锂电池健康状态区间估计[J]. 储能科学与技术, 2025, 14(1): 346-357.
LIU Yingying, ZHANG Xiaoyuan, LIU Mengnan, et al. State of health interval estimation for lithium battery via Gaussian process regression with adaptive optimal combination kernel function [J]. Energy Storage Science and Technology, 2025, 14(1): 346-357.

[13]周洪宇, 肖佳鹏. 基于高斯过程回归组合核函数的磷酸铁锂电池荷电状态估算[J]. 农业装备与车辆工程, 2020, 58(8): 87-91, 111.
ZHOU Hongyu, XIAO Jiapeng. Estimation for state of charge of lithium iron phosphate battery based on Gaussian process regression with composite kernel function [J]. Agricultural Equipment & Vehicle Engineering, 2020, 58(8): 87-91, 111.

[14]GUO Y, YU X, WANG Y, et al. Health prognostics of lithium-ion batteries based on universal voltage range features mining and adaptive multi-Gaussian process regression with harris hawks optimization algorithm [J]. Reliability Engineering & System Safety, 2024, 244: 109913.

[15]王琛, 闵永军. 基于容量增量曲线与GWO-GPR的锂离子电池SOH估计[J]. 储能科学与技术, 2023, 12(11): 3508-3518.
WANG Chen, MIN Yongjun. SOH estimation of lithium-ion batteries based on capacity increment curve and GWO-GPR[J]. Energy Storage Science and Technology, 2023, 12(11): 3508-3518.

[16]庞景月, 马云彤, 刘大同, 等. 锂离子电池剩余寿命间接预测方法[J]. 中国科技论文, 2014, 9(1): 28-36.
PANG Jingyue, MA Yuntong, LIU Datong, et al. Indirect remaining useful life prognostics for lithium-ion battery[J]. China Science Paper, 2014, 9(1): 28-36.

[17]陈毅, 黄妙华, 王树坤. 基于数据驱动的锂电池剩余容量估计[J]. 自动化与仪表, 2017, 32(8): 69-73.
CHEN Yi, HUANG Miaohua, WANG Shukun. Lithium battery residual capacity estimation based on the data-driven[J]. Automation & Instrumentation, 2017, 32(8): 69-73.

[18]ZHOU Y, HUANG M. On-board capacity estimation of lithiumion batteries based on charge phase[J]. Journal of Electrical Engineering and Technology, 2018, 13(2): 733-741.

[19]朱振威, 苗嘉伟, 祝夏雨, 等. 基于机器学习方法的锂电池剩余寿命预测研究进展[J]. 储能科学与技术, 2024(9): 3134-3149.
ZHU Zhenwei, MIAO Jiawei, ZHU Xiayu, et al. Research

中国知网 https://www.cnki.net

progress of residual life prediction of lithium batteries based on machine learning method [J]. Energy Storage Science and Technology, 2024(9): 3134-3149.

[20]陈璐, 于仲安, 熊莹燕. 不同温度下基于PSO-LSSVM的锂电池SOH估计与RUL预测[J]. 传感器与微系统, 2023, 42(6): 141-145.
CHEN Lu, YU Zhongan, XIONG Yingyan. SOH estimation and RUL prediction of Li battery based on PSO-LSSVM at different temperatures [J]. Transducer and Microsystem Technologies, 2023, 42(6): 141-145.

[21]赵靖华, 闻龙, 汪守丰, 等. 基于改进组合核函数高斯过程回归的车速预测[J]. 吉林大学学报(理学版), 2025, 63(2): 454-464.
ZHAO Jinghua, WEN Long, WANG Shoufeng, et al. Vehicle speed prediction based on Gaussian process regression with improved combination kernel function [J]. Journal of Jilin University (Science Edition), 2025, 63(2): 454-464.

[22]PAN Y, ZENG X K, XU H X, et al. Evaluation of Gaussian process regression kernel functions for improving groundwater prediction [J]. Journal of Hydrology, 2021, 603: 126960.

[23]DEND T Q, YE D S, MA R, et al. Low-rank local tangent space embedding for subspace clustering [J]. Information Sciences, 2020, 508: 1-21.

[24]YANG X H, JIANG X Y, TIAN C X, et al. Inverse projection group sparse representation for tumor classification: A low rank variation dictionary approach [J]. Knowledge-Based Systems, 2020, 196(4): 105768.

[25]SI S, HSIEH C J, DHILLON I S. Memory efficient kernel approximation [J]. Journal of Machine Learning Research, 2017, 18(20): 1-32.

[26]蒋剑, 杜董生, 苏林. 基于改进HHO-LSTM-Self-Attention的质子交换膜燃料电池剩余使用寿命预测[J]. 综合智慧能源, 2025, 47(6): 47-56.
JIANG Jian, DU Dongsheng, SU Lin. Remaining useful life prediction of proton exchange membrane fuel cells based on improved HHO-LSTM-Self-Attention [J]. Integrated Intelligent Energy, 2025, 47(6): 47-56.

[27]李云, 周世杰, 胡哲千, 等. 基于NSGA-Ⅱ-WPA的综合能源系统多目标优化调度[J]. 综合智慧能源, 2024, 46(4): 1-9.
LI Yun, ZHOU Shijie, HU Zheqian, et al. Optimal scheduling of integrated energy systems based on NSGA-Ⅱ-WPA [J]. Integrated Intelligent Energy, 2024, 46(4): 1-9.

(本文责编:陆华)

收稿日期:2025-08-28;**修回日期**:2025-09-19
上网日期:2025-12-01;**附录网址**:www.iienergy.cn

作者简介:

胡林静(1975),女,副教授,硕士,从事热工过程控制、新能源利用等方面的研究 hulinjing666@163.com;

李在伟(1999),男,硕士生,从事新能源利用方面的研究,lizaiweijiayou@126.com。

中国知网　https://www.cnki.net